



北京邮电大学

遗传现象的通信理论描述

—— 信息论视角下的遗传信息传递定量描述方法

姓 名： 王殿云

班 级： 2022219107

学 号： 2022211733

所在学院： 人工智能学院

指导教师： 张国涵

2023 年 10 月

遗传现象的通信理论描述

摘要：本报告旨在描述各个生命层次中遗传现象的生物过程与现代通信中信息传递的过程，并参照现代通信过程对遗传现象进行数学建模，从信息论视角定量具体地描述不同层次的遗传过程中信息的传递过程，并探讨遗传信息的传递与通信过程的相似之处与遗传思想在具体问题中的应用，最终解答课题中提出的五个疑问。

关键词：生物 遗传 信息论 通信 数学建模

1 引言

自香农(C. E. SHANNON)于1948年发表《通信的数学理论》(*A Mathematical Theory of Communication*)一文后，现代信息论的基础工作便正式确立。自此，人类便对信息的产生、表示、传递有了更加贴近本质的深刻认知。与此同时，华生(James D. Watson)、克里克(Francis Crick)在分子层面的遗传研究揭示了DNA大分子作为遗传信息载体的作用，为人们揭开了笼罩在遗传学上的神秘面纱。随着信息论研究方法在通信问题中的广泛应用与遗传过程的深入研究，遗传系统和通信过程神秘的相似性被越来越多富有洞察力的研究者所关注。本文将从信息论的基础知识出发，试图发现并构建遗传现象中的通信模型，帮助读者更深入地理解遗传与信息的关系，并更好地理解遗传思想是怎么解决具体问题的。

2 遗传信息的传递与通信过程的相似之处

2.1 任务的一致性

遗传与通信的相似性首先体现在任务的一致。遗传的目的是为了在体细胞与生殖细胞、亲代与子代间尽可能完整地传递遗传信息，以保证子代继承基因信息的完整性和稳定性，确保子代对不变环境的适应能力。而通信的基本任务是在一个地方准确地或近似地复现在另一个地方选定的消息。两者的任务都是在两个不同的信息平台间或精确或部分地传递信息，有高度一致性。

2.2 系统的一致性

不难注意到，在相似的任务下，遗传信息的传递和通信的过程在系统上也具有高度一致性。生物遗传中，DNA 作为主要遗传物质，其中的遗传信息由碱基对序列编码表示，父代遗传信息和信源，父代用碱基对表示遗传信息和编码过程，DNA 复制或受精过程与信道，遗传信息在子代的转录和翻译，均有一一对应关系，在系统构成上有相当高的一致性。并且，DNA 在自我复制、转录和表达蛋白质时遵守的匹配规则和多种物质协同工作，与信息论中信道的容错降噪机制有紧密的联系。美国数学家维尔纳的《控制论》一书中也指出“许多存储信息的方法，共同具有一个重要的物理要素，这就是他们似乎都是高度量子简并性系统……量子简并性的出现，是由于这种物质具有某种由微小原因就能产生显著而稳定的结果的能力”，他更是提出“新陈代谢和生殖作用的许多问题，都与量子简并性有关”。为我们揭示了通信系统与生物遗传过程之间巧妙的对称性。

3 通信过程的数学描述方法

3.1 通信的基本任务

通信的基本问题就是在一个地方准确地或近似地复现在另一个地方选定的消息¹，这意味着尽可能精准地传递消息是通信的基本任务。而通信系统的基本需求，便是能够处理在指定通信问题中任意选定的消息¹，即通信系统确保全体消息集合中的任何消息都能被妥善处理。

3.2 通信的过程

现代的通信系统通常可以分为五个环节：信源、发送器、接收器、信宿。信源生成要发送给接收方的消息，发送器处理消息后生成能在信道中传送的信号，信道作为媒介供信号传递，接收器重构信息最后传递给信宿¹。而通信中还必须考虑噪声对信息传递的干扰作用，故引入噪声源，噪声源可能在信道中对信息进行干扰。




图 1 一般通信系统示意图

¹ C. E. SHANNON : *A Mathematical Theory of Communication*, 1984

3.3 信息论基本概念的描述方法

有信息论基础的读者可以跳过本部分的阅读，笔者希望在此处给出信息论中对通信过程的基本描述方法，便于后续建模时使用数学语言描述建模过程。

直观认知中，信息量似乎难以比较，更难定量描述。但可以认为，对某一时间，在没有任何信息的情况下，事件的所有可能构成了一个事件空间，而一则信息的作用便是消除事件空间中不可能的事件，由此消除事件的不确定性。而香农给出离散信源对不确定性的减少作用给出了信息熵 $H(x)$ 的定义¹：

$$H(x) = - \sum_{i=1}^n \{p(x_i) \log_2 p(x_i)\}$$

对于某个随机变量 x ，信息熵 $H(x)$ 表示通过对 x 的观测结果所消除的不确定性。当 x 的概率分布非常均匀，即各种结果都等可能时，信息熵最大。相反，当 x 的分布高度集中在某个特定结果上时，信息熵最小，因为几乎不需要信息来确定结果。

在遗传过程中，碱基对序列在复制、分配时存在错配等问题，单纯靠信息熵来描述信息并不足以全面地说明信息的不同特征维度，因此描述信息的抗干扰能力也尤为重要，此处引入冗余度 $R(x)$ 的概念，其定义为¹：

$$R = 1 - \frac{H(x)}{H_{\max}(x)}$$

即信源的熵与该信源可能有的最大熵之间的偏差，该信源的最大熵 $H_{\max}(x)$ 为 n 个 x 的概率分布均为 $1/n$ 时的情况，此时需要最多的信息来确定结果。可以直观地理解为冗余度和信息的抗干扰能力有正相关性。

根据生物学研究可知，遗传过程的信息符号序列中，每个符号并非是随机出现的²。举例而言，当我已知碱基序列的前缀序列，便能减少后缀序列的可能性，这意味着已有的信息可以在一定程度上降低后续信息的不确定性。因此，引入离散马尔科夫过程的概念，指符号的选择一定程度上取决于其前一个或几个符号的过程，即一个系统存在有限种可能“状态” $S_1, S_2, \dots, S_n$ 。此外，还有一组转换概率 $p_i(j)$ ，也就是当系统为状态 S_i ，接下来进入状态 S_j 的概率¹。这一过程可以用状态转移矩阵较为详细地描述，状态转移矩阵 P 的一般格式如下²：

$$P = \begin{pmatrix} p(S_1|S_1) & \cdots & p(S_1|S_n) \\ \vdots & \ddots & \vdots \\ p(S_n|S_1) & \cdots & p(S_n|S_n) \end{pmatrix}$$

其中每个 $p(S_i|S_j)$ 表示从状态 S_j 向状态 S_i 转移的概率。因此，当我们确定 x 时，为表示 y 平均有多大的不确定性，引入条件熵：

²陈建华.遗传密码的信息论[J].曲阜师院学报(自然科学版),1982,(04):58-66.

$$H(Y|X) = - \sum_{i,j} p(x_i, y_j) \log p(y_j|x_i)$$

在具体的通信过程中，考虑有噪声存在的情况，对于噪声，在传输过程中，接受信号 E 与传输信号 S 收到噪声 N 的干扰，存在如下关系¹

$$E = f(S, N)$$

当噪声存在的时候，上述通信中的马尔科夫过程相应受到影响，概率转移函数在噪声的影响下更新为 $p_{\alpha,i}(\beta, j)$ ，表示信道处于状态 α 并传输符号 i ，则接收到符号 j ，且信道变为状态 β 的概率。

对于有噪声存在的情况，因为无法确定地恢复原始信息，故引入疑义度 $H(x|y)$ 的概念，表示通信中收到干扰的信息量，用于度量接受信号的平均模糊度。显然，对于实际传输效率 R，有 $R = H(x) - H(x|y)$ 。也可以将疑义度理解为为了校正接收消息，在接收点每秒钟必须提供的附加信息量。

以上，使用信息论的方法，我们了解了用于描述通信过程特征的一系列基本工具，并拥有了定量地分析一个具体遗传过程中信息传递过程的信息论工具。

4 信息论视角下遗传现象在不同尺度生物层次上的具体表现与其建模过程

4.1 基本研究对象与方法

狭义上的遗传现象研究主要包含亲代与子代间的遗传现象，但这一过程包括细胞复制、细胞分裂、基因表达、有性生殖以及个体生长等多个维度。故本报告试探究上述各个流程中遗传现象的建模与遗传信息的定量描述。

对具体的情景来说，生物研究对象纷繁复杂，不可一概而论，因此本文中，出于一般性描述遗传现象的考虑和实际性的需要，以高等哺乳动物的细胞、个体、群落进行的遗传信息传递、继承、变异和表达为主要对象尝试进行建模。

上文中，笔者给出了通信的任务、过程与信息论中描述信息传递过程所需的基本概念工具。下文中，笔者将先描述不同生物层次下的遗传现象，然后建立具体空间尺度上遗传事件与不同通信阶段的对应关系，最后计算不同阶段中遗传信息所包含的信息熵、不确定度等可量化的指标，给出一般性的数学建模，供解决具体问题时求解计算。

4.2 分子与细胞尺度生物层次下的遗传现象建模

4.2.1 DNA 复制中的通信原理

4.2.1.1 DNA 复制的生物基础

通过对遗传学中基本知识的学习，可以获知关于遗传物质分子基础的基本相关知识：

- a) 除少数 RNA 病毒外，DNA 是其他所有生物的主要遗传物质。
- b) DNA，即脱氧核苷酸的多聚体，由四种脱氧核苷酸构成，分别为脱氧腺嘌呤核苷（dATP）、脱氧鸟嘌呤核苷酸（dGTP）、脱氧胞嘧啶核苷酸（dCTP）、脱氧胸腺嘧啶核苷酸（dTTP），分别简记为 A、G、C、T。且碱基 A 与 T、G 与 C 间存在互补配对关系。
- c) DNA 的基本结构是两条反向平行的核苷酸链被氢键连接形成的双螺旋结构，两条链同一位置的碱基满足碱基互补配对关系，配对的碱基间被氢键约束形成碱基对，故两条链能较稳定地维持结构。
- d) 细胞复制的过程中，DNA 双链解旋成为两条单链，两条单链各自充当模版链，与环境中游离的核苷酸按碱基互补配对原则配对，形成两条新的双链，完成半保留复制的过程。这个过程中最小的信息单位是核苷酸的种类。
- e) 碱基对按特定顺序排列形成 DNA 分子，DNA 的遗传信息由碱基对的排列顺序承载。³




图 2-4 DNA 分子双螺旋结构模型（引自 Klug and Cummings, 2002）

简单概括，DNA 由 A、T、C、G 四种碱基构成，遗传信息由碱基对的顺序和种类传递。由于两条链同一位置的碱基符合碱基互补配对原则，故考察一条链的碱基序列也能反应 DNA 的整体情况。在细胞复制这一遗传过程中，碱基作为最小的信息单位传递给新的 DNA，完成遗传过程。

4.2.1.2 DNA 复制的数学建模方法

下面给出信息论视角下，DNA 复制过程中将四种碱基作为基本事件时 DNA 分子中所含信息量的建模方法。

根据信息论相关知识，在考察 DNA 所含信息量时，应将其当做信源处理。而信源的信息量由信息熵和冗余度描述，故计算一段 DNA 的信息熵和冗余度便能反应其信息量。

³ 刘祖洞,乔守怡,吴燕华,赵寿元.《遗传学》(第3版)[J].遗传,2012,34(09):1107.

可知该信源的四个基本事件分别为 A、T、G、C，对一段 DNA 做 DNA 测序或分子杂交便可获得其四种碱基的比例信息。由信息熵的定义可知， $H(x) = -\sum_{i=1}^n \{p(x_i) \log_2 p(x_i)\}$ ，可见一段 DNA 所含的信息量与其碱基对的个数无关，而与其碱基的概率分布有关。因此不需要获得 DNA 碱基的详细数量信息便能了解该段 DNA 所包含的信息熵。信息熵反应了信源的消息多样性潜力，而冗余度则表示信源的信息存储能力，且冗余度与信源的信息存储能力呈正相关。

当 DNA 信源处于随机状态时，即四种碱基对出现的概率均为 $\frac{1}{4}$ 时，信源有最大信息熵

$$H(x) = -\sum_{i=A}^N \{p(x_i) \log_2 p(x_i)\} = -\frac{1}{4} \times 2 = -2 \text{ (bit)}$$

设一段 DNA 含有 N 个碱基，四种碱基的数量分别为 $N(A), N(T), N(G), N(C)$ ，则对该段 DNA，有：

$$\begin{aligned} H(x) &= -\sum_{i=A}^c \{p(x_i) \log_2 p(x_i)\} \\ &= \frac{N(A)}{N} \log_2 \frac{N(A)}{N} + \frac{N(T)}{N} \log_2 \frac{N(T)}{N} + \frac{N(G)}{N} \log_2 \frac{N(G)}{N} \\ &\quad + \frac{N(C)}{N} \log_2 \frac{N(C)}{N} \\ R &= 1 - \frac{H(x)}{H_{max}(x)} = 1 - \frac{H(x)}{2} \end{aligned}$$

可见，一个 DNA 分子的信息量同时受 R 与 H 约束，且约束关系呈负相关，故一段信息含量大的 DNA 必然在 R 与 H 的比例上呈现某种平衡。⁴

以上，我们给出了生物在 DNA 复制中遗传信息传递的数学过程。

4.2.2 基因表达中的通信原理

4.2.2.1 基因表达的生物基础

DNA 承载的信息可以从更大尺度的视角理解，仅碱基尺度解读有失偏颇。显然，生物的遗传信息也并不只有 A、T、C、G 四则。在生殖遗传、基因表达等情景下，DNA 所承载的是生物的蓝图信息，其信息对应的是相应的氨基酸乃至蛋白质种类。

由现代遗传理论可知，一段 DNA 中，每三个碱基构成一个密码子，四种碱基共能构成 $4^3 = 64$ 种密码子。UAA、UAG 和 UGA 为终止密码子，其余每种密

⁴ 陈建华.遗传密码的信息论[J].曲阜师院学报(自然科学版),1982,(04):58-66.

密码子对应唯一的氨基酸。但一种氨基酸并非对应唯一的密码子。密码子（U与 T 互换）与氨基酸的对应关系如下图。⁵

第一碱基 (5'端)	第二碱基 (中间碱基)								第三碱基 (3'端)
	U		C		A		G		
U	UUU	苯丙氨酸	UCU	丝氨酸 Ser	UAU	酪氨酸	UGU	半胱氨酸	U
	UUC	Phe	UCC		UAC	Tyr	UGC	Cys	C
	UUA	亮氨酸	UCA		UAA	终止密	UGA	终止密码子	A
	UUG	Leu	UCG		UAG	码子	UGG	色氨酸 Trp	G
C	CUU	亮氨酸 Leu	CCU	脯氨酸 Pro	CAU	组氨酸	CGU	精氨酸 Arg	U
	CUC		CCC		CAC	His	CGC		C
	CUA		CCA		CAA	谷氨酰胺	CGA		A
	CUG		CCG		CAG	Gln	CGG		G
A	AUU	异亮氨酸 Ile	ACU	苏氨酸 Thr	AAU	天冬酰胺	AGU	丝氨酸	U
	AUC		ACC		AAC	Asn	AGC	Ser	C
	AUA		ACA		AAA	赖氨酸	AGA	精氨酸	A
	AUG *	甲硫氨酸 Met	ACG		AAG	Lys	AGG	Arg	G
G	GUU	缬氨酸 Val	GCU	丙氨酸 Ala	GAU	天冬氨酸	GGU	甘氨酸 Gly	U
	GUC		GCC		GAC	Asp	GGC		C
	GUA		GCA		GAA	谷氨酸	GGA		A
	GUG *	缬氨酸 Val	GCG		GAA	Glu	GGG		G

注：* 同时为起始密码子。

值得注意的是，一个 DNA 分子上并非全部段落都是有意义的，我们将能够被表达的部分称为基因。显然，只有基因承载了会被表达的遗传信息，故未承载遗传信息的其余部分在本报告不予考察。

4.2.2.2 基因表达的数学建模方法

4.2.2.2.1 以密码子序列信息视角

对具体的基因表达过程进行考察，并使之与通信过程相对应。显然，信源依然是 DNA 上基因中的遗传信息，可以把一种密码子看成一个事件，共有 64 个基本事件。从三体密码到氨基酸的过程，可以看成是一个通讯过程。发出的消息是密码子，通过表达过程的信道，氨基酸则作为收到的信息。

理清了过程，下面给出信息论视角下，从密码子层面考察基因表达过程中 DNA 分子中所含信息量的建模方法。

为了建模的简洁性，做出如下假设：

- 环境对基因表达的情况视物种与环境不同，有诸多影响形式，本处仅探讨确知基因表达情况下的建模。
- 现代生物对基因表达的深入研究表明，基因的表达是一个受到众多偶然事件调控的过程，包括密码子偏倚、基因修饰等情况，不能一概而论，故本建模仅考虑无其他情况下基因的表达情况。

DNA 测序可知一段 DNA 分子的核苷酸序列，其中的基因片段可以三个碱基一组划分出密码子序列。引入两种密码子的表示方法便于后续探讨：

⁵ 刘祖洞,乔守怡,吴燕华,赵寿元.《遗传学》(第3版)[J].遗传,2012,34(09):1107.

- a) 对于某个氨基酸或终止信号 Y ，有 n_Y 种密码子 X_Y 相对应，值得注意的是，对于确定的 Y ， X_Y 并不唯一。
- b) 对于不需要考虑氨基酸与密码子对应关系的情况，密码子按上表顺序编码为 $x_1 \sim x_{64}$ 。

不难注意到，DNA 碱基序列的统计信息中，密码子的先后出现关系并非毫无关联，而是服从某种规律，类似于通信中的马尔科夫过程，在此仅探讨将 DNA 序列作为一阶马尔科夫链考虑时的情况。为此引入可由统计信息获得的密码子状态转移矩阵 P_{c-c} ：

$$P_{c-c} = \begin{pmatrix} p(x_1|x_1) & \cdots & p(x_{64}|x_1) \\ \vdots & \ddots & \vdots \\ p(x_1|x_{64}) & \cdots & p(x_{64}|x_{64}) \end{pmatrix}$$

根据以上信息，可以计算出，信源的信息量为：

$$H(X) = - \sum_{i=1}^{63} P(x_{i+1}x_i)P(x_{i+1}|x_i)$$

使用求条件极值的方法可以发现，当

考虑通信过程，因为一种氨基酸对应多个密码子，同时存在密码子与反密码子错配等情况，引入状态转移矩阵 P_{c-a} ：

$$P_{c-a} = \begin{pmatrix} p(x_1|y_1) & \cdots & p(x_{64}|y_1) \\ \vdots & \ddots & \vdots \\ p(x_1|y_{21}) & \cdots & p(x_{64}|y_{21}) \end{pmatrix}$$

信宿处收到某个氨基酸这一消息时，并不能确定信源发出的消息是哪个密码子。因此对于一段 DNA，在信宿处收到氨基酸序列后确认密码子序列还需要信息量：

$$H(X|Y) = - \sum_{j=1}^{24} \sum_{i=1}^{64} P(x_i y_j) \log P(x_i | y_j)$$

因此，收到消息后，对信源的情况还有 $H(X|Y)$ 的不确定性，称之为模棱度。而信道的传输率 R 表示输出端实际收到的信息量，计算式为⁶：

$$R = H(X) - H(X|Y) = - \sum_{i=1}^{63} P(x_{i+1}x_i)P(x_{i+1}|x_i) + \sum_{j=1}^{24} \sum_{i=1}^{64} P(x_i y_j) \log P(x_i | y_j)$$

通过以上指标，我们可以定量地描摹在表达这一通信过程中，在密码子尺度下，DNA 所包含的信息量，以及输出端接受到的信息量，和在通信过程中丢失的信息量。

⁶ 陈建华.遗传密码的信息论[J].曲阜师院学报(自然科学版),1982,(04):58-66.

4.2.2.2.2 以氨基酸序列信息视角

但同时，以密码子尺度来描述并不能很好地表达 DNA 在传递遗传信息中的抗干扰性和密码子的简并性，因此将视角拉远，如果把密码子看作承载氨基酸序列信息的符号——即氨基酸序列才是信源发送的信息，而密码子不过是经过调制的信号，便能重新衡量一段 DNA 的信息含量与通信过程中的不确定性。沿用之前的符号，分析如下。

新视角下，由上一阶段分析的密码子统计信息可以得知 DNA 片段上隐含的氨基酸序列信息，设氨基酸 Y 对应的密码子有 $X_1^Y \sim X_n^Y$ ，则可知 $p(y_1) =$

$\sum_{i=1}^n p(x_i)$ 。为此引入新的状态转移矩阵 $P_{a_0-a_0}$ ：

$$P_{a-a} = \begin{pmatrix} p(y_1|y_1) & \cdots & p(y_{21}|y_1) \\ \vdots & \ddots & \vdots \\ p(y_1|y_{21}) & \cdots & p(y_{21}|y_{21}) \end{pmatrix}$$

故新视角下一段 DNA 所承载的信息含量为：

$$H(X) = - \sum_{i=1}^{21} P(y_{i+1}|y_i) P(y_{i+1}|y_i)$$

而由因为信源和信宿的氨基酸序列信息具有一一对应关系，因此不确定度仅需考虑表达过程中产生的错配问题。设转录与翻译碱基互补配对时的转移矩阵分别为 $P_{c_{DNA}-c_{tRNA}}$ ， $P_{c_{tRNA}-a_1}$ ：

$$P_{c_{DNA}-c_{tRNA}} = \begin{pmatrix} p(x_1|x_1) & \cdots & p(x_{64}|x_1) \\ \vdots & \ddots & \vdots \\ p(x_1|x_{64}) & \cdots & p(x_{64}|x_{64}) \end{pmatrix}$$

$$P_{c_{tRNA}-a_1} = \begin{pmatrix} p(x_1|y_1) & \cdots & p(x_{64}|y_1) \\ \vdots & \ddots & \vdots \\ p(x_1|y_{21}) & \cdots & p(x_{64}|y_{21}) \end{pmatrix}$$

可以计算出，DNA 上的一则消息 Y_0 ，经过确定的编码变为 X_0 ，再经过转录、翻译被正确表达的概率为：

$$P(Y_1 Y_0) = p(x_n|x_n) \times p(x_n|y_m)$$

* m 为 x_n 对应的氨基酸种类

据此可以计算出，不确定度 $H(X|Y)$ 与传输率 R 的计算方法为

$$H(Y_1|Y_0) = - \sum_{j=1}^{24} \sum_{i=1}^{24} P(y_i y_j) \log P(y_i | y_j)$$
$$R = H(Y_0) - H(Y_1|Y_0)$$

由此，我们可以定量地描摹将氨基酸序列作为信源信息时，表达这一通信过程中信源的信息熵、信息传递中的不确定度与该信道的传输率。

4.3 个体与种群尺度生物层次下的遗传现象建模

4.3.1 有性生殖中的遗传现象建模

4.3.1.1 有性生殖的生物过程

有其父必有其子”、“龙生龙，凤生凤”，古已有之的谚语为我们揭示了亲代与子代之间的相似性，也意味着亲代与子代之间本就包含的信息传递过程——即性状从亲代流向子代这一遗传过程是生物特征信息传递的过程。从生殖遗传角度考虑，繁殖行为本身的结果是遗传信息在亲子两代间传递，亲代和子代之间的信息交流也蕴含着通信的模型。本节试从一对等位基因的情况出发，以信息论的视角综合考察包括伴性遗传、基因连锁等情况在内的遗传情况，为读者建立关于亲代向子代的基因遗传模型。

根据现代遗传学为遗传构建的简易模型可知，位于染色体上的一对或数对等位基因通常控制一个性状或数个，并受到环境的调控表达出不同的表现型。对有性生殖的生物而言，亲代生殖细胞经历两次减数分裂，确保核基因上的一对同源染色体分别由父母生殖细胞平均地分配到子代的生殖细胞中。两性生殖细胞在受精后合并，形成受精卵。然后，在环境条件的影响下，受精卵发育形成子代，而遗传信息在环境的影响下表达，最终决定子代的性状。⁷

4.3.1.2 有性生殖的数学建模

根据现代遗传学为遗传构建的简易模型可知，位于染色体上的一对或数对等位基因通常控制一个性状或数个，并受到环境的调控表达出不同的表现型。对有性生殖的生物而言，亲代生殖细胞经历两次减数分裂，确保核基因上的一对同源染色体分别由父母生殖细胞平均地分配到子代的生殖细胞中。两性生殖细胞在受精后合并，形成受精卵。然后，在环境条件的影响下，受精卵发育形成子代，而遗传信息在环境的影响下表达，最终决定子代的性状。

⁷ 刘祖洞,乔守怡,吴燕华,赵寿元.《遗传学》(第3版)[J].遗传,2012,34(09):1107.

通过分析这一遗传过程和通信过程的相似性可以得到，分别位于父本与母本中的一对等位基因承载的遗传信息作为信源，通过信道，即包括两次减数分裂、授精在内的过程到达子代，而子代作为新宿接受来自亲代的遗传信息。下面对这一过程建模，并分析其中的信息流动特征。

将要分析的等位基因记作 A，其对应的显性基因与隐性基因分别记作 A 与 a。可以发现，信源的基本事件包括 AA、Aa 和 aa 共 3 件，一则信息只有两个位置。其对应的信息熵为：

$$H(X) = - \sum_{i=1}^3 p(x_i) \log p(x_i)$$

用求条件极值的方法可以求得，对于一个确定的亲本组合，即一个父本和一个母本来说，当父本和母本的基因型不同时，有 $H(X) = 1$ 。同时，只存在另外一种可能的情况，即父本和母本的基因型相同时， $H(X) = 0$ 。在这种情况下，该信源的冗余度 $1 - H(X)$ 。可见，对于父本与母本基因型相同的情况下，信源冗余度比较大，毕竟父本或母本中的任何一个个体具有子代所需要全部等位基因。

在这种情况下，受交配环境、亲本身体状况等因素影响，可以由统计信息获得不同亲代基因型下子代关于等位基因 A 的遗传情况，统计信息用转移矩阵 $P_{P \rightarrow F}$ 表示，注意父本与母本基因型的顺序可能会影响子代的基因型，故采用父本基因型 $\times$ 母本基因型的方式表示亲代基因型（考虑基因突变等情况）：

$$P_{P \rightarrow F} = \begin{pmatrix} p(AA|AA \times AA) & p(AA|AA \times Aa) & p(AA|AA \times aa) & p(Aa|AA \times AA) & p(Aa|AA \times Aa) & p(Aa|AA \times aa) & p(aa|AA \times AA) & p(aa|AA \times Aa) & p(aa|AA \times aa) \\ p(Aa|AA \times AA) & p(Aa|AA \times Aa) & p(Aa|AA \times aa) & p(Aa|Aa \times AA) & p(Aa|Aa \times Aa) & p(Aa|Aa \times aa) & p(Aa|aa \times AA) & p(Aa|aa \times Aa) & p(Aa|aa \times aa) \\ p(aa|AA \times AA) & p(aa|AA \times Aa) & p(aa|AA \times aa) & p(aa|Aa \times AA) & p(aa|Aa \times Aa) & p(aa|Aa \times aa) & p(aa|aa \times AA) & p(aa|aa \times Aa) & p(aa|aa \times aa) \end{pmatrix}$$

考察信宿的情况，可以发现子代作为信宿仍然具有三种基本事件 AA、Aa、aa。在收到子代的信息后，还不能确切地知道亲代的基因型构成。用 Y 表示亲代的有序基因型构成，可以计算得出，在子代处收到子代基因型后还需要信息量：

$$H(X|Y) = - \sum_{j=1}^9 \sum_{i=1}^3 P(x_i y_j) \log P(x_i | y_j)$$

据此，可以得知在子代收到遗传信息后，对信源的情况还有 $H(X|Y)$ 的不确定性，称之为模棱度。而信道的传输率 R 表示输出端实际收到的信息量，计算式为：

$$R = H(X) - H(X|Y) = - \sum_{i=1}^3 p(x_i) \log p(x_i) + \sum_{j=1}^9 \sum_{i=1}^3 P(x_i y_j) \log P(x_i | y_j)$$

以上给出了对于一对等位基因在有性繁殖遗传过程中的信息传递情况，只要拥有对于特定环境特定生物个体的状态转移矩阵，就能较为简便地算出该过程的通信情况。

当然，生物的遗传并非是一对等位基因的传递，下面对这一过程进行扩展，考虑多对常染色体等位基因和性染色体基因与环境一同作用下影响性状的过程，并尝试对其建模描述。

基本分析过程同上，我们设生物甲的性状由 m 对常染色体基因与 x 个伴 X 染色体基因与 y 个伴 Y 染色体基因共同影响，可以给出一个雌性甲个体的基因构成为 $M_0M_0/M_1m_1/M_2m_2/M_3m_3 \sim M_nm_n/X_1x_0/X_1x_1 \sim X_x x_x$ ，雄性个体的基因型则可以用 $M_0M_0/M_1m_1/M_2m_2/M_3m_3 \sim M_nm_n/X_1/x_2 \sim X_x/Y_1/Y_2 \sim Y_y$ 的形式来表示。将一种特定的基因型记为 G_n ， n 由基因串编码的二进制数对应的十进制数表示，编码规则为按顺序排列的基因串中显性基因标记为 1，隐性基因标记为 0，不存在的伴性遗传基因位均标记为 0，可知一共有 $N_{All} = 3^n(3^x + 2^x 2^y)$ 种情况。但是发现，对于一个确定的父本母本，仍然只能选择一个父本与一个母本，且由于考虑了性染色体，自然情况下的基因型必定不同。因此信源的信息熵 $H(X)$ 与冗余度 $R(X)$ 必定为：

$$H(X) = - \sum_{i=1}^3 p(x_i) \log p(x_i) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 1$$

$$R(X) = 1 - \frac{H(X)}{H_{max}(X)} = 1 - 1 = 0$$

同时，分析方法同一对等位基因的情况，可以根据统计的方法获得在已知亲本基因型的情况下子代为特定基因型的概率。状态转移矩阵 $P_{P \rightarrow F}$ 可以表示如下：

$$P_{P \rightarrow F} = \begin{pmatrix} p(G_1|G_1 \times G_1) & \cdots & p(G_1|G_{N_{ALL}} \times G_{N_{ALL}}) \\ \vdots & \ddots & \vdots \\ p(G_{N_{ALL}}|G_1 \times G_1) & \cdots & p(G_{N_{ALL}}|G_{N_{ALL}} \times G_{N_{ALL}}) \end{pmatrix}$$

也可以用与之前一样的方式表示通信过程中的模棱度 $H(X|Y)$ 与信道的传输率 R ：

$$H(X|Y) = - \sum_{j=1}^{N_{ALL}^2} \sum_{i=1}^{N_{ALL}} P(x_i y_j) \log P(x_i | y_j)$$

$$R = H(X) - H(X|Y) = 1 + - \sum_{j=1}^{N_{ALL}^2} \sum_{i=1}^{N_{ALL}} P(x_i y_j) \log P(x_i | y_j)$$

但这并非终点，而是子代的起点，遗传信息在子代中的表达仍收到环境信息的调控。环境对表型的影响设计连续的过程，这里先引入信息论中密度函数连续型分布的信息熵，为了便于计算，底数取 e：⁸

$$H(x, y) = - \int \int f(x, y) \ln f(x, y) dx dy$$

由于表现型是基因型和环境共同作用的结果，根据 Weiser M. 的研究成果与柯卫东的研究成果，可以合理地假设三者呈线性关系，且不考虑基因型与环境的相互作用时，可以列出下式：

$$H(p) = H(g) + H(e)$$

$$V_p = V_g + V_e$$

又因为 G 与 E 的影响均服从正态分布，可以通过计算得知子代表现型受到基因型的信息量有⁸：

$$H(p, g) = H(p) - H(e) = \frac{1}{2} \ln[2\pi e(V_g + V_e)] - \frac{1}{2} \ln(2\pi e V_e) = \frac{1}{2} \ln\left(\frac{V_g + V_e}{V_e}\right)$$

在这个过程中，可以将子代生长的环境看做是亲本基因型在表达中受到的噪音，此噪音的影响程度由信噪比定义，定义为信号与噪声功率的比值，在本模型中用 V_g 与 V_e 表示如下：

$$\rho = \frac{V_g}{V_e}$$

因此，对于确定的情况，我们可以通过计算基因型与环境信息方差的方式来获得基因表达这一过程的信噪比。但因为在实际研究中，较难定义环境与基因的方差，故此处给出其他计算方式。不难发现，有⁸：

$$H(p, g) = \frac{1}{2} \ln\left(\frac{V_g + V_e}{V_e}\right) = \frac{1}{2} \ln\left(\frac{V_g}{V_e} + 1\right) = \frac{1}{2} \ln(\rho + 1)$$

故

$$\rho = e^{2H(p, g)} - 1$$

可以较为直观地发现，环境噪声相同的情况下，基因型传递给表现型的信息越多，信噪比越大，遗传对表型的稳定性也越强。

以上，该建模较为全面地给出了有性生殖的生物在繁殖过程中 DNA 中的遗传信息从亲代流向子代，最终由子代在环境中表达的过程，定量地刻画了各个通信过程中的信息特征。

4.3.2 群体基因库

上述部分给出了遗传现象从分子到个体层面的表征与建模，下面主要考虑群体层面遗传现象的发生过程。

⁸ 柯卫东,刘采芹.数量遗传学中的信息问题初探[J].自然杂志,1990,(04):210-212.

遗传学上的群体是指相互有交配关系的个体构成的有机几何体，其基因库则是指该群体中全部个体包含的基因总集。⁹对于群体，遗传上主要研究其基因库的组成情况，研究内容上关心该群体基因库的构成情况与其基因多样性。

描述一个群体基因库的主要维度有其基因频率和基因型频率。当一个群体各基因频率在上下代保持相对稳定时，其个体性状也相对保持稳定。而此时，根据 *Hardy-Weinberg* 定律，基因型频率和基因频率的关系是 $D = p^2, H = 2pq, R = q^2$ 。其中 p, q 分别表示任何一对等位基因 A, a 的频率， D, H, R 分别表示显性纯合子、杂合子和隐性纯合子的基因型概率。

对一个群体的每个复等位基因 A^i ，可以用下式描述其基因库中的全部基因的基因频率：

$$A_1^i, A_2^i, \dots, A_K^i = P_1^i, P_2^i, \dots, P_K^i, \sum_{j=1}^K P_j^i = 1$$

从基因的层面考量，若将基因库 S 中的全部基因看作一个信源中的信息，将每种复等位基因看作信源中的一个基本事件，可以给出其信息熵 $H(A)$ 和冗余度 $R(X)$ 的计算方式如下¹⁰：

$$H(A) = \sum_{i=0} p(a) \log p(a) = \sum_{i=0} \sum_{j=0} P_j^i \log P_j^i$$

$$R(A) = 1 - \frac{H(A)}{H_{\max}(A)} = 1 - \frac{H(A)}{\log \frac{1}{ij}}$$

但同时，一个生物群体的主要特征由信息表征，而性状主要由基因型表征，故同时给出以基因型为信源基本事件的信息熵计算方式。设该基因库对应的群体中纯合基因型 $A_i A_i$ 有 K 个，频率为 D_i ，杂合基因型 $A_i A_j$ 有 $\frac{K(K-1)}{2}$ 个，则对整个群体的基因库有：

$$A_1 A_1, A_2 A_2, \dots, A_K A_K, A_1 A_3, A_1 A_2, \dots, A_{K-1} A_K = D_1 D_2, \dots, D_K, H_{12} H_{13}, \dots, H_{K-1 K}$$

其纯合体信息量 $H_j(G)$ 和 $H_H(G)$ 和其对应的冗余度 $R_j(G)$ 和 $R_H(G)$ 可以分别定义为：

$$H_j(G) = - \sum_{i=1}^K D_i \log D_i \quad H_h(G) = - \sum_{i < j} H_{ij} \log H_{ij}$$

⁹ 遗传学 第三版 刘庆昌 科学出版社

¹⁰ 郭满才, 宋世德, 周静芋, 袁志发. 非平衡群体基因变异测量的 Shannon 信息量方法[J]. 生物数学学报, 2001, (03): 341-347.

$$R_j(G) = 1 - \frac{H_j(G)}{H_{j_{max}}(G)} \quad R_h(G) = 1 - \frac{H_h(A)}{H_{h_{max}}(A)}$$

又因为信息熵的计算有线性关系，故群体基因型总信息熵与冗余度为：

$$H(G) = -\left(\sum_{i=1}^K D_i \log D_i + \sum_{i < j} H_{ij} \log H_{ij}\right)$$

$$H(G) = 1 - \frac{H(G)}{H_{max}(G)}$$

上文给出了将群体基因库当做信源考虑时，其信息熵与冗余度描述方式，下面探讨群体与群体之间的通信问题。若把一个物种看做群体，其所有个体的基因构成一个物种基因库，在这里称为总集 S 。

但由于物种被环境分割为不同的种群，每个种群的基因库可以看作是 S 的一个子集 S_i 。种群和种群之间发生交配关系的概率因地理隔离等因素而降低，造成种群与种群基因交流减少，最终导致种群与种群间基因库构成存在差异性，即 $S_i \neq S_j, \cup S_i = S$ 。但并不意味着同一物种不同种群间无法进行基因交流，正相反，自然界中群体的迁入迁出现象并不罕见，这也带来的基因流动的可能。

下面讨论同一物种的两个种群发生基因交流时的一对复等位基因的基因型信息流动情况。

设个体数量分别为 i, j 的两个种群 P_i 和 P_j 每个群体的基因库都有复等位基因 A^k 的基因型及其概率如下：

$$A^k_1 A^k_1, A^k_2 A^k_2, \dots, A^k_K A^k_K, A^k_1 A^k_3, A^k_1 A^k_2, \dots, A^k_{K-1} A^k_K$$

$$= D^k_1, D^k_2, \dots, D^k_K, H^k_{12}, H^k_{13}, \dots, H^k_{K-1 K}$$

先描述两个群体自然状态下因个体流动等原因发生基因交换的情况。定义矩阵 P_i 和 P_j ：

$$P_i = (p_i(1) \quad \cdots \quad p_i(n))$$

$$P_j = (p_j(1) \quad \cdots \quad p_j(n))$$

$p_i(n)$ 表示 S_i 中第 n 种基因型流动到 S_j 的概率，反之同理。

故可以刻画出自然状态下基因流动的过程，设 S_i 有 N_i 次向 S_j 基因流动的机会，流动后 S_i 与 S_j 更新为 S'_i 与 S'_j 。只需要计算 S'_i 与 S'_j 的信息熵变化量 $\Delta H_i, \Delta H_j$ ，便可定量描述这一流动过程对两个基因库的信息量影响。当 N_i 较大时，可以认为各个基因的流动频率与 P_i 一致。此时对 S'_i 有：

$$\begin{aligned}
& A_1^{k'} A_1^{k'}, A_2^{k'}, A_2^{k'} \dots A_K^{k'} A_K^{k'}, A_1^{k'} A_3^{k'}, A_1^{k'} A_2^{k'}, \dots, A_{K-1}^{k'} A_K^{k'} \\
& = D_1^{k'}, D_2^{k'}, \dots, D_K^{k'}, H_{12}^{k'} H_{13}^{k'}, \dots, H_{K-1 K}^{k'} \\
& = \frac{iD_1^k - N_i P_i[1]}{i - N_i}, \frac{iD_2^k - N_i P_i[2]}{i - N_i}, \dots, \frac{iD_K^k - N_i P_i[k]}{i - N_i}, \frac{iH_{12}^k - N_i P_i[k+1]}{i - N_i}, \frac{iH_{13}^k - N_i P_i[k+2]}{i - N_i}, \dots, \frac{iH_{K-1 K}^k - N_i P_i[k+K-1]}{i - N_i}
\end{aligned}$$

此时对 S_j' 有:

$$\begin{aligned}
& A_1^{k'} A_1^{k'}, A_2^{k'}, A_2^{k'} \dots A_K^{k'} A_K^{k'}, A_1^{k'} A_3^{k'}, A_1^{k'} A_2^{k'}, \dots, A_{K-1}^{k'} A_K^{k'} \\
& = D_1^{k'}, D_2^{k'}, \dots, D_K^{k'}, H_{12}^{k'} H_{13}^{k'}, \dots, H_{K-1 K}^{k'} \\
& = \frac{jD_1^k + N_i P_i[1]}{j + N_i}, \frac{jD_2^k + N_i P_i[2]}{j + N_i}, \dots, \frac{jD_K^k + N_i P_i[k]}{j + N_i}, \frac{jH_{12}^k + N_i P_i[k+1]}{j + N_i}, \frac{jH_{13}^k + N_i P_i[k+2]}{j + N_i}, \dots, \frac{jH_{K-1 K}^k + N_i P_i[k+K-1]}{j + N_i}
\end{aligned}$$

此时对 $S_i S_j$ 仍有:

$$H_j'(G) = - \sum_{i=1}^K D_i' \log D_i' \quad H_h'(G) = - \sum_{i < j} H_{ij}' \log H_{ij}'$$

$$H'(G) = - \left(\sum_{i=1}^K D_i' \log D_i' + \sum_{i < j} H_{ij}' \log H_{ij}' \right)$$

故可给出 $\Delta H_i, \Delta H_j$ 的计算方法如下(注意前后 i, j 无关):

$$\begin{aligned}
\Delta H_i &= H_i'(G) - H_i(G) \\
&= \sum_{i=1}^K (D_i' \log D_i' - D_i \log D_i) \\
&\quad + \sum_{i < j} (H_{ij}' \log H_{ij}' - H_{ij} \log H_{ij}) \\
&= \sum_{i=1}^K (D_i' \log D_i' - D_i \log D_i) \\
&\quad + \sum_{i < j} (H_{ij}' \log H_{ij}' - H_{ij} \log H_{ij}) \\
&= \sum_{i=1}^K (D_i' \log D_i' - D_i \log D_i) + \sum_{i < j} (H_{ij}' \log H_{ij}' - H_{ij} \log H_{ij})
\end{aligned}$$

$$\Delta H_j = H_j'(G) - H_j(G) = \sum_{i=1}^K (D_i' \log D_i' - D_i \log D_i) + \sum_{i < j} (H_{ij}' \log H_{ij}' - H_{ij} \log H_{ij})$$

对于确定的情景，上述方法描述了信息在同一物种两个群体间流动的情况，并分别给出了纯合子与杂合子的基因信息描述方法。由此，我们可以定量地描述一个种群基因库中基因或基因型的信息含量，便于后续定量分析特定种群信息库中的信息含量。值得注意的是，与 P_i 相关的信息仍要对实际情况中两个种群的流动情况进行统计才能获得。

5 研究课题中的问题解决

5.1 DNA 序列有效信息量的计算

问题：

信息论中，一条消息所蕴含的信息量可以用获得这一消息后所消除的不确定概率来衡量。在遗传过程中，是否可以用类似的方法计算一段 DNA 序列的有效信息量？

解答：

根据前述建模方法，通过 4.2.2.2 节基因表达的数学建模方法、4.2.2.2 节基因表达的数学建模方法和 4.3.1.2 节有性生殖的数学建模方法，我们可以给出不同尺度下一段 DNA 中的有效信息量如下：

碱基序列尺度：

$$\begin{aligned} H(x) &= - \sum_{i=A}^C \{ p(x_i) \log_2 p(x_i) \} \\ &= \frac{N(A)}{N} \log_2 \frac{N(A)}{N} + \frac{N(T)}{N} \log_2 \frac{N(T)}{N} + \frac{N(G)}{N} \log_2 \frac{N(G)}{N} \\ &\quad + \frac{N(C)}{N} \log_2 \frac{N(C)}{N} \end{aligned}$$

密码子序列尺度：

$$H(X) = - \sum_{i=1}^{63} P(x_{i+1}x_i) P(x_{i+1}|x_i)$$

氨基酸序列尺度：

$$H(X) = - \sum_{i=1}^{21} P(y_{i+1}y_i) P(y_{i+1}|y_i)$$

等位基因尺度：

$$H(X|Y) = - \sum_{j=1}^{N_{ALL}^2} \sum_{i=1}^{N_{ALL}} P(x_i y_j) \log P(x_i | y_j)$$

5.2 DNA 稳定性的机制

问题：

为了保证通信过程中传输信息的完整性，人们引入了多种纠错编码技术。遗传过程中 DNA 是如何保持强大稳定性的呢？能否将其视作一种纠错编码呢？

解答：

通信过程中，对于有噪声存在的情况，人们引入了一种名为多元符号编码（Multilevel Symbol Encoding）的纠错编码方式，用来纠正易出错的信息。在多元符号编码中，一个符号可以用多个不同容易在通信过程中发生跳变的编码表示，以增加容错性。例如对于电报通信系统，A 的编码是 0001，但在通信过程中受噪声干扰，0001 可能被干扰而跳变为 0101 或 0000，因此用 0101、0000 和 0001 编码 A，减少报文出错的概率。

类似地，生物在遗传信息的传递上也采用了类似的多元符号编码方式，即多个密码子编码同一个氨基酸，也意味着遗传密码的通信符号系统存在普遍的简并性。为证明这一编码方式能有效降低遗传信息中氨基酸序列信息表达达到蛋白质中氨基酸序列信息这一过程的易错性，给出以下论证：

假设：

遗传密码的简并性能减低遗传信息中氨基酸序列信息表达达到蛋白质中氨基酸序列信息这一通信过程中的错误率。

证明：

首先给出通信过程中错误率的表示方式，此处采用符号错误率表示错误的程度，定义式如下：

$$SER = \frac{N_{err}}{N_{All}} \times 100\%$$

由 4.2.2.2 节基因表达的数学建模方法中第二部分的论述可知，对于表达中原基因上隐含的氨基酸序列信息 A_0 、原基因上的密码子序列 C_0 、转录到 tRNA 后的反密码子序列 C_1 和翻译出的氨基酸序列 A_1 ，分别有状态转移矩阵 $P_{a_0-c_0}$, $P_{c_0-c_1}$, $P_{c_0-a_1}$ 表示转移概率，值得注意

的是， $P_{a_0-c_0}$ 中的概率均为 1 或 0，因为一个氨基酸和密码子之间的编码规则已经确定，只存在唯一的映射关系（大写字母代表序列，小写字母代表符号）：

$$F(C_0) = A_0$$

有了以上三个矩阵，设一段基因序列对应的氨基酸个数为 N ，就可以计算出一段基因上氨基酸符号序列再表达中的错误率，即：

$$SER(A_0, A_1) = \frac{N_{err}}{N_{All}} \times 100\% = \left(1 - \frac{N_{crt}}{N_{All}}\right) \times 100\% = 1 - \sum_{i=1}^N \frac{i}{n} \times P_i^N$$

P_i^N 表示的是对于长为 N 的序列，有 i 个氨基酸被正确表达的概率，计算式如下：

$$P_i^N = \sum_{\substack{\text{从 } N \text{ 中选 } i \text{ 个} \\ \text{不同的序号 } j}} \left(\prod p(c_1^j | c_0^j) p(a_1^j = F(c_0^j) | c_1^j) \right)$$

据此可以计算出一段基因序列在表达的符号错误率 $SER(A_0, A_1)$ ，下面模拟比较简并性对错误的减少作用。

对于上述矩阵，目前并不具有普适性的研究成果。而现有研究成果表明，大部分原核和真核生物的转录错误率基本上都在 10^{-6} 量级水平，而翻译的错误率达到了 10^{-4} 量级水平，故在此设 21 个基因在转录和翻译中的转移矩阵如下：

$$P_{c_0-c_1} = \begin{pmatrix} 1 - 10^{-6} & 10^{-6} & \cdots & 10^{-6} & 10^{-6} \\ 10^{-6} & 1 - 10^{-6} & \cdots & 10^{-6} & 10^{-6} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 10^{-6} & 10^{-6} & \cdots & 1 - 10^{-6} & 10^{-6} \\ 10^{-6} & 10^{-6} & \cdots & 10^{-6} & 1 - 10^{-6} \end{pmatrix},$$

$$P_{c_0-a_1} = \begin{pmatrix} 1 - 10^{-4} & 10^{-4} & \cdots & 10^{-4} & 10^{-4} \\ 10^{-4} & 1 - 10^{-4} & \cdots & 10^{-4} & 10^{-4} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 10^{-4} & 10^{-4} & \cdots & 1 - 10^{-4} & 10^{-4} \\ 10^{-4} & 10^{-4} & \cdots & 10^{-4} & 1 - 10^{-4} \end{pmatrix},$$

为方便后续表述，重新定义符号 $\binom{i}{N}(P)^i$ 表示从长为 N 的序列中找出 i 个元素，求这 i 个元素的概率之积，然后再求所有这样的序列的概率之积的和。使用 MATLAB 实现从长为 N 的有序序列中选择 n 个位点的递归算法实现方式如下：

```
function combinations = generateCombinationsIndices(N, n)
```

```

combinations = {}; % 存储组合的单元格数组

% 边界情况：如果 n 为 0，返回一个空组合
if n == 0
    combinations = {};
    return;
end

% 递归基本情况：如果 n 等于序列的长度 N，返回整个序列的编号作为一个组合
if n == N
    combinations = {[1:N]};
    return;
end

% 递归情况：生成所有组合的编号
for i = 1:N
    % 生成剩余部分的组合的编号
    remainingCombinations = generateCombinationsIndices(N -
i, n - 1);

    % 将当前元素与剩余组合组合起来
    for j = 1:length(remainingCombinations)
        combinationIndices = [i, i +
remainingCombinations{j}];
        combinations{end + 1} = combinationIndices;
    end
end
end

```

A. 对于不存在简并性的基因编码系统，密码子和氨基酸具有一一对应关系，即 C_0 集和 A_0 集存在双射关系。对于该情况，可以简化SER的运算：

$$P_i^N = \left[\binom{i}{N} (P_{c_0-c_1}(i, i) P_{c_1-a_1}(i, i))^i \binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \right. \\ \left. + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i))]^{N-i} \right] \\ + P^*$$

$$P^* \approx 10^{-6} \times 10^{-4} = 10^{-10}$$

* P' 表示除了对角线上的任意值,

* P^* 表示错配后又成功错配回正确氨基酸的概率

故 P^* 概率极小, 可以忽略不计。

$$SER(A_0, A_1) = 1 - \sum_{i=1}^N \frac{i}{n} \times P_i^N \\ = 1 - \sum_{i=1}^N \frac{i}{n} \times \left[\binom{i}{N} (P_{c_0-c_1}(i, i) P_{c_1-a_1}(i, i))^i \binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \right. \\ \left. + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i))]^{N-i} \right]$$

B. 对于生物的基因编码系统, 有

$$F(C_0) = A_0$$

设 a_0 对应的 c_0 数量为 N_{a_0} , $F(c_0^1) = \dots = F(c_0^{N_{a_0}}) = A_0$ 。

故存在转录时错误, 但经过翻译仍对应相同氨基酸的情况, 即:

$$C_0^i(A_0^i) \rightarrow C_1^{i'} \rightarrow A_1^i$$

对于某个 a_0 的这一过程, 概率 P' 为:

$$P' = P_{c_0-c_1}'(i, i) \times N_{a_0}$$

因此, 有:

$$P_i^N = P + P' + P^* \\ = \binom{i}{N} (P_{c_0-c_1}(i, i) P_{c_1-a_1}(i, i))^i \binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \\ + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i)) \\ - P_{c_0-c_1}'(i, i) \times N_{a_0}]^{N-i} \\ + \binom{i}{N} (P_{c_0-c_1}'(i, i) \times N_{a_0})^i \binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \\ + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i)) \\ - P_{c_0-c_1}'(i, i) \times N_{a_0}]^{N-i} + 0$$

$$\begin{aligned}
SER(A_0, A_1) &= 1 - \sum_{i=1}^N \frac{i}{n} \times P_i^N \\
&= 1 - \sum_{i=1}^N \frac{i}{n} \times \left(\binom{i}{N} (P_{c_0-c_1}(i, i) P_{c_1-a_1}(i, i))^i \left(\binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \right. \right. \\
&\quad \left. \left. + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i) \right. \right. \\
&\quad \left. \left. - P_{c_0-c_1}'(i, i) \times N_{a_0})]^{N-i} \right. \right. \\
&\quad \left. \left. + \binom{i}{N} (P_{c_0-c_1}'(i, i) \times N_{a_0})^i \left(\binom{N-i}{N} [(P_{c_0-c_1}'(i, i) P_{c_1-a_1}'(i, i)) \right. \right. \right. \\
&\quad \left. \left. + (P_{c_0-c_1}(i, i) P_{c_1-a_1}'(i, i)) + (P_{c_0-c_1}'(i, i) P_{c_1-a_1}(i, i) \right. \right. \\
&\quad \left. \left. - P_{c_0-c_1}'(i, i) \times N_{a_0})]^{N-i} \right) \right)
\end{aligned}$$

下面使用 MATLAB 进行仿真实验，对比两种情况在序列情况为变量的情况下，两种密码子系统的 SER 值的变化情况 $SER(N)$ 及其对比，设计程序如下：

函数：

```

function numNonZero = countNonZeroElementsInRow(coden, matrix)
    rowNumber = findRowWithNonZeroInNthColumn(coden, matrix);
    % 获取指定行
    targetRow = matrix(rowNumber, :);

    % 计算非零元素的个数
    numNonZero = sum(targetRow ~= 0);

end

function rowNumber = findRowWithNonZeroInNthColumn(coden, matrix)
    [numRows, ~] = size(matrix); % 获取矩阵的行数
    N = mapCodonToNumber(coden);
    for row = 1:numRows
        if matrix(row, N) ~= 0
            rowNumber = row; % 找到第一个不为 0 的元素所在的行
            return; % 返回行号并结束函数
        end
    end
    % 如果没有找到，返回 -1 表示未找到
    rowNumber = -1;

end

```

```

function codonSequence = generateRandomCodonSequence(N)
    codons = {'UUU', 'UUC', 'UUA', 'UUG', 'UCU', 'UCC', 'UCA', 'UCG',
'UAU', 'UAC', 'UAA', 'UAG', 'UGU', 'UGC', 'UGA', 'UGG', 'CUU', 'CUC',
'CUA', 'CUG', 'CCU', 'CCC', 'CCA', 'CCG', 'CAU', 'CAC', 'CAA', 'CAG',
'CGU', 'CGC', 'CGA', 'CGG', 'AUU', 'AUC', 'AUA', 'AUG', 'ACU', 'ACC',
'ACA', 'ACG', 'AAU', 'AAC', 'AAA', 'AAG', 'AGU', 'AGC', 'AGA', 'AGG',
'GUU', 'GUC', 'GUA', 'GUG', 'GCU', 'GCC', 'GCA', 'GCG', 'GAU', 'GAC',
'GAA', 'GAG', 'GGU', 'GGC', 'GGA', 'GGG'};
    codonSequence = cell(1, N);
    for i = 1:N
        randomIndex = randi(64); % 随机选择 1 到 64 之间的整数
        codonSequence{i} = codons{randomIndex};
    end
end
function result = SER_1(N, Pa0_c0, Pc0_c1, Pc1_a1)
    len = length(N);
    pc0_c1 = zeros(1, len);
    pc1_a1 = zeros(1, len);

    % 计算 pc0_c1 和 pc1_a1
    for i = 1:len
        coden = mapCodonToNumber(N{i});
        aminoacid = findRowWithNonZeroInNthColumn(N{i}, Pa0_c0);
        pc0_c1(i) = Pc0_c1(coden, coden);
        pc1_a1(i) = 1-1e-4;
    end

    result = 0; % 初始化结果为 0

    for i = 0:len
        indexList = generateCombinationsIndices(len, i);
        temp_p = 0;

        for j = 1:length(indexList)
            permutation = indexList{j};
            prob = 1; % 初始化为 1

```



```

        % 计算每个位置的概率
        for k = 1:len
            if ismember(k, permutation)
                prob = prob * pc0_c1(k) * pc1_a1(k);
            else
                prob = prob * ((1 - pc0_c1(k)) * pc1_a1(k) +
pc0_c1(k) * (1 - pc1_a1(k)));
            end
        end

        temp_p = temp_p + i/len*prob;
    end

    % 将 temp_p 加到结果里
    result = result + temp_p;
end

result = 1 - result;
end
function result = SER_2(N, Pa0_c0, Pc0_c1, Pc1_a1)
    len = length(N);
    pc0_c1 = zeros(1, len);
    pc1_a1 = zeros(1, len);
    Na = zeros(1, len);

    % 计算 pc0_c1 和 pc1_a1
    for i = 1:len
        coden = mapCodonToNumber(N{i});
        aminoacid = findRowWithNonZeroInNthColumn(N{i}, Pa0_c0);
        pc0_c1(i) = Pc0_c1(coden, coden);
        pc1_a1(i) = 1-1e-4;
        Na(i) = countNonZeroElementsInRow(N{i},Pa0_c0);
    end
    disp(pc1_a1)
end

```

```

result = 0; % 初始化结果为 0

for i = 0:len
    indexList = generateCombinationsIndices(len, i);
    temp_p = 0;

    for j = 1:length(indexList)
        permutation = indexList{j};
        prob = 1; % 初始化为 1

        % 计算每个位置的概率
        for k = 1:len
            if ismember(k, permutation)
                prob = prob * (pc0_c1(k) * pc1_a1(k)+Na(i)*(1-
pc0_c1(k))*pc1_a1(k));
            else
                prob = prob * 2 * ((1 - pc0_c1(k)) * pc1_a1(k) +
pc0_c1(k) * (1 - pc1_a1(k)));
            end
        end

        temp_p = temp_p + i/len*prob;
    end

    % 将 temp_p 加到结果里
    result = result + temp_p;
end

result = 1 - result;
end

```

主程序:

```
nC = 64;
```

```

nA = 21;
mistranscriptionRat = 1e-6;
mistranslationRat = 1e-4;
corttranscriptionRat = 1 - mistranscriptionRat;
corttranslationRat = 1 - mistranslationRat;

% 创建一个氨基酸到密码子的映射结构
aminoacidCodonMap = containers.Map;
aminoacidCodonMap('1') = {'UUU', 'UUC'};
aminoacidCodonMap('2') = {'UUA', 'UUG', 'CUU', 'CUC', 'CUA', 'CUG'};
aminoacidCodonMap('3') = {'AUU', 'AUC', 'AUA'};
aminoacidCodonMap('4') = {'AUG'};
aminoacidCodonMap('5') = {'GUU', 'GUC', 'GUA', 'GUG'};
aminoacidCodonMap('6') = {'UCU', 'UCC', 'UCA', 'UCG', 'AGA', 'AGG'};
aminoacidCodonMap('7') = {'CCU', 'CCC', 'CCA', 'CCG'};
aminoacidCodonMap('8') = {'ACU', 'ACC', 'ACA', 'ACG'};
aminoacidCodonMap('9') = {'GCU', 'GCC', 'GCA', 'GCG'};
aminoacidCodonMap('10') = {'UAU', 'UAC'};
aminoacidCodonMap('11') = {'CAU', 'CAC'};
aminoacidCodonMap('12') = {'CAA', 'CAG'};
aminoacidCodonMap('13') = {'AAU', 'AAC'};
aminoacidCodonMap('14') = {'AAA', 'AAG'};
aminoacidCodonMap('15') = {'GAU', 'GAC'};
aminoacidCodonMap('16') = {'GAA', 'GAG'};
aminoacidCodonMap('17') = {'UGU', 'UGC'};
aminoacidCodonMap('18') = {'UGG'};
aminoacidCodonMap('19') = {'CGU', 'CGC', 'CGA', 'CGG', 'AGA', 'AGG'};
aminoacidCodonMap('20') = {'GGU', 'GGC', 'GGA', 'GGG'};
aminoacidCodonMap('21') = {'UGA', 'UAA', 'UAG'};
aminoacidKeys = keys(aminoacidCodonMap);

% 创建三个转移矩阵
Pa0_c0 = zeros(nA,nC);
for i = 1:numel(aminoacidKeys)
    aminoacidKey = aminoacidKeys{i};

```

```

aminoacidString = num2str(aminoacidKey); % 将整数键转换为字符串
codons = aminoacidCodonMap(aminoacidString);

for j = 1:numel(codons)
    codon = codons{j};
    codonIndex = mapCodonToNumber(codon);
    Pa0_c0(str2double(aminoacidKey), codonIndex) = 1;
end
end

Pc0_c1 = mistranscriptionRat * ones(nC);
Pc0_c1(1:nC+1:end) = corttranscriptionRat;

Pc1_a1 = transpose(Pa0_c0);
Pc1_a1(Pc1_a1 == 1) = corttranslationRat;
Pc1_a1(Pc1_a1 == 0) = mistranslationRat;

N_values = 1:15; % N 的取值范围，可以根据需要调整
num_sequences = 10; % 每个 N 生成的随机序列数量
SER_1_avg_values = zeros(size(N_values));
SER_2_avg_values = zeros(size(N_values));

for i = 1:length(N_values)
    N = N_values(i);
    SER_1_sum = 0;
    SER_2_sum = 0;

    for j = 1:num_sequences
        CodonSequence = generateRandomCodonSequence(N);
        SER_1_sum = SER_1_sum + SER_1(CodonSequence, Pa0_c0, Pc0_c1,
Pc0_c1);
        SER_2_sum = SER_2_sum + SER_2(CodonSequence, Pa0_c0, Pc0_c1,
Pc0_c1);
    end
end

```

```


SER_1_avg_values(i) = SER_1_sum / num_sequences;
SER_2_avg_values(i) = SER_2_sum / num_sequences;
end

% 绘制曲线图
figure;
plot(N_values, SER_1_avg_values, 'r', 'LineWidth', 2); % SER_1 平均值曲线
hold on;
plot(N_values, SER_2_avg_values, 'b', 'LineWidth', 2); % SER_2 平均值曲线
xlabel('N'); % x 轴标签
ylabel('Average SER'); % y 轴标签
title('Average SER vs. N'); % 图表标题
legend('SER_1', 'SER_2'); % 图例
grid on; % 显示网格
hold off;

```

输出结果：

（生物编码的错码率为 SER_2 ，密码子与氨基酸一一对应时编码的错码率为 SER_1 ）



可以直观地看到，随着基因长度的增加，具有多重编码的 SER_1 的错配率一路降低，且与一一对应编码的错码率差距不断拉大。

可见，如果将多个密码子与一个氨基酸之间的对应关系看作是多重编码这一纠错编码方法的话，这样的编码方式有助于 DNA 在遗传过程中降低 *SER*，保持强大稳定性，更好地承载基因信息。

5.3 DNA 能提供的最大信息量

问题：

信息论中常用熵来定量描述一则信息能消除的不确定性。在父代和子代之间，遗传信息是否也有类似的效果？请结合文献，选取合适的参量，从一对等位基因开始，描述一段 DNA 最大能提供的信息量。

解答：

由上文中 4.3.1.2 有性生殖中的数学建模一节中的分析可知，对于特定繁殖过程中确定的亲代和子代，无论分析一对等位基因还是分析全部基因型构成，亲代中雄性个体与雌性个体为其子代提供的最大信息熵均为：

$$H(X) = - \sum_{i=1}^3 p(x_i) \log p(x_i) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 1$$

5.4 环境变化对物种繁衍的影响

问题：

每个物种都有一个基因库，包含了本物种所有个体的遗传信息。每个个体的 DNA 都是这个基因库的子集。分隔两地的种群之间的交互也与现代社会远距离通信有相似之处。试据此定性分析环境变化对物种稳定繁衍的影响。

解答：

每个物种均有其基因库，地理环境等因素将同一个物种区隔成很多不同的种群，地理隔离和不同的环境使每个种群有其独特的基因库，而同一个物种所有种群的基因库由作为子集构成了该物种基因库的全集。

当两个种群产生地理隔离后，种群在各自的环境中会发生包括基因突变、选择在内的一系列变化，导致各自的基因库发生定向变化。例如，在多风的小岛上能飞行的昆虫更易被吹入海中丧生¹¹，故昆虫多为残翅或无翅，残翅或无翅基因型在其基因库中占比明显增加。而这种变化也直接导致了种群与种群间基因

¹¹ Charles Robert Darwin: *On the Origin of Species by Means of Natural Selection, or the Preservation of Favoured Races in the Struggle for Life*, 1859

库的相异，也相应导致了物种总基因库的变化。在上例中，这种变化主要体现在两方面：

1. 已有基因型频率的变化：残翅基因型占比的提高与长翅基因型占比的降低；

2. 新基因的增加：无翅基因型的出现和比例的增加；

理清了地理隔离和环境变化对物种基因库的改变作用后，下面讨论环境变化对物种稳定繁衍的影响，提出猜想与其证明如下。

猜想：

环境变化对物种稳定繁衍有促进作用。

证明：

在本问题中，环境变化主要指环境的突变造成处于环境中的群落基因库适应环境发生定向改变，并增加新的基因的过程。

而物种稳定繁衍则是指这一物种在生物圈整体环境变化时，能够保证物种存续的能力。这一能力的衡量标准是物种在不同环境中的适应能力，与基因型多样化紧密相关。

又因为基因型信息熵越小，群体越有序，基因型越一致；信息熵越大，群体越无序，基因型越多样化。¹²因此，只需要证明同一个物种在地理隔离下不同群落基因库的定向改变会使整个物种基因型更加多样化，即物种整体信息熵增加，就能证明环境变化对物种稳定繁衍有促进作用。

在本文第 4.3.2 小节关于不平衡群体基因库信息熵的讨论中，给出了关于群体基因库信息量的定量描述方法。对于一个物种而言，若将其视为一个群体，则其物种基因库本身构成一个不平衡群体基因库，其中包含本物种全部基因信息。该基因库基因型及其信息熵的计算方法如下：

$$A_1A_1, A_2A_2, \dots, A_KA_K, A_1A_3, A_1A_2, \dots, A_{K-1}A_K = D_1D_2, \dots, D_K, H_{12}H_{13}, \dots, H_{K-1}K$$

$$H_j(G) = -\sum_{i=1}^K D_i \log D_i \quad H_h(G) = -\sum_{i < j} H_{ij} \log H_{ij}$$

$$H(G) = -\left(\sum_{i=1}^K D_i \log D_i + \sum_{i < j} H_{ij} \log H_{ij}\right)$$

使用 MATLAB 进行仿真实验，随机初始化一个复等位基因的基因型序列，序列内容为该复等位基因组成的每个基因型的基因频率，满足每个基因型频率的总和为 1。然后为该复等位基因的遗传设置两个环境，一个稳定环境中每代每个基因型的遗传概率不同，另一个多变环境中每代每个基因型的遗传概率不同，

¹² 汪小龙, 袁志发, 郭满才, 宋世德, 张全启, 包振民. 最大信息熵原理与群体遗传平衡[J]. 遗传学报, 2002, (06): 562-564.

以表示环境的选择作用。然后计算 N 代以后两个环境中物种基因型的信息熵，并使用图示的方法作出 N 与两个环境下基因信息熵的折线图。

代码实现如下：

函数：

```
function genotypeFrequencies = variableEnvironment(genotypeFrequencies,
selectionCoefficients)
    noise = 1e-5 * rand(1, length(selectionCoefficients));
    genotypeFrequencies = genotypeFrequencies .* (selectionCoefficients
+ noise);
    genotypeFrequencies = genotypeFrequencies /
sum(genotypeFrequencies);
end
function genotypeFrequencies = stableEnvironment(genotypeFrequencies,
selectionCoefficients)
    genotypeFrequencies = genotypeFrequencies .* selectionCoefficients;
    genotypeFrequencies = genotypeFrequencies /
sum(genotypeFrequencies);
end
function genotypeFrequencies = initializeGenotypeFrequencies(n)
    genotypeFrequencies = rand(1, n);
    genotypeFrequencies = genotypeFrequencies /
sum(genotypeFrequencies);
end
function selectionCoefficients = generateRandomSelectionCoefficients(n)
    selectionCoefficients = 1e-10 * rand(1, n);
end
```

主程序：

```
n = 20; % 基因型数量
N = 100; % 仿真的代数
stablegenotypeFrequencies = initializeGenotypeFrequencies(n);
variablenameotypeFrequencies = initializeGenotypeFrequencies(n);
selectionCoefficients = generateRandomSelectionCoefficients(n);
% 初始化遗传选择系数
selectionCoefficientsStable = selectionCoefficients;
selectionCoefficientsVariable = selectionCoefficients;
```



```

% 存储信息熵的数组
entropyStable = zeros(1, N);
entropyVariable = zeros(1, N);


% 仿真循环
for generation = 1:N
    stablegenotypeFrequencies =
stableEnvironment(stablegenotypeFrequencies, selectionCoefficientsStable);
    entropyStable(generation) = -sum(stablegenotypeFrequencies .*
log2(stablegenotypeFrequencies));

    variablegenotypeFrequencies =
variableEnvironment(variablegenotypeFrequencies,
selectionCoefficientsVariable);
    entropyVariable(generation) = -sum(variablegenotypeFrequencies .*
log2(variablegenotypeFrequencies));
end

% 绘制折线图
generation = 1:N;
plot(generation, entropyStable, 'r-', generation, entropyVariable, 'b-
');
xlabel('代数');
ylabel('基因信息熵');
legend('稳定环境', '多变环境');
title('基因信息熵随代数变化趋势图');

```

运行结果：



由此可以看出，同一物种相同代数中，环境变化越稳定，物种总基因库信息熵越小，物种基因库基因信息熵越小越高，相应保持稳定繁衍的能力越弱。环境变化越剧烈，物种总基因库信息熵越大，物种基因库基因多样性越高，物种越能适应环境而存续，在对环境的适应中保持物种的繁衍存续。

综上，环境变化对物种稳定繁衍有促进作用。

5.5 保护濒危物种的措施

问题：

一个物种个体数量下降到一定程度后就会加速消亡。这可以理解为由于遗传信息的减少，生物与环境之间的交互能力急剧下降，逐渐无法应对生存环境中出现的种种变化。为挽救濒危物种，人们采取了哪些措施？试用信息论的观点加以分析。

解答：

解决濒危物种的繁殖和遗传问题一直是挽救濒危物种工作的重点工作。为了延缓濒危动物的灭绝速度，人们采取了包括建立野生动物保护区、人工育种在内的多种措施以保证濒危物种的繁殖与其基因库的延续。

对于数量较少的濒危动物而言，增加该物种的数量并增强该物种对新环境的适应能力是评价措施有效性的两个重点维度。下面尝试从遗传信息的角度分析建立野生动物保护区对特定物种数量与其对新环境适应能力的影响。提出假设和证明如下：

假设：

对于濒危动物，建立野生动物保护区能够增加其物种数量，并提升其对新环境的适应能力。

论证：

在本文第 4.3.2 小节关于不平衡群体基因库信息熵的讨论中，给出了复等位基因的表示方法。利用该方法设某总量为 N 的濒危动物基因库中复等位基因型与该基因型频数为：

$$A_1A_1, A_2A_2, \dots, A_KA_K, A_1A_3, A_1A_2, \dots, A_{K-1}A_K = D_1D_2, \dots, D_K, H_{12}H_{13}, \dots, H_{K-1K}$$

$$\sum_{i=1}^K D_i + \sum_{i<j} H_{ij} = N$$

则其基因信息熵可表示为：

$$H_j(G) = -\sum_{i=1}^K \frac{D_i}{N} \log \frac{D_i}{N} \quad H_h(G) = -\sum_{i<j} \frac{H_{ij}}{N} \log \frac{H_{ij}}{N}$$

$$H(G) = -\left(\sum_{i=1}^K \frac{D_i}{N} \log \frac{D_i}{N} + \sum_{i<j} \frac{H_{ij}}{N} \log \frac{H_{ij}}{N}\right)$$

对于物种数量的表示，可以较为地直观统计每代 N_i 的数量。

野生动物保护区对动物繁殖的帮助作用较大，本处仅考虑基因对环境的适应性。环境对生物的选择性主要体现在，在特定的环境中，拥有适应环境的性状的个体会更好地生存繁殖，而不适应环境的个体会有更大的概率死亡，同时处于生存劣势，繁殖行为也相应降低。而对于濒危动物，其原本的生存环境下，大部分基因型的个体死亡率与繁殖率都很低，也很难在几代之内适应，故物种数量减少。而保护区中环境与物种较为适应，大部分基因型的个体死亡率与繁殖率相较原先有所改善，故群体总数应当呈上升趋势。

使用 MATLAB 进行仿真实验，对一个个体总数为 N 的物种，某复等位基因数为 n ，先初始化一个基因库中基因型的频数表（频数必须为整数且频数之和等于该群体总数 N ），然后分别测试该物种基因库在保护区环境和普通环境中群体数量和基因型频率的信息熵随繁殖代数 G 的变化趋势。

测试方法为：普通环境中，随机生成一个长为 n 的死亡概率和繁殖概率表，每一代死亡概率较大 ($\geq 20\%$) 且繁殖概率较小 ($\leq 20\%$)，保护区环境中，随机生成一个长为 n 的死亡概率和繁殖概率表，每一代死亡概率较小 ($\leq 10\%$) 且繁殖概率较大 ($\geq 80\%$)。然后使用对两种环境生成的概率表对基因型频数表进行操作，基因型频数表对应位增加繁殖几率 $\times$ 频数的个体数量，并减少死亡频率 $\times$ 频数的数量。

代码实现如下：

函数：

```

function entropy = calculateEntropy(frequencies)
    normalized_freq = frequencies / sum(frequencies);
    entropy = -sum(normalized_freq .* log2(normalized_freq));
end

function probabilities = generateProbabilities(n, environment)
    probabilities = zeros(2, n);

    if strcmp(environment, 'normal')
        probabilities(1, :) = 0.2 + 0.8 * rand(1, n); % 死亡概率较大
        (≥20%)
        probabilities(2, :) = 0.2*rand(1,n); % 繁殖概率较小(≤20%)
    elseif strcmp(environment, 'protected')
        probabilities(1, :) = 0.1 * rand(1, n); % 死亡概率较小(≤10%)
        probabilities(2, :) = 0.8 + 0.2 *rand(1,n); % 繁殖概率较大
        (≥80%)
    end
end

function frequencies = generateGenotypeFrequencies(n, N)
    % 生成 n 个随机数
    random_values = rand(1, n);
    % 归一化处理
    normalized_values = random_values / sum(random_values);
    % 得到频数
    frequencies = round(normalized_values * N);
    frequencies(end) = N - sum(frequencies(1:end-1));
    % 随机打乱频数表的顺序
    frequencies = frequencies(randperm(n));
end

function updated_frequencies =
updateGenotypeFrequencies(probabilities, frequencies)
    n = length(probabilities);
    updated_frequencies = zeros(1,n);
    for i = 1:n
        updated_frequencies(i) = frequencies(i) +
        floor(frequencies(i) * (probabilities(2, i) - probabilities(1, i)));
    end
end

```

```
end
```

```
end
```

主程序：

```
N = 1000; % 初始种群大小
n = 10;   % 基因型数量
G = 10;   % 仿真代数

% 初始化基因型频率
initial_frequencies_protected = generateGenotypeFrequencies(n, N);
initial_frequencies_normal = initial_frequencies_protected;

% 初始化环境概率表
probabilities_protected = generateProbabilities(n, 'protected');
probabilities_normal = generateProbabilities(n, 'normal');

% 创建数组存储每一代的结果
population_history_protected = zeros(G, 1);
entropy_history_protected = zeros(G, 1);
population_history_normal = zeros(G, 1);
entropy_history_normal = zeros(G, 1);

for generation = 1:G
    initial_frequencies_normal =
updateGenotypeFrequencies(probabilities_normal,
initial_frequencies_normal);
    population_history_normal(generation) =
sum(initial_frequencies_normal);
    entropy_history_normal(generation) =
calculateEntropy(initial_frequencies_normal);

    initial_frequencies_protected =
updateGenotypeFrequencies(probabilities_protected,
initial_frequencies_protected);
    population_history_protected(generation) =
sum(initial_frequencies_protected);
```

```

        entropy_history_protected(generation) =
calculateEntropy(initial_frequencies_protected);

end


generation_numbers = 1:G;

figure;
subplot(2, 1, 1);
plot(generation_numbers, population_history_protected, 'b',
generation_numbers, population_history_normal, 'r');
xlabel('代数');
ylabel('群体大小');
legend('保护区环境', '普通环境');

subplot(2, 1, 2);
plot(generation_numbers, entropy_history_protected, 'b',
generation_numbers, entropy_history_normal, 'r');
xlabel('代数');
ylabel('信息熵');
legend('保护区环境', '普通环境');

```

运行结果:



由仿真结果可以看出，保护区中随着代数的增加，濒危物种的数量不断上升，而普通环境中濒危物种的数量不断减少，且相较普通环境而言，保护区环境能更好地保持每种基因型的延续，而普通环境中抗逆性强的基因型会被快速筛选出来，导致基因型的偏好性普通环境大于保护区环境，最终造成普通环境

相较保护区环境基因库中基因型的信息熵较低，也意味着普通环境中的濒危物种将对新环境的适应能力更差。

综上，无论从物种数量还是物种对新环境的适应能力角度考量，保护区都能有效保护濒危物种，故建立野生动物保护区能够增加其物种数量，并提升其对新环境的适应能力。