

## A2.4 在分类问题中，最小化交叉熵损失等价于最大化似然的推导

在机器学习的分类问题中，最小化交叉熵损失等价于极大化似然。下边给出这一结论的证明。

设数据集 $\{(x_i, y_i)\}_{i=1}^N$ ，其中：

- $x_i$ ：输入特征向量
- $y_i$ ：目标输出（类别标签）， $y_i \in \{1, 2, \dots, N\}$ ， $N$ 为类别数量

设模型的预测函数为 $f(x_i; \theta)$ ，其中 $\theta$ 为模型参数。对于多分类问题，我们通常使用**Softmax**函数将模型的输出转换为各类别的概率分布。对于输入 $x_i$ ，模型的输出为一个实数向量 $\mathbf{z}_i = [z_{i1}, z_{i2}, \dots, z_{iN}]^\top$ 。令 $p_{iN}$ 表示样本 $x_i$ 被预测为第 $N$ 类的概率。通过Softmax函数，将其转换为概率分布：

$$p_{iN} = \frac{\exp(z_{iN})}{\sum_{j=1}^N \exp(z_{ij})}$$

### 一、似然函数

对于单个样本 $x_i$ ，其真实类别为 $y_i$ ，则其条件概率为：

$$p(y_i | x_i; \theta) = p_{iy_i} = \frac{\exp(z_{iy_i})}{\sum_{j=1}^N \exp(z_{ij})}$$

由于各个样本是独立的，整个数据集的似然函数为：

$$\begin{aligned} L(\theta) &= \prod_{i=1}^N p(y_i | x_i; \theta) = \prod_{i=1}^N \frac{\exp(z_{iy_i})}{\sum_{j=1}^N \exp(z_{ij})} \\ -\ln L(\theta) &= -\sum_{i=1}^N \ln p(y_i | x_i; \theta) = -\sum_{i=1}^N \ln \left( \frac{\exp(z_{iy_i})}{\sum_{j=1}^N \exp(z_{ij})} \right) \\ -\ln L(\theta) &= -\sum_{i=1}^N \left( \ln \exp(z_{iy_i}) - \ln \sum_{j=1}^N \exp(z_{ij}) \right) = -\sum_{i=1}^N \left( z_{iy_i} - \ln \sum_{j=1}^N \exp(z_{ij}) \right) \end{aligned}$$

### 二、交叉熵损失函数

对于分类问题，交叉熵损失函数定义为：

$$\text{CrossEntropy}(\theta) = -\sum_{i=1}^N \sum_{N=1}^N y_{iN} \ln p_{iN}$$

其中,  $y_{iN}$  是样本  $x_i$  的真实标签的 one-hot 编码, 若  $y_i = N$ , 则  $y_{iN} = 1$ , 否则  $y_{iN} = 0$ 。

将  $p_{iN}$  代入, 可以得到:

$$\text{CrossEntropy}(\theta) = - \sum_{i=1}^N \ln p_{iy_i} = - \sum_{i=1}^N \left( z_{iy_i} - \ln \sum_{j=1}^N \exp(z_{ij}) \right)$$

可以看出, 表达式形式与负对数似然函数形式完全一致, 可以认为两者等价。

综上所述, **在分类问题中, 最小化交叉熵损失等价于极大化似然。**