

Aligner: Achieving Efficient Alignment through Weak-to-Strong Correction

Aligner: Achieving Efficient Alignment through Weak-to-Strong Correction

发表时间：2024.2.6

我希望通过这篇论文了解的信息/解决的问题是什么

- 寻找能够增强大语言模型在对话系统中安全性的方法；
- 寻找大语言模型安全性的评价方法；
- 收集安全问题相关的中文数据集；

本论文要解决的问题是什么：

如何减少各种语言大模型（黑箱与白箱模型）生成不安全内容的可能并增强大模型的能力？

现有方法/内容与局限性：

内容	时间	做法（简述）	优势	局限性	参考文献
RLHF方法	2017	提出了一种根据人类评价优化agent能力的有监督强化学习方法。可以在不定义传统奖励函数的情况下将人类的意图更加有效地传递给agent。	1. 这种方法可以在不定义奖励函数的情况下有效地解决复杂的RL任务。 2. 大大降低了人工监督的成本，使其可以实际应用于最先进的RL系统。	1. 算力消耗在agent参数规模大时明显较大。 2. 需要代表及的数据集供agent学习。	Christiano, P. F., Leike, J., Brown, T., Martic, M., Legg, S., and Amodei, D. Deep reinforcement learning from human preferences. Advances in neural information

					processing systems, 30, 2017.
使用 RLHF 微调大模型	2022/2/15	训练方式： 1. 收集了大量人类比较摘要的数据集，用于训练模型来预测人类首选的摘要。 2. 训练了一个模型来预测人类偏好的摘要，即给定两个摘要，预测哪一个更受人类喜欢。 3. 将上一步训练得到的模型作为奖励函数，利用强化学习对摘要生成模型进行微调，使其生成的摘要更符合人类偏好。 4. 对微调后的摘要生成模型进行评估，比较其生成的摘要与人类参考摘要以及其他模型生成的摘要的质量。	1. 实现了对摘要生成模型的优化，使其生成的摘要质量显著提高，超过了使用传统评价指标（如 ROUGE）进行训练和评估的模型。 2. 表明了 RLHF 在大语言模型优化任务上的有效性 3. 提供了一种可用的优化大模型的有效方法	1. 需要广泛的数据集才能完成任务 2. 算力消耗巨大 3. 数据集不公开	Learning to summarize from human feedback Training language models to follow instructions with human feedback. Easy, fast and affordable rlhf training of chatgpt-like models at all scales
使用 RLHF 微调大模型这一方法的效果	2023/12	文中提出的问题与局限性包括： 分类一： 1. 人类反馈的挑战 2. 奖励模型的挑战 3. 政策的挑战 分类二： 1. RLHF框架内能解决的 2. 框架内难以解决的 讨论的问题： 1. 使用 RLHF 训练 AI 系统的公司披露某些细节如何改善问责制和审计（没啥用）	1. 非常全面地索引了RFHL方法在大模型应用中的问题以及解决方法，很全面的一篇关于RFHL在LLM中应用的综述类文章；	1. 无	Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback

		具体问题： 1. 使用 RLHF 微调的部署模型还是揭示了敏感的私人信息 2. 幻觉和不真实内容无法得到改善 3. 政治意识形态偏见等 4. 奇怪的意识（不想被关闭等） 5. 很容易被新示例影响 			
RLHF 方法对开放 API 的大模型无用	2024/5/4	报告了 GPT-4 的开发方法，测评了 GPT-4 在各种专业和学术基准上表现出人类水平的表现，	1. GPT-4大模型的完整能力报告	1. 对大模型安全问题帮助其实不大 2. RLHF方法对开放API的大模型无用	arXiv:2303.08774 [cs.CL]
使用大模型优化数据集质量以更好地训练大模型	2022	用于训练大模型的数据集往往存在错误或低质量的数据内容，利用现有模型的预测一致性对这些数据集进行降噪，以增强这些数据集的质量，以进一步优化大模型的能力。	1. 提高了GEC数据集的效果 2. 在我们的任务上可能有助于优化数据集的质量，完成数据清洗工作	1. 无	Mita et al., 2020 A self-refinement strategy for noise reduction in grammatical error correction. ;
使用大模型迭代地更新读入的文本（主动修改而非被动阅读）对大模型能力有增强作用	2022	编辑过程是指对文档或内容进行逐步修改和调整的过程。在这个过程中，可能涉及插入、替换、保留或删除文本等编辑操作，以使文档更加清晰、准确或符合特定要求。本文提出了对编辑过程进行建模的方法，对大模型迭代生成序列的整个过程进行建模。建立了一个概念框架来描述多步编辑的可能性，并描述了可以基于这	1. 与传统单步编辑模型不同，该方法考虑了多步编辑过程，更全面地捕捉了文档逐步修改的情况，提高了生成文本的准确性和连贯性。	1. 标注数据要求好像比较复杂，没太看懂	Reid & Neubig, 2022 Learning to model editing processes.

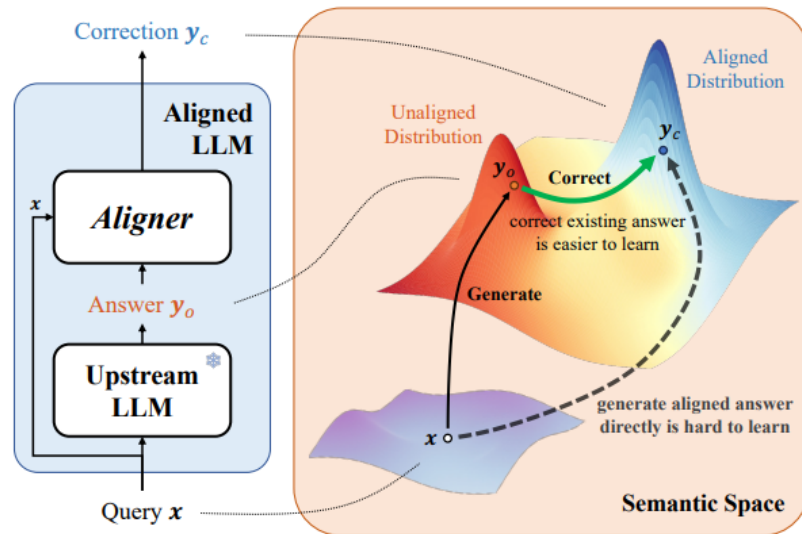
		些多步编辑学习序列生成模型的神经模型。	2. 基于编辑过程的模型在序列生成任务上表现出更好的性能，相比于单步编辑模型，在相关下游任务上取得了更好的效果。		
小型语言模型通过重写大语言模型的输出来改进大语言模型的能力	2024.2.1	通过少量提示从 LLM 中创建了一个候选者池，并采用了一个紧凑的模型，即 LMcorrector（LMCOR），经过专门训练以合并这些候选者以产生增强的输出。	1. 直接针对 LLM 的输出进行改进而无需访问LLM的权重。 2. 同一个小模型对不同的大模型有迁移性 3. 显著降低了训练成本202	1. 无	Vernikos et al., Small language models improve giants by rewriting their outputs .2023
通过让红小模型批判大模型的答案来增强大模型的能力	2023/10/14	实验表明，通过对强大的预训练模型使用由较弱模型生成的标签进行微调，这些强模型能够一致地超越原有水平，即"弱到强泛化"。	1. 不需要人类监督，小模型能够自主监督大模型的行为 2. 提出了弱到强泛化的思想	1. 小模型怎么训练和调整能更好地监督大模型需要研究。	WEAK-TO-STRONG GENERALIZATION: ELICITING STRONG CAPABILITIES WITH WEAK SUPERVISION

(根据所需自行添加评价维度)

本文提出的方法/给出的内容：

本文方法的具体做法/本文内容的产生方法：


基本原理：



训练一个较小的语言模型，该模型能将上游大模型中的初始答案重写为更有用且无害的答案。在不更改大模型参数的情况下改变组合模型的回答质量的前提下，只更改回答以完成优化。上图展现了语义空间中Aligner的作用。

Aligner的作用：

Aligner的作用类似于LLM 在架构和能力方面的残差修正器。Aligner首先从上游的语言模型（LLM）获取初始输出，然后通过 Aligner 应用自回归功能来生成修正后的版本，Aligner 采用了“复制和更正”的方法，在保持基本结构不变的情况下，将改进叠加到原始答案上。详细过程如图所示：



训练方法：

Aligner实际上学习的是大模型输出与期望输出之前的残差，也就是说，Aligner的训练方式主要是通过残差校正策略进行的。在这种策略下，Aligner利用问题-答案-校正（Q-A-A）数据集中答案和校正之间的语义残差进行训练。具体训练步骤为：

- a. 数据集构建：首先构建一个Q-A-A数据集，其中包含用户的查询问题 x ，原始答案 y_o 以及根据既定原则进行校正的答案 y_c 。这个数据集将用于训练Aligner模型。

$$\mathcal{M} = \{x^{(i)}, y_o^{(i)}, y_c^{(i)}\}_{i=1}^N$$

- b. 模型训练：使用构建好的数据集 $\mathcal{M}$ 进行模型训练。在训练过程中，Aligner模型

$$\mu_{\phi}(y_c|y_o, x)$$

会被参数化为 θ ，以将初始答案 y_o 重新分配为对齐的答案 y_c 。具体来说，根据上游LLM π_{θ} 生成对齐答案的过程为：


$$\pi'(y_c|x) = \mu_{\phi}(y_c|y_o, x)\pi_{\theta}(y_o|x).$$

损失函数被设计为根据数据集 $\mathcal{M}$ 计算的期望值损失。损失函数的计算公式为：

$$\underset{\phi}{\text{minimize}} \mathcal{L}_{\text{Aligner}}(\phi, \mathcal{M}) = -\mathbb{E}_{\mathcal{M}} [\log \mu_{\phi}(y_c|y_o, x)].$$

本文方法的实验效果：

- i. 资源消耗：对于 7B 源模型，DPO 需要的资源是 Aligner 的 1.66 倍，RLHF 需要 5.71 倍的资源。此外，随着源模型规模的扩大，其他方法的资源需求急剧上升：对于70B模型，DPO需要的资源是Aligner的16.67倍，RLHF需要30.7倍的资源。但是，由于 Aligner 对这些变化不敏感，因此无论源模型的规模如何，其训练资源需求都保持不变。
- ii. 在可解释性方面，基于seq2seq模型的Aligner超越了其他方法。这种优势源于文本空间固有的可泛化性。调整训练数据集的分布可以使 Aligner 的行为符合我们的期望。然而，RLHF 的训练过程将文本转换为标量奖励，缺乏泛化性，从而减少了序列中存储的信息，缺乏可解释性
- iii. 对各个大模型的提升效果：



Aligner	LLM		BeaverTails		HarmfulQA		Average	
			Helpfulness	Harmlessness	Helpfulness	Harmlessness	Helpfulness	Harmlessness
7B	GPT-4	🔒🛡️	+18.6%	+25.8%	+16.3%	+28.0%	+17.5%	+26.9%
	GPT-3.5	🔒🛡️	+9.3%	+9.3%	+8.4%	+7.0%	+8.9%	+8.1%
	Claude 2	🔒🛡️	+58.4%	+30.3%	+69.4%	+42.1%	+63.9%	+36.2%
	Beaver-v1	🛡️	+21.9%	+12.0%	+8.9%	+6.0%	+15.4%	+9.0%
	Llama2-7B-Chat	🛡️	+19.9%	+7.4%	-5.7%	+22.1%	+7.1%	+14.8%
	Llama2-13B-Chat	🛡️	+20.1%	+10.3%	+15.5%	+28.6%	+17.8%	+19.4%
	Llama2-70B-Chat	🛡️	+5.2%	+2.4%	-6.6%	+4.1%	-0.7%	+3.3%
	Alpaca-7B		+34.9%	+47.0%	+38.2%	+70.7%	+36.5%	+58.9%
	Vicuna-7B		+26.4%	+15.9%	+12.0%	+29.3%	+19.2%	+22.6%
	Vicuna-13B		+37.6%	+16.6%	+21.9%	+18.9%	+29.8%	+17.7%
	Vicuna-33B		+51.0%	+55.9%	-1.0%	+33.6%	+25.0%	+44.7%
13B	GPT-4	🔒🛡️	+33.9%	+25.1%	+25.1%	+20.1%	+29.5%	+22.6%
	GPT-3.5	🔒🛡️	+15.1%	+10.9%	+7.6%	+7.7%	+11.3%	+9.3%
	Claude 2	🔒🛡️	+50.0%	+30.0%	+45.9%	+28.6%	+48.0%	+29.3%
	Beaver-v1	🛡️	+14.2%	+19.1%	+8.0%	+11.6%	+11.1%	+15.3%
	Llama2-7B-Chat	🛡️	+13.5%	+4.6%	+12.6%	+32.3%	+13.1%	+18.4%
	Llama2-13B-Chat	🛡️	+16.7%	+10.6%	+30.7%	+35.0%	+23.7%	+22.8%
	Llama2-70B-Chat	🛡️	+10.6%	+1.9%	+6.3%	+7.6%	+8.5%	+4.7%
	Alpaca-7B		+8.5%	+53.4%	+3.4%	+75.9%	+6.0%	+64.6%
	Vicuna-7B		+19.1%	+24.0%	+19.5%	+31.0%	+19.3%	+27.5%
	Vicuna-13B		+31.8%	+26.7%	+30.9%	+18.9%	+31.3%	+22.8%
	Vicuna-33B		+33.3%	+63.3%	+7.3%	+33.3%	+20.3%	+48.3%
70B	GPT-4	🔒🛡️	+26.2%	+29.3%	+17.1%	+31.7%	+21.7%	+30.5%
	GPT-3.5	🔒🛡️	+16.4%	+8.9%	+25.2%	+10.6%	+20.8%	+9.7%
	Claude 2	🔒🛡️	+50.0%	+29.4%	+62.9%	+39.7%	+56.4%	+34.6%
	Beaver-v1	🛡️	+22.2%	+11.7%	+20.0%	+7.9%	+21.1%	+9.8%
	Llama2-7B-Chat	🛡️	+29.1%	+6.4%	+19.0%	+25.6%	+24.0%	+16.0%
	Llama2-13B-Chat	🛡️	+34.1%	+9.3%	+41.2%	+29.0%	+37.7%	+19.1%
	Llama2-70B-Chat	🛡️	+23.1%	+1.9%	+17.0%	+6.9%	+20.1%	+4.4%
	Alpaca-7B		+38.5%	+47.1%	+39.7%	+69.6%	+39.1%	+58.4%
	Vicuna-7B		+39.9%	+15.4%	+25.6%	+29.7%	+32.7%	+22.6%
	Vicuna-13B		+49.4%	+16.5%	+19.4%	+19.1%	+34.4%	+17.8%
	Vicuna-33B		+56.8%	+57.6%	+5.0%	+33.3%	+30.9%	+45.5%

(更多内容请见原始文献，这里整理不下)

本文方法/内容的优势与旧方法/内容的对比：

传统的训练方法中，无论是RLHF，还是SFT，都是直接微调大模型的参数，以完成性能的提升，这意味着需要更新的是庞大的参数，算力消耗巨大。

并且，对于只开放API接口的黑箱模型，无法调整参数，使得直接改变大模型的性能变得难以实现。

传统的安全方法容易使大模型的回答受限，这导致了大模型的能力下降，容易生成模板化低质量回答等问题。

与上述方法相比，本文提出的Aligner只需要将一个额外的模块堆叠到上游 LLM 上即可进行对齐。此外，计算资源需求完全取决于 Aligner 的预期功效，而不是上游 LLM 的参数大小，极其有效地降低了安全问题的解决成本。具体来说，优势包括：

- 训练矫正器不涉及任何 RLHF 过程。没有额外的模型，只训练一个自回归的 seq2seq 模型，通过监督学习在查询-答案校正数据集上进行训练，计算效率更高。
- Aligner 框架有助于从弱到强的泛化。利用来自小型 Aligner 模型的监控信号来微调强模型，可显著提高性能。
- Aligner 的即插即用特性和模型不可知性使其成为基于 API 的模型的理想选择，无需参数访问。训练完成后，Aligner 可以应用于不同的上游 LLM，而无需调整参数。可泛化性强。

本文相关内容在赛题中的可能应用与优势：

本文提出的Aligner能有效且可泛化地快速增强大模型的能力，而不需要大模型本身做出改变，可以考虑提供即插即用的Aligner api服务，提升他人大模型的能力。

白盾——一站式LLM安全服务

一、安全测评

1.最全面的中文测试方式

我们提供的安全测评服务包括攻击防御和安全测试。攻击防御包括六种不同攻击方式的真实中文数据，总量达十万级别。安全测评覆盖近三十个不同领域的大模型题库。我们从多个维度出发，全面模拟真实应用场景，提供最全面的中文测评基准。

2.最详尽的安全评估报告

我们给出的安全评估报告涵盖八种安全场景、六种指令攻击与三十种不同领域的数据分析与专业安全人员给出的详细安全评估，为您的大模型安全性能提供权威证明。

3.最便捷的服务接口

我们的服务允许用户自定义大模型接口方式，无论是上传原始LLM，或是使用api接口，都能使用我们的服务。为不同的用户提供最便捷的解决方案。

二、安全增强：

1.更加智能的安全增强

平庸的防御是阻拦，优秀的防御是提升。我们的安全服务守护于您的输出侧，在保留有效信息的同时，提升LLM输出文本的安全性能。让安全不再桎梏大模型的能力，转而提升大模型的质量。

2.即插即用的api式服务

不同于以往的大模型安全增强手段，我们提供即插即用的api服务。不需修改大模型本身，只需接受大模型输出，即可快速提升大模型安全性能。快速部署，显著提升。

3.提供针对指定大模型的定制化产品

我们不但提供通用的大模型安全增强服务，更能针对您手中大模型完成专项提升。在数据的迭代中，提供您的安全最优解。

*多方验证的安全效果

我们的服务已在ChatGPT系列，Claude系列、文心一言系列、通义千问系列等市面主流LLM验证，中文安全性能效果提升显著，详情请见「安全报告」。