

Conditional Random Fields

Yongmei Tan

ymtan@bupt.edu.cn

- 条件随机场（conditional random field, CRF）是给定一组输入随机变量条件下另一组输出随机变量的条件概率分布模型，其特点是假设输出随机变量构成马尔可夫随机场。
- 条件随机场可以用于不同的预测问题。
- 线性链（linear chain）条件随机场
 - 由输入序列对输出序列预测的判别模型
 - 形式为对数线性模型
 - 通常采用极大似然估计或正则化的极大似然估计的学习方法。
- 线性链条件随机场应用于标注问题(Lafferty, 2001)。

概率无向图模型

- 概率无向图模型（probabilistic undirected graphical model），即马尔可夫随机场（Markov random field），是一个可以由无向图表示的联合概率分布。
- 图（graph）是由结点（node）及连接结点的边（edge）组成的集合。结点和边分别记作 v 和 e ，结点和边的集合分别记作 V 和 E ，记作 $G=(V,E)$ 。
- 无向图是指边没有方向的图。

- 概率图模型（probabilistic graphical model）
 - 由图表示的概率分布。
 - 设有联合概率分布 $P(Y)$ ， $Y \in \mathcal{Y}$ 是一组随机变量。
 - 由无向图 $G=(V,E)$ 表示概率分布 $P(Y)$ ，在图 G 中，结点 $v \in V$ 表示一个随机变量 Y_v ， $Y = (Y_v)_{v \in V}$ ；边 $e \in E$ 表示随机变量之间的概率依赖关系。

- 给定一个联合概率分布 $P(Y)$ 和表示它的无向图 G 。
- 成对马尔可夫性pairwise Markov property)
 - 设 u 和 v 是无向图 G 中任意两个没有边连接的结点，结点 u 和 v 分别对应随机变量 Y_u 和 Y_v 。
 - 其他所有结点为 O ，对应的随机变量组是 Y_O 。
 - 成对马尔可夫性是指给定随机变量组 Y_O 的条件下随机变量 Y_u 和 Y_v 是条件独立的，即

$$P(Y_u, Y_v | Y_O) = P(Y_u | Y_O) P(Y_v | Y_O)$$

- 局部马尔可夫性 (local Markov property)
 - 设 $v \in V$ 是无向图 G 中任意一个结点
 - W 是与 v 有边连接的所有结点, O 是 v, W 以外的其他所有结点。
 - v 表示的随机变量是 Y_v , W 表示的随机变量组是 Y_W , O 表示的随机变量组是 Y_O 。
 - 局部马尔可夫性是指在给定随机变量组 Y_W 的条件下随机变量 Y_v 与随机变量组 Y_O 是独立的, 即

$$P(Y_v, Y_O | Y_W) = P(Y_v | Y_W) P(Y_O | Y_W)$$

– 在 $P(Y_O | Y_W) > 0$ 时

$$P(Y_v | Y_W) = P(Y_v | Y_W, Y_O)$$




图 11.1 局部马尔可夫性

- 全局马尔可夫性（global Markov property）
 - 设结点集合 A ， B 是在无向图 G 中被结点集合 C 分开的任意结点集合，如图11.2所示。
 - 结点集合 A ， B 和 C 所对应的随机变量组分别是 Y_A ， Y_B 和 Y_C 。
 - 给定随机变量组 Y_C 条件下随机变量组 Y_A 和 Y_B 是条件独立的。

$$P(Y_A, Y_B | Y_C) = P(Y_A | Y_C) P(Y_B | Y_C)$$

$$P(Y_A, Y_B | Y_C) = P(Y_A | Y_C) P(Y_B | Y_C)$$




图 11.2 全局马尔可夫性

- 概率无向图模型（probability undirected graphical model），或马尔可夫随机场（Markov random field）
 - 设有联合概率分布 $P(Y)$ ，由无向图 $G=(V,E)$ 表示
 - 在图 G 中，结点表示随机变量，边表示随机变量之间的依赖关系。
 - 联合概率分布 $P(Y)$ 满足成对、局部或全局马尔可夫性
- 将整体的联合概率写成若干子联合概率的乘积的形式（联合概率因子分解），便于模型的学习与计算。

概率无向图模型的因子分解

- 团 (clique) 与最大团 (maximal clique)
 - 无向图 G 中任何两个结点均有边连接的结点子集称为团。
 - 若 C 是无向图 G 的一个团，并且不能再加进任何一个的结点使其成为一个更大的团，则称此 C 为最大团




图 11.3 无向图的团和最大团

- 给定概率无向图模型，设其无向图为 G ， C 为 G 上的最大团， Y_C 表示 C 对应的随机变量。那么概率无向图模型的联合概率分布 $P(Y)$ 可写作图中所有最大团 C 上的函数 $\psi_C(Y_C)$ 的乘积形式

$$P(Y) = \frac{1}{Z} \prod_C \psi_C(Y_C)$$

$$Z = \sum_Y \prod_C \psi_C(Y_C)$$

$$\psi_C(Y_C) = \exp\{-E(Y_C)\}$$

Z 规范化因子保证 $P(Y)$ 构成一个概率分布。

函数 $\psi_C(Y_C)$ 称为势函数（potential function）。这里要求势函数是严格正的，通常定义为指数函数。

- Hammersley-Clifford 定理 概率无向图模型的联合概率分布 可以表示为如下形式:

$$P(Y) = \frac{1}{Z} \prod_C \psi_C(Y_C)$$

$$Z = \sum_Y \prod_C \psi_C(Y_C)$$

C 是无向图的最大团, Y_C 是 C 的结点对应的随机变量, $\psi_C(Y_C)$ 是 C 上定义的严格正函数, 乘积是在无向图所有的最大团上进行的。

条件随机场的定义和表示方法

- 条件随机场（conditional random field）

设 X 与 Y 是随机变量, $P(Y/X)$ 在给定 X 的条件下 Y 的条件概率分布。

若随机变量 Y 构成一个由无向图 $G=(V,E)$ 表示的马尔可夫随机场，即

$$P(Y_v | X, Y_w, w \neq v) = P(Y_v | X, Y_w, w \sim v)$$

对任意结点 v 成立，则称条件概率分布 $P(Y/X)$ 为条件随机场。

Y_v 和 Y_w 为结点 v ， u 与 w 对应的随机变量, $w \neq v$ 表结点 v 以外的所有结点， $w \sim v$ 表示在图 G 中与结点 v 有边连接的所有结点 w 。

考虑无向图为如图11.4与图11.5所示的线性链的情况。

$$G = (V = \{1, 2, \dots, n\}, E = \{(i, i+1)\}) \quad i = 1, 2, \dots, n-1$$

$$X = (X_1, X_2, \dots, X_n) \quad Y = (Y_1, Y_2, \dots, Y_n)$$




图 11.4 线性链条件随机场




图 11.5 X 和 Y 有相同的图结构的线性链条件随机场

最大团是相邻两个结点的集合。

- 线性链条件随机场（linear chain conditional random field）
 - 定义在线性链上的特殊的条件随机场。
 - 设 $X = (X_1, X_2, \dots, X_n)$ $Y = (Y_1, Y_2, \dots, Y_n)$ 均为线性链表示的随机变量序列，若在给定随机变量序列 X 的条件下，随机变量序列 Y 的条件概率分布 $P(Y/X)$ 构成条件随机场，即满足马尔可夫性

$$P(Y_i | X, Y_1, \dots, Y_{i-1}, Y_{i+1}, \dots, Y_n) = P(Y_i | X, Y_{i-1}, Y_{i+1})$$

（在 $i=1$ 和 n 时只考虑单边）

条件随机场的参数化形式

- 定理 线性链条件随机场的参数化形式

设 $P(Y/X)$ 为线性链条件随机场，则在随机变量 X 取值为 x 的条件下，随机变量 Y 取值为 y 的条件概率为

$$P(y | x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} u_l s_l(y_i, x, i) \right)$$

$$Z(x) = \sum_y \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} u_l s_l(y_i, x, i) \right)$$

t_k 和 s_l 是特征函数， λ_k 和 u_l 是对应的权值。 $Z(x)$ 是规范化因子，求和是在所有可能的输出序列上进行的。

- t_k 是定义在边上的特征函数，称为转移特征，依赖于当前和前一个位置。
- s_l 是定义在结点上的特征函数，称为状态特征，依赖于当前位置。
- t_k 和 s_l 都依赖于位置，是局部特征函数。
- 特征函数 t_k 和 s_l 取值为1或0；当满足特征条件时取值为1，否则为0。条件随机场完全由特征函数 t_k, s_l 和对应的权值 λ_k, u_l 确定。

- **例 1** 设有一标注问题：输入观测序列为 $X=(X_1, X_2, X_3)$ ，输出标记序列为 $y=(y_1, y_2, y_3)$ ，取值于 $\{1, 2\}$ 。

假设特征 t_k ， s_l 和对应的权值 λ_k ， u_l 如下：↵

$$t_1 = t_1(y_{i-1} = 1, y_i = 2, x, i), \quad i = 2, 3, \quad \lambda_1 = 1 \quad \leftarrow$$

这里只注明特征取值为 1 的条件，取值为 0 的条件省略，即↵

$$t_1(y_{i-1}, y_i, x, i) = \begin{cases} 1, & y_{i-1} = 1, y_i = 2, x, i, (i = 2, 3) \\ 0, & \text{其他} \end{cases}$$

下同。↵

$$t_2 = t_2(y_1 = 1, y_2 = 1, x, 2) \quad \lambda_2 = 0.6 \quad \leftarrow$$

$$t_3 = t_3(y_2 = 2, y_3 = 1, x, 3) \quad \lambda_3 = 1 \quad \leftarrow$$

$$t_4 = t_4(y_1 = 2, y_2 = 1, x, 2) \quad \lambda_4 = 1 \quad \leftarrow$$

$$t_5 = t_5(y_2 = 2, y_3 = 2, x, 3) \quad \lambda_5 = 0.2 \quad \leftarrow$$

$$s_1 = s_1(y_1 = 1, x, 1) \quad \mu_1 = 1 \quad \leftarrow$$

$$s_2 = s_2(y_i = 2, x, i), \quad i = 1, 2 \quad \mu_2 = 0.5 \quad \leftarrow$$

$$s_3 = s_3(y_i = 1, x, i), \quad i = 2, 3 \quad \mu_3 = 0.8 \quad \leftarrow$$

$$s_4 = s_4(y_3 = 2, x, 3) \quad \mu_4 = 0.5 \quad \leftarrow$$

对给定的观测序列 $X = (X_1, X_2, X_3)$ 求标记序列为 $y = (y_1, y_2, y_3) = (1, 2, 2)$ 的非规范化条件概率（即没有除以规范化因子的条件概率）。

- 解：线性链条件随机场模型为

$$P(\mathbf{y} | \mathbf{x}) \propto \exp \left[\sum_{k=1}^5 \lambda_k \sum_{i=2}^3 t_k(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{k=1}^4 \mu_k \sum_{i=1}^3 s_k(y_i, \mathbf{x}, i) \right]$$

对给定的观测序列 $\mathbf{x}$ ，标记序列 $\mathbf{y} = (1, 2, 2)$ 的非规范化条件概率为

$$P(y_1 = 1, y_2 = 2, y_3 = 2 | \mathbf{x}) \propto \exp(3.2)$$

$$P(\mathbf{y} | \mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{i,l} u_l s_l(y_i, \mathbf{x}, i) \right)$$

条件随机场的简化形式

- 条件随机场式中同一特征在各个位置都有定义:

$$P(y | x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} u_l s_l(y_i, x, i) \right)$$

- 将转移特征和状态特征及其权值用统一的符号表示。
设有 K_1 个转移特征, K_2 个状态特征, $K=K_1+K_2$

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k = 1, 2, \dots, K_1 \\ s_l(y_i, x, i), & k = K_1 + l; l = 1, 2, \dots, K_2 \end{cases}$$

然后, 对转移与状态特征在各个位置 i 求和, 记作

$$f_k(y, x) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i), \quad k = 1, 2, \dots, K$$

用 w_k 表示特征 $f_k(y, x)$ 的权值, 即

$$w_k = \begin{cases} \lambda_k, & k = 1, 2, \dots, K_1 \\ \mu_l, & k = K_1 + l; l = 1, 2, \dots, K_2 \end{cases}$$

$$P(y | x) = \frac{1}{Z(x)} \exp \sum_{k=1}^K w_k f_k(y, x)$$

$$Z(x) = \sum_y \exp \sum_{k=1}^K w_k f_k(y, x)$$

若以 w 表示权值向量，即

$$w = (w_1, w_2, \dots, w_k)^T$$

以 $F(y, x)$ 表示全局特征向量，即

$$F(y, x) = (f_1(y, x), f_2(y, x), \dots, f_k(y, x))^T$$

则条件随机场可以写成向量 w 与 $F(y, x)$ 的内积的形式：

$$P_w(y | x) = \frac{\exp(w \cdot F(y, x))}{Z_w(x)}$$

其中，

$$Z_w(x) = \sum \exp(w \cdot F(y, x))$$

条件随机场的矩阵形式

- 条件随机场还可以由矩阵表示。假设线性链条件随机场 $P(y|x)$ ，表示对给定观测序列 x ，相应的标记序列 y 的条件概率。

$$P(y|x) = \frac{1}{Z(x)} \exp \sum_{k=1}^K w_k f_k(y, x)$$

$$Z(x) = \sum_y \exp \sum_{k=1}^K w_k f_k(y, x)$$

- 引进特殊的起点 $y_0=\text{start}$, $y_{n+1}=\text{stop}$ 和终点状态标记， $P(y|x)$ 可通过矩阵形式表示。

- 对观测序列 $\mathbf{x}$ 的每一个位置 $i=1,2,\dots,n+1$ ，定义一个 m 阶矩阵（ m 是标记 y_i 取值的个数）

$$M_i(\mathbf{x}) = [M_i(y_{i-1}, y_i | \mathbf{x})]$$

$$M_i(y_{i-1}, y_i | \mathbf{x}) = \exp(W_i(y_{i-1}, y_i | \mathbf{x}))$$

$$W_i(y_{i-1}, y_i | \mathbf{x}) = \sum^K w_k f_k(y_{i-1}, y_i | \mathbf{x})$$

- 给定观测序列 $\mathbf{x}$ ，标记序列 $\mathbf{y}$ 的非规范化概率可以通过 $n+1$ 个矩阵的乘积表示 $\prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x})$
- 条件概率 $P(\mathbf{y} | \mathbf{x})$ 为

$$\frac{1}{Z_w(\mathbf{x})} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x})$$

$$Z_w(\mathbf{x}) = (M_1(\mathbf{x}) M_2(\mathbf{x}) \cdots M_{n+1}(\mathbf{x}))_{start, stop}$$

- 例2** 给定一个由图11.6所示的线性链条件随机场，观测序列 $\mathbf{x}$ ，状态序列 $\mathbf{y}$ ， $i=1,2,3$ ， $n=3$ ，标记 $y_i \in \{1,2\}$ ，假设 $y_0 = \text{start} = 1$ ， $y_4 = \text{stop} = 1$ ，各个位置的随机矩阵 $M_1(\mathbf{x})$ ， $M_2(\mathbf{x})$ ， $M_3(\mathbf{x})$ ， $M_4(\mathbf{x})$ 分别是

$$M_1(\mathbf{x}) = \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(\mathbf{x}) = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix},$$

$$M_3(\mathbf{x}) = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(\mathbf{x}) = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}.$$

试求状态序列 以start为起点stop为终点所有路径的非规范化概率及规范化因子。




图 11.6 状态路径

- **解** 首先计算从start到stop对应于各路径的非规范化概率分别是

$$a_{01}b_{11}c_{11}, a_{01}b_{11}c_{12}, a_{01}b_{12}c_{21}, a_{01}b_{12}c_{22},$$

$$a_{02}b_{21}c_{11}, a_{02}b_{21}c_{12}, a_{02}b_{22}c_{21}, a_{02}b_{22}c_{22}$$




图 11.6 状态路径

- 求规范化因子

计算矩阵乘积

$$M_1(x)M_2(x)M_3(x)M_4(x)$$

其第1行第1列的元素

$$M_1(x) = \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix},$$

$$M_3(x) = \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix},$$

$$a_{01}b_{11}c_{11} + a_{02}b_{21}c_{11} + a_{01}b_{12}c_{21} + a_{02}b_{22}c_{22} + a_{01}b_{11}c_{12} + a_{02}b_{21}c_{12} + a_{01}b_{12}c_{22} + a_{02}b_{22}c_{21}$$

恰好等于从start到stop的所有路径的非规范化概率之和，即规范化因子。

习题

11.4 参考图 11.6 的状态路径图，假设随机矩阵 $M_1(x)$ ， $M_2(x)$ ， $M_3(x)$ ， $M_4(x)$ 分别是。

$$M_1(x) = \begin{bmatrix} 0 & 0 \\ 0.5 & 0.5 \end{bmatrix}, \quad M_2(x) = \begin{bmatrix} 0.3 & 0.7 \\ 0.7 & 0.3 \end{bmatrix},$$

$$M_3(x) = \begin{bmatrix} 0.5 & 0.5 \\ 0.6 & 0.4 \end{bmatrix}, \quad M_4(x) = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}.$$

求以 start=2 为起点 stop=2 为终点的所有路径的状态序列 y 的概率及概率最大的状态序列。

表 12.1 10 种统计学习方法特点的概括总结

方法	适用问题	模型特点	模型类型	学习策略	学习的损失函数	学习算法
感知机	二类分类	分离超平面	判别模型	极小化误分点到超平面距离	误分点到超平面距离	随机梯度下降
k 近邻法	多类分类, 回归	特征空间, 样本点	判别模型			
朴素贝叶斯法	多类分类	特征与类别的联合概率分布, 条件独立假设	生成模型	极大似然估计, 极大后验概率估计	对数似然损失	概率计算公式, EM 算法
决策树	多类分类, 回归	分类树, 回归树	判别模型	正则化的极大似然估计	对数似然损失	特征选择, 生成, 剪枝
逻辑斯蒂回归与最大熵模型	多类分类	特征条件下类别的条件概率分布, 对数线性模型	判别模型	极大似然估计, 正则化的极大似然估计	逻辑斯蒂损失	改进的迭代尺度算法, 梯度下降, 拟牛顿法
支持向量机	二类分类	分离超平面, 核技巧	判别模型	极小化正则化合页损失, 软间隔最大化	合页损失	序列最小最优化算法 (SMO)
提升方法	二类分类	弱分类器的线性组合	判别模型	极小化加法模型的指数损失	指数损失	前向分步加法算法
EM 算法 ^①	概率模型参数估计	含隐变量概率模型		极大似然估计, 极大后验概率估计	对数似然损失	迭代算法
隐马尔可夫模型	标注	观测序列与状态序列的联合概率分布模型	生成模型	极大似然估计, 极大后验概率估计	对数似然损失	概率计算公式, EM 算法
条件随机场	标注	状态序列条件下观测序列的条件概率分布, 对数线性模型	判别模型	极大似然估计, 正则化极大似然估计	对数似然损失	改进的迭代尺度算法, 梯度下降, 拟牛顿法

THANK YOU!