

智能信息网络实验 期末大作业

成员：王殿云(2022211733) 王博涵(2022211735) 王艺栋(2022211799)

作业选题：

飞桨学习赛：中文新闻文本标题分类

摘要

中文新闻标题分类作为自然语言处理的重要任务，在内容推荐、信息检索和媒体分析等领域具有广泛应用。然而，由于中文语言缺乏明确词边界、新闻数据严重的类别不平衡以及标题文本长度过短等特点，该任务面临诸多技术挑战。本文提出了一种综合的中文新闻文本分类方法，通过整合预训练语言模型微调、数据平衡技术和数据增强策略来系统性地解决这些挑战。

首先，我们采用hfl/chinese-roberta-wwm-ext-large作为基础模型，该模型通过全词掩码策略和大规模中文语料预训练，能够有效捕获中文文本的语义特征。其次，针对数据集中头尾类别样本比例高达500:1的极端不平衡问题，我们复现并改进了标签特定特征增强（LSFA）方法，通过在特征空间中将头部标签的二阶统计量迁移到尾部标签，在保持数据自然分布的同时有效缓解了类别不平衡。第三，针对新闻标题平均长度仅为10-30字符的短文本问题，我们创新性地提出了基于大语言模型的内容扩充策略，利用LLM生成与标题语义一致的扩展内容，将短文本扩充为包含更丰富语义信息的中等长度文本。

在THUCNews数据集上的实验结果表明，我们的方法取得了显著的性能提升。相比基础模型89.22%的准确率，通过逐步引入伪标签学习、LSFA数据增强和LLM内容扩充，最终准确率达到90.55%，提升了1.33个百分点。基于本文提出的方法，我们的团队在飞桨学习赛中文新闻文本标题分类竞赛中取得了月榜第一的成绩，验证了方法的有效性和实用性。

1. 引言

1.1 研究背景

随着中文数字内容的爆炸性增长，自动文本分类已成为信息管理系统中不可或缺的核心技术。在超过10亿中文互联网用户的背景下，准确高效的新闻标题分类对内容推荐、信息检索和媒体分析具有重要意义。中文新闻标题分类作为一个特定的研究领域，由于中文语言的独特性质和新闻数据的固有特征，面临着诸多技术挑战。

与基于空格分隔的语言不同，中文文本缺乏明确的词边界，这一根本性差异贯穿整个中文自然语言处理任务的流程[1]。近期研究表明，基于字符的模型在中文处理任务中展现出优越性能，这一发现

得到了语言学研究的支撑——即使是母语使用者在词边界识别上的一致性仅达到约90%[2]。这种分词歧义性，结合中文字符的高度多义性和密集信息编码特性（平均1.5个中文字符对应一个英文单词），要求模型具备强大的上下文建模能力[3]。

预训练语言模型的出现为中文自然语言处理带来了革命性进展，BERT及其变体在多项任务中取得了最佳性能[3]。然而，将这些模型应用于新闻分类时，数据不平衡和文本长度变化带来了新的挑战。真实世界的新闻数据集呈现极端的长尾分布，头部类别与尾部类别的样本比例可达200:1至500:1[5]。此外，长度仅为10-30个字符的短标题普遍存在，对依赖上下文的深度模型提出了严峻考验。

1.2 中文新闻文本分类的挑战

通过系统性分析，我们识别了中文新闻标题分类面临的三个核心挑战：

语言复杂性：中文的字词二元性要求模型同时处理字符级别和词级别的语义信息。缺乏形态标记剥夺了模型可利用的语法线索，而字符的上下文依赖性使得相同字符序列在不同语境下可能表达截然不同的语义。这些语言学特征与新闻领域特征的相互作用进一步增加了任务复杂度。

数据长尾问题：实证分析显示，主流新闻数据集呈现严重的类别不平衡。以包含14个类别的THUCNews基准数据集为例，政治和经济类新闻占据主导地位，而科技和地方新闻等专业类别样本稀少。传统机器学习方法在此类不平衡数据上表现出明显的多数类偏向，导致少数类别的召回率严重不足。在多标签分类场景中，复杂的标签共现模式使这一问题更加棘手。

领域特定性：新闻文本包含大量专业术语、命名实体和时间敏感表达，需要领域知识进行准确解释。新闻语言的快速演变带来了词汇分布漂移问题，要求模型在保持稳定性能的同时具备适应性。此外，正式与口语风格的混合、地域性表达以及文化典故的使用进一步增加了建模难度。

1.3 研究目标与成果

本文提出了一种综合的中文新闻文本分类方法，通过微调预训练模型、数据平衡技术和数据增强策略来解决上述挑战。在本次实验中，我们的主要工作包括：

第一，我们探索了微调**hfl/chinese-roberta-wwm-ext-large**模型在THUCNews数据集上进行中文新闻分类的有效应用。该模型结合了RoBERTa的训练优化和中文特定的全词掩码（WWM），通过在预训练期间保留语义单元提供了优越的上下文理解。我们的实验表明，这种架构有效地捕获了中文新闻文本中的细微关系，在所有14个新闻类别中相对于基线模型都取得了显著的性能改进。

第二，我们复现并改进了**标签特定特征增强（LSFA）**方法来解决新闻数据集中固有的严重类别不平衡问题。与传统重采样方法不同，LSFA在学习的特征空间中操作，将二阶统计量从头部标签转移到尾部标签，同时保留对准确新闻分类至关重要的标签共现模式。这种复杂的方法能够有效处理不平衡数据，而不会破坏准确新闻分类所必需的自然分布特征。

第三，我们设计并实现了专门为新闻分类中的短文本扩展的**基于大语言模型的数据增强策略**。通过利用大语言模型扩展短文本新闻标题数据，为其补充固定长度的新闻内容，解决了短新闻标题带来的挑战。同时，在讨论部分，我们结合互信息理论，提供了该方法有效的理论支撑。

通过这三个部分的整合，我们的实验结果表明，分类准确性大幅提高，特别是对于少数类别，同时在整个标签空间中保持高整体性能。同时，应用本实验中提出的方法，截止2025年5月27日，我们

的团队在[飞桨学习赛：中文新闻文本标题分类](#)本月榜单排行第一（OhMyKing的团队）。

202505	202504	202503	202502	202501	202412	202411	202410	202409	202408	202407
排名	参赛团队	所属组织	score	提交时间						
1	OhMyKing的团队	北京邮电大学	90.54893	2025-05-26 09:49						
2	ヤチヨ的团队	北京邮电大学	90.54534	2025-05-24 16:25						
3	一个小团队	北京邮电大学	90.19964	2025-05-20 08:18						

图1 本月榜单排行榜

2. 相关工作

2.1 预训练语言模型在文本分类中的应用

预训练语言模型的发展历程深刻改变了中文NLP的研究范式。从早期的静态词嵌入到当前的大规模预训练模型，技术演进带来了性能的飞跃。Word2Vec等早期方法提供了context-independent的词表示，虽然捕获了基本的语义关系，但无法处理中文字符的多义性问题[5]。BERT的提出标志着范式转变，其双向Transformer架构通过掩码语言建模和下一句预测任务实现了深度上下文理解[3]。

2.1.1 BERT及其变种

Google发布的BERT-Base-Chinese采用字符级WordPiece分词，在中文维基百科数据上进行预训练。然而，这种方法忽视了中文的词级语义单元，可能限制了模型对多字符词汇的理解能力。认识到这一局限性，哈工大讯飞联合实验室（HFL）提出了BERT-WWM（Whole Word Masking）系列模型[6]。WWM策略在词级别而非字符级别进行掩码，例如掩码"语言模型"时同时掩码所有组成字符，强制模型学习完整的语义单元。这一改进与中文词汇的组合特性高度契合，在多项任务中展现出优越性能。

RoBERTa（Robustly Optimized BERT Pretraining Approach）引入了多项关键优化[7]：(1) 动态掩码机制在每个训练epoch生成不同的掩码模式；(2) 移除NSP任务以专注于MLM目标；(3) 使用160GB的大规模训练数据（相比BERT的16GB）；(4) 采用更大的批次和更长的训练周期。

HFL团队将RoBERTa的优化策略与中文特定的WWM相结合，推出了chinese-roberta-wwm-ext系列。大型变体包含24层Transformer、1024维隐藏层和3.3亿参数，在包含维基百科、新闻语料和网络文本的大规模中文数据上预训练[8]。该模型在CLUE基准测试中取得了最佳性能，特别是在文本分类任务上展现出超过90%的F1分数[9]。

在中文语言理解评估（CLUE）基准测试中，chinese-roberta-wwm-ext模型在多个任务中始终取得顶级性能。[9] 特别是对于文本分类，这些模型在各种基准测试中展示了90%以上的F1分数。该模型的架构实现了有效的迁移学习，只需要对特定的新闻分类任务进行最小的微调，同时在从政治到娱乐的各种新闻类别中保持稳健的性能。

2.2 长尾分布问题处理技术

长尾分布是真实世界文本分类的固有特征，少数头部类别占据大量样本，而众多尾部类别面临数据稀缺[10]。在中文新闻分类中，这种不平衡尤为严重，头尾类别的样本比例可达500:1[5]。

2.2.1 重采样与重加权方法

处理不平衡数据的经典方法包括重采样技术，如SMOTE（合成少数重采样技术），它通过在少数类实例之间的插值生成合成样本。然而，SMOTE对k最近邻的依赖在高维文本特征空间中变得有问题，经常产生语义无效的文本表示。[11]

另外一类处理不平衡数据的经典方法是重加权方法，包括逆频率加权和焦点损失，试图通过为少数类分配更高的重要性来平衡训练。虽然最初为目标检测设计的焦点损失已经适配用于文本分类，但这些方法在多标签场景中显示出有限的有效性，其中标签依赖关系使简单的重加权策略复杂化。[12]

2.2.2 迁移学习方法

通过调研，我们发现方法利用迁移学习来解决尾部类别的数据稀缺问题。预训练语言模型提供了强大的Baseline表示，部分缓解了有限训练数据的影响。然而，在不平衡数据集上进行微调仍然会产生偏向多数类别的有偏模型。先进的技术如TAPON使用元学习将知识从头部标签转移到尾部标签，基于丰富类别模式为稀有类别创建原型。这些方法前景广阔，但需要仔细的架构设计以防止不相似类别之间的负迁移。[12]

2.3 数据增强技术

数据增强已成为改善模型泛化和解决文本分类中数据稀缺的关键技术。早期的增强技术依赖于保留语义含义同时引入词汇变化的简单转换。简易数据增强（EDA）规范了四种操作：使用WordNet的同义词替换、随机词插入、随机词交换和随机删除。虽然EDA在小数据集上实现了0.8-3.0%的改进，但其有效性随着语料库的增大而减弱，并且在同义词数据库覆盖不足的领域特定文本中表现困难。[13] 回译涉及翻译到中间语言并返回，提供了更自然的释义，但存在质量不一致和潜在意义漂移的问题。对于中文文本，由于语言族之间的结构差异，通过多种中间语言（英语、日语、韩语）的回译通常会产生更好的结果。

3. 方法

3.1 问题定义

本实验的目标是构建一个高性能的中文新闻标题分类系统，给定一个新闻标题，准确预测其所属的类别。形式化定义如下：

给定一个中文新闻标题文本 $T = c_1, c_2, \dots, c_n$ ，其中 c_i 表示中文字符，我们的目标是学习一个映射函数 $f: T \rightarrow Y$ ，将标题映射到预定义的类别集合 $Y = y_1, y_2, \dots, y_k$ 中的一个标签。在本实验中，使用的THUCNews数据集包含14个类别，分别是：财经、彩票、房产、股票、家居、教育、科技、社会、时尚、时政、体育、星座、游戏和娱乐。

3.2 数据分析

通过分析赛题给定的数据集，我们发现数据集主要存在以下两大问题：

1. 短文本问题

预训练Bert模型训练数据长度通常在128~512左右，属于中等长度文本，而新闻标题长度分布在12~28，属于短文本范畴，文本语义信息较少，较难学习到足够的特征以支撑分类任务、

1. 数据长尾问题

真实世界的新闻数据集表现出严重的类别不平衡，本数据集中，科技、经济类新闻占主导地位，而星座或彩票新闻等类别则相对稀少。机器学习方法在处理此类不平衡数据时表现不佳，对多数类表现出强烈偏向，而实际上忽略了少数类别。

数据文本长度分布于各类别数据统计信息见下图：




图2 数据集数据分布情况

3.3 总体架构

3.3.1 数据处理方法

本实验采用了三阶段的数据处理策略，如下图所示：




图3 数据处理策略

- 1. **原始数据集：**基于THUCNews数据集，包含14个类别（财经、彩票、房产、股票、家居、教育、科技、社会、时尚、时政、体育、星座、游戏和娱乐）的约75万条新闻标题。原始数据集存在两个主要问题：各类别样本数量不平衡，且新闻标题文本平均长度较短。
- 2. **应用LSFA的平衡数据集：**通过标签特定特征增强(Label-Specific Feature Augmentation, LSFA)技术，对数据集进行平衡处理，扩展至约84万条样本。LSFA针对原始数据集不平衡的问题，在保障数据分布不被破坏的前提下扩展数据，解决长尾问题，使模型能更好地捕捉各类别的区分性特征。
- 3. **LLM扩写的增强数据集：**利用大型语言模型(LLM)对新闻标题进行扩写，生成包含标题及内容的长文本样本。这一步骤显著增加了文本长度和语义信息密度，为模型提供了更丰富的特征。

3.3.2 模型训练架构

如下图所示，本实验采用了基于预训练语言模型的分分类架构：




图4 模型训练架构

1. **基础模型**：使用 `hfl/chinese-roberta-wwm-ext-large` 作为基础编码器。将输入的新闻标题文本转换为向量表示，捕捉文本的语义特征；
2. **全连接分类层**：接收文本嵌入输出，通过全连接网络映射到14个目标类别；
3. **训练策略**：采用两阶段训练方法：
 - **第一阶段**：在原始标记数据上训练模型
 - **第二阶段**：利用伪标签技术(Pseudo-Labeling)，对置信度高的测试集样本生成伪标签，结合原始训练数据进行模型增强训练

3.4 模型架构

3.4.1 chinese-roberta-wwm-ext-large预训练模型

本实验采用hfl开源的 `hfl/chinese-roberta-wwm-ext-large` 作为基础预训练模型。该模型具有以下特点：

- **模型规模**：24层Transformer架构，1024维隐藏层，16个注意力头，约3.3亿参数
- **全词掩码**：采用全词掩码（Whole Word Masking）预训练策略，更适合中文语义理解
- **预训练数据**：在超过5.4亿词的中文语料上预训练，包括新闻、百科、问答等多样化文本
- **序列长度**：支持最大512个token的输入，足以处理新闻标题及其上下文
- **词汇表**：使用21128个token的词汇表，覆盖常见中文字符及词汇

该模型比BERT-base和RoBERTa-base具有更强的表达能力，特别是在处理中文文本时，全词掩码策略确保了模型能够理解完整的语义单元，而不仅仅是单个字符，这对于短文本分类尤为重要。

3.4.2 分类头设计

在预训练模型之上，我们设计了一个简洁高效的单层分类头：

代码块

```
1 model = AutoModelForSequenceClassification.from_pretrained(  
2     model_name,  
3     num_labels=len(label_list)  
4 ).to(device)
```

分类头由以下组件构成：

- **池化层**：采用Roberta模型的最终隐藏状态作为整个序列的表示
- **分类层**：全连接层将1024维隐藏表示映射到14个类别
- **激活函数**：最终层不使用激活函数，直接输出logits，与交叉熵损失函数配合使用

3.5 数据增强方法

3.5.1 长尾分布优化策略——标签特定特征增强(LSFA)方法

这篇工作来自AAAI 2023[14]，针对文本分类中普遍存在的长尾标签分布问题，提出了一种标签特定特征增强（LSFA）框架。在现实应用中，标签通常遵循长尾分布，其中大部分尾部标签只包含少量文档，这严重限制了多标签文本分类的性能。为了解决这一挑战，作者提出了一种新颖的配对级增强框架，该框架仅为尾部标签增强正特征-标签对，通过在高级潜在空间中进行标签特定的文档表示学习，并将头部标签的二阶统计信息（类内语义变化）转移到尾部标签来实现特征增强。




图5 LSFA结构

具体而言，LSFA分为解耦表示学习和头部到尾部特征增强两个主要部分。

3.5.1.1 解耦表示学习

解耦表示学习的核心在于标签特定编码器的设计。该编码器采用分层架构，由一个共享的早期层和多个标签特定的后期层组成。共享层使用双向LSTM来提取文档中每个词汇的隐藏表示，捕获前向和后向的上下文信息。在此基础上，标签特定层通过注意力机制让每个标签有选择性地关注文档中与其相关的关键词汇，将标签作为查询来检索文档中的显著词汇，从而为每个标签生成独特的特征表示。这种设计理念基于不同标签可能关注文档中不同部分的观察，避免了传统方法中所有标签共享相同文档表示的局限性。

为了进一步提升解耦表示的质量，还引入了原型监督对比学习策略。传统的交叉熵损失往往导致学习到的特征偏斜且松散，这会影响后续的分类器性能和增强效果。原型监督对比学习通过将每个特征向量推离其他标签的原型并拉向其自身标签的原型来优化特征空间的分布。具体而言，该方法首先为每个标签计算原型向量，然后通过对比损失函数确保同一标签的特征在空间中聚集，而不同标签的特征相互分离。这种学习策略不仅提升了特征的区分性和紧密性，还为后续的特征增强提供了更可靠的基础，因为更好的特征表示有助于生成高质量的增强样本。

3.5.1.2 从头部到尾部的特征增强

头部到尾部特征增强的核心组件是基于原型的变分自编码器（PVAE）。该模块的设计基于一个关键假设：头部标签和尾部标签之间的类内语义变化模式具有可迁移性。PVAE首先通过计算每个标签所有特征向量各维度的均值来获得标签原型，这些原型代表了每个标签的中心特征表示。然后根据预设的头尾阈值将标签划分为头部标签集合和尾部标签集合，为后续的知识迁移做准备。

PVAE的训练过程专门针对头部标签进行。编码器接收头部标签的特征向量及其对应的原型作为输入，将其映射到潜在变化空间，学习捕获类内的语义变化模式。解码器则从潜在变量和原型重构原始特征向量，确保模型能够准确建模头部标签的特征分布。训练目标函数结合了KL散度项和重构损失项，前者确保潜在变量遵循先验分布，后者保证重构质量。通过在头部标签的充足数据上训练，PVAE学习到了丰富的类内语义变化知识。

特征生成和损失函数设计是该框架的最终环节。训练完成后，PVAE可以为尾部标签生成增强特征。生成过程通过输入尾部标签的原型和从标准高斯分布采样的噪声向量来实现，利用解码器生成与真实特征分布一致的增强特征。这些生成的特征被视为尾部标签的正特征-标签对，专门用于调整相应的分类器。作者设计了专门的增强损失函数来处理这些生成的正样本，该损失函数与原始的二元交叉熵损失相结合，形成更加平衡的训练目标。通过这种方式，原本数据稀缺的尾部标签获得了充足的训练样本，显著提升了分类器在尾部标签上的性能。

3.5.2 基于LLM的内容扩充数据增强

短文本分类任务面临的核心挑战在于文本长度受限导致的语义信息稀疏问题。新闻标题作为典型的短文本，通常仅包含10-20个词，难以为深度学习模型提供充分的上下文信息。为解决这一问题，本实验提出了一种基于大语言模型（LLM）的内容扩充数据增强方法。

该方法的核心思想是利用LLM强大的文本生成能力，基于原始新闻标题生成相应的新闻内容摘要，从而将短文本扩充为包含更丰富语义信息的中等长度文本。具体而言，我们通过精心设计的提示词（prompt），引导LLM根据标题的主题、类别和关键信息，生成128-156字的新闻内容扩充。这种扩充不是简单的同义词替换或句式变换，而是基于LLM对新闻领域知识的理解，生成符合新闻写作规范且与标题语义一致的内容补充。

具体而言，该方法步骤如下：

- 提示词设计：**构建包含任务说明、输出格式要求和示例的提示词模板，确保LLM生成的内容既符合新闻文体特征，又保持与原标题的语义一致性。
- 批量生成：**对训练集中的每条数据，将"标题+类别"作为输入，通过LLM生成对应的扩充内容。生成过程中控制较低温度参数以保证文本分布与真实世界文本分布的一致性。主要代码逻辑如下：

代码块

```
1  def enhance_news_title(title, category, model, tokenizer):
2      """使用Qwen模型为新闻标题生成内容"""
3      try:
4          # 格式化提示以便模型更好地理解任务
5          prompt = f"""请为以下新闻标题生成一段较短的新闻内容，内容应该与标题相关，体现标题所属的分类，并且包含合理的细节。内容大约150-200字左右。
6          标题: {title}
```

```

7  分类: {category}
8  生成的内容: ""
9
10     # 对提示进行编码
11     inputs = tokenizer(prompt, return_tensors="pt").to(model.device)
12
13     # 生成内容
14     with torch.no_grad():
15         outputs = model.generate(
16             **inputs,
17             max_new_tokens=200, # 限制生成内容的长度
18             temperature=0.7,   # 控制随机性
19             top_p=0.9,         # 使用nucleus sampling
20             do_sample=True     # 使用采样以获得更多样化的输出
21         )
22
23     # 解码并清理生成的文本
24     generated_text = tokenizer.decode(outputs[0],
25 skip_special_tokens=True)
26     # 提取生成的内容部分 (提示之后的内容)
27     content = generated_text.split("生成的内容: ")[-1].strip()
28
29     # 清理CUDA缓存以防止内存问题
30     if torch.cuda.is_available():
31         torch.cuda.empty_cache()
32
33     return content
34
35 except Exception as e:
36     print(f"为'{title}'生成内容时出错: {str(e)}")

```

3. **数据整合**：将原始标题与生成的扩充内容拼接，形成新的训练样本，格式为"[标题] ([类别]) [扩充内容]"。

3.6 训练策略

3.6.1 模型预热与学习率调度

我们采用了warmup结合余弦退火的学习率调度策略来优化模型训练过程。具体而言：

学习率预热 (Learning Rate Warmup)：在训练初期，模型参数远离最优解，使用较大的学习率可能导致训练不稳定。因此，我们在前10%的训练步数中线性增加学习率，从0逐渐上升至目标学习率 $2e-5$ 。形式化表示为：

代码块

```
1 lr(t) = lr_target × (t / t_warmup), if t < t_warmup
```

其中, $t_warmup = 0.1 \times total_steps$ 。这种策略有效缓解了训练初期的梯度震荡问题。

余弦退火调度 (Cosine Annealing Schedule)：预热阶段结束后, 学习率按照余弦函数从最大值平滑衰减至0:

代码块

```
1 lr(t) = 0.5 × lr_max × (1 + cos(π × (t - t_warmup) / (T - t_warmup)))
```

余弦退火相比于线性衰减或阶梯衰减, 能够帮助模型在训练后期更细致地探索损失函数表面, 从而找到更优的局部最小值。

3.6.2 伪标签学习

为充分利用无标注的测试数据, 我们提出了一种两阶段的伪标签学习框架:

第一阶段 - 教师模型训练: 使用原始标注数据集 D_train 训练初始模型 $M_teacher$, 通过4个epoch的训练获得在验证集上表现最优的模型参数。

伪标签生成: 利用训练好的教师模型对无标签测试集 D_test 进行推理, 计算每个样本的预测概率分布:

代码块

```
1 p(y|x) = softmax(M_teacher(x))
```

我们采用高置信度筛选策略, 仅保留 $\max(p(y|x)) \geq 0.9$ 的样本作为伪标签数据。这一阈值的设定平衡了伪标签的质量和数量——过低的阈值会引入噪声, 过高的阈值则限制了可用数据规模。

第二阶段 - 增强训练: 将高质量伪标签数据 D_pseudo 与原始训练集合并, 形成增强训练集:

代码块

```
1 D_augmented = D_train ∪ D_pseudo
```

使用增强数据集从头训练一个新的模型。值得注意的是, 我们选择重新初始化模型参数而非在教师模型基础上继续训练, 这一设计避免了模型过度拟合初始训练集的偏差, 使其能够更好地学习扩展数据中的模式。

实验观察: 通过wandb的详细日志记录, 我们观察到伪标签学习带来了以下改进:

- 训练数据规模得到有效扩充, 提升了模型的泛化能力

- 各类别的伪标签分布相对均衡，避免了类别不平衡的加剧
- 第二阶段训练的收敛速度更快，验证集性能得到显著提升

这种自训练（self-training）范式在半监督学习领域已被证明是有效的，特别是在标注数据有限而无标签数据充足的场景下。

4. 实验

4.1 数据集

4.1.1 THUCNews数据集介绍

THUCNews是根据新浪新闻RSS订阅频道2005~2011年间的历史数据筛选过滤生成，包含74万篇新闻文档（2.19 GB），均为UTF-8纯文本格式。在原始新浪新闻分类体系的基础上，重新整合划分出14个候选分类类别：财经、彩票、房产、股票、家居、教育、科技、社会、时尚、时政、体育、星座、游戏、娱乐。

4.1.2 数据预处理

训练集格式：标签ID+\t+标签+\t+原文标题

验证集格式：标签ID+\t+标签+\t+原文标题

测试集格式：原文标题

4.1.3 类别分布分析

下面为赛题方提供的THUCNews数据集的统计结果，可以看到呈现典型的长尾分布特点。

表1 THUCNews数据集统计情况

类别	训练样本数	占比（%）
科技	146637	19.49
股票	138959	18.47
体育	118440	15.74
娱乐	83368	11.08
时政	56778	7.55
社会	45765	6.08
教育	37743	5.02
财经	33389	4.44

家居	29328	3.9
游戏	21936	2.92
房产	18045	2.4
时尚	12032	1.6
彩票	6830	0.91
星座	3221	0.43




图6 数据集长尾分布情况

4.2 实验设置

4.2.1 基准模型

为了全面评估所提出方法的有效性，我们选择了以下模型进行对比实验：

主模型：

- **hfl/chinese-roberta-wwm-ext-large**：采用全词掩码（Whole Word Masking）和扩展训练数据的中文预训练语言模型，包含24层Transformer编码器，1024维隐藏层，16个注意力头，总计约3.3亿参数。该模型在多项中文NLP任务上达到了SOTA性能。

对比基准：

- **google-bert/bert-base-chinese**：Google发布的中文BERT基础版本，12层，768维，1.1亿参数。
- **nghuyong/ernie-1.0-base-zh**：ERNIE（通过知识整合增强表示）由百度于2019年提出，旨在通过知识掩码策略（即实体级掩码和短语级掩码）学习增强的语言表示。实验结果表明，ERNIE在五个中文自然语言处理任务（包括自然语言推理、语义相似度、命名实体识别、情感分析和问答）上取得了最先进的结果。

4.2.2 评估指标

考虑到新闻分类任务的特点，我们采用以下指标进行综合评估：

主要指标：

- **准确率（Accuracy）**：正确分类样本占总样本的比例，计算公式为：

代码块

```
1 Accuracy = (TP + TN) / (TP + TN + FP + FN)
```

辅助指标：

- **宏平均F1（Macro-F1）**：对各类别F1分数求算术平均，能够反映模型在不同类别上的均衡性能
- **加权F1（Weighted-F1）**：按类别样本数加权的F1分数，更适合类别不平衡的场景
- **混淆矩阵（Confusion Matrix）**：可视化模型在各类别间的预测偏差

4.2.3 实验细节

所有实验均在AutoDL租赁的NVIDIA 4090 GPU服务器上进行。我们使用PyTorch 1.12.0和Transformers 4.25.0实现模型。详细的超参数设置如下：

数据预处理：

- 分词器：与预训练模型配套的BertTokenizer
- 填充策略：固定长度填充至max_length

训练配置：

- 批次大小（Batch Size）：64
- 学习率（Learning Rate）：2e-5（通过网格搜索从{1e-5, 2e-5, 3e-5, 5e-5}中选择）
- 优化器：AdamW (Loshchilov & Hutter, 2019)，权重衰减率为0.0

- 训练轮数 (Epochs) : 4 (早停策略: 验证集性能连续2轮未提升则停止)
- 梯度累积: 未使用 (显存充足)
- 混合精度训练: FP16自动混合精度加速训练

正则化策略:

- Dropout率: 0.1 (继承预训练模型设置)
- 梯度裁剪: 最大梯度范数1.0
- 标签平滑: 未使用 (数据集类别分布相对均衡)

实验管理:

- 随机种子: 1024 (确保结果可复现)
- 实验追踪: 使用Weights & Biases (wandb)记录训练过程中的所有指标
- 模型保存: 仅保存验证集上表现最优的checkpoint

硬件环境:

镜像	PyTorch 2.1.2 Python 3.10(ubuntu22.04) CUDA 11.8	更换
GPU	RTX 4090(24GB) * 1 升降配置	
CPU	16 vCPU Intel(R) Xeon(R) Gold 6430	
内存	120GB	
硬盘	系统盘: 30 GB	
	数据盘: 免费:50GB 付费:0GB 扩容 缩容	
附加磁盘	无	
端口映射	无	
自定义服务		
端口协议	http 修改	
网络	同一地区实例共享带宽	
计费方式	按量计费	
费用	¥ 2.40/时	

图7 实验硬件环境

4.3 实验结果与分析

4.3.1 主要结果比较

由于百度赛题以准确性作为排名标准，因此下文主要采用Accuracy作为关注指标。

- 仅使用chinese-roberta-wwm-ext-large预训练模型+分类头：89.21557%
- 增加使用伪标签：89.21557%——>89.51542%(+0.29985%)
- 增加LSFA进行数据增强：89.51542%——>90.00246%(+0.48704%)
- 增加LLM内容扩充数据增强：90.00246%——>90.54893%(+0.54647%)

实验记录如下：




图8 训练相关曲线

4.3.2 长尾类别性能分析

我们针对原始数据，在未进行LSFA进行数据增强时对于模型在不同的类别上的分类效果做了全方位的评估，具体结果如下表：

表2 未添加数据增强时不同类别的分类效果

label	original_train_count	dev_acc
科技	146637	0.9802
股票	138959	0.9796
体育	118440	0.9599
娱乐	83368	0.9087
时政	56778	0.9002
社会	45765	0.8894
教育	37743	0.8849
财经	33389	0.8702
家居	29328	0.8642
游戏	21936	0.8637
房产	18045	0.8499
时尚	12032	0.8357
彩票	6830	0.8049
星座	3221	0.7877

4.3.3 数据增强效果分析

4.3.3.1 LSFA数据增强效果分析

经LSFA数据增强后，数据总量由原来的75万增加到84万。具体的数据分布情况如下表所示：

表3 使用LSFA后数据分布情况

label	original_train_count	augmented_train_count	increase_ratio	added_samples
-------	----------------------	-----------------------	----------------	---------------

科技	146637	146637	1.0	0
股票	138959	138959	1.0	0
体育	118440	118440	1.0	0
娱乐	83368	83368	1.0	0
时政	56778	56778	1.0	0
社会	45765	45765	1.0	0
教育	37743	37743	1.0	0
财经	33389	33389	1.0	0
家居	29328	29328	1.0	0
游戏	21936	21936	1.0	0
房产	18045	36090	2.0	18045
时尚	12032	32231	2.68	20199
彩票	6830	37141	5.44	30311
星座	3221	27985	8.69	24764

对于每一个类别的准确率情况如下表：

表4 添加LSFA后不同类别的分类效果

label	original_train_count	dev_acc	increase
科技	146637	0.9899	0.0097
股票	138959	0.9893	0.0097
体育	118440	0.9723	0.0124
娱乐	83368	0.9275	0.0188
时政	56778	0.9273	0.0271
社会	45765	0.9182	0.0288
教育	37743	0.9151	0.0302
财经	33389	0.9049	0.0347

家居	29328	0.9030	0.0388
游戏	21936	0.9027	0.0390
房产	18045	0.8952	0.0453
时尚	12032	0.8856	0.0499
彩票	6830	0.8606	0.0557
星座	3221	0.8550	0.0673

在经过LSFA进行数据增强之后，我们会发现每一个类别的dev_acc都有所增加，而且对于尾部的类别，acc的增幅要大于头部类别的增幅，这也说明我们专注于增加尾部类别的增强是有用的，且不只是能够提升尾部类别的分类效果，也能够间接改善头部类别的分类效果。

这种改善具体来说：

- 对于头部类别，因为数据量大所以造成模型学到过多头类别的内容，有overfitting的隐患，现在有尾部类别特征的介入，会避免学习到过多头类别特征。
- 对于尾部类别，本身就没有学到太多东西，造成效果也很差，现在通过数据增强，使得尾部类别有了足够的特征让模型进行学习。

4.3.3.2 LLM内容扩充数据增强效果分析

经过LLM的内容扩充的数据增强之后，我们对每一个类别上的表现效果进行了测试，具体情况如下表所示：

表5 添加LSFA与LLM内容扩充后不同类别的分类效果

label	original_train_count	dev_acc	increase
科技	146637	0.9978	0.0079
股票	138959	0.9977	0.0084
体育	118440	0.9907	0.0184
娱乐	83368	0.9905	0.0630
时政	56778	0.9903	0.0630
社会	45765	0.9896	0.0714
教育	37743	0.9893	0.0742
财经	33389	0.9841	0.0792

家居	29328	0.9837	0.0807
游戏	21936	0.9836	0.0809
房产	18045	0.9808	0.0856
时尚	12032	0.9802	0.0946
彩票	6830	0.9792	0.1186
星座	3221	0.9785	0.1235

在经过LLM进行内容的扩充之后，我们会发现每一个类别的dev_acc都又有所增加，而且对于尾部的类别，acc的增幅要大于头部类别的增幅，这点与使用LSFA的效果是一样的，且使用LLM进行内容扩充之后的改善效果更优，这也证明了我们在开始时所讨论的标题文本过短导致模型无法学到足够的特征信息。

在经过LLM进行内容扩充之后，dev_acc上的准确率达到了较高的水平，此时我们在测试集上进行测试，得到最终的测试准确率90.54893%，成功达到本月榜单的最高水平。

5. 讨论

5.1 基于LLM的内容扩充数据增强有效性讨论

5.1.1 直观解释

5.1.1.1 Bert预训练阶段文本长度分布

预训练Bert模型训练数据长度通常在128~512作业，适应中等长度文本，而新闻标题长度分布在12~28，属于短文本范畴，文本语义信息较少，因此存在数据分布偏差，适应性较差。

5.1.1.2 长文本中的信息增益

虽然文本信息量缺乏良好的定义，但当一段长文本包含短文本时，我们可以认为短文本中的信息含量上界小于等于长文本信息含量上界。这意味着Bert模型能够从长文本中提取更多特征信息，获得更好的分类性能。

5.1.2 形式化证明

1. 问题形式化

设原始数据集为 $\mathcal{D} = (x_i, y_i)_{i=1}^N$ ，其中 x_i 是短文本标题， $y_i \in \mathcal{Y}$ 是类别标签。
通过LLM增强后的数据集为 $\mathcal{D}' = (x_i, \tilde{c}i, y_i)_{i=1}^N$ ，其中 $\tilde{c}i = \text{LLM}(x_i, y_i)$ 是LLM生成的扩展内容。

2. 理论分析：从信息论角度

定理1（信息增益）： 设 $I(X;Y)$ 表示随机变量之间的互信息，则有：

$$I(X, \tilde{C}; Y) \geq I(X; Y)$$

证明： 根据数据处理不等式和互信息的链式法则：

$$I(X, \tilde{C}; Y) = I(X; Y) + I(\tilde{C}; Y|X)$$

由于 $\tilde{C}$ 是基于 (X, Y) 生成的，包含了关于 Y 的额外信息，因此 $I(\tilde{C}; Y|X) \geq 0$ 。

3. 从分布匹配角度

定理2（分布对齐）：

设预训练LLM学习到的语言分布为 $p_{\text{LLM}}(c|x, y)$ ，真实的完整新闻分布为 $p_{\text{true}}(c|x, y)$ 。当LLM充分训练时： $D_{\text{KL}}(p_{\text{true}}|p_{\text{LLM}}) < \epsilon$ ，这保证了生成内容的质量和相关性。

4. 从特征空间角度

定理3（特征空间扩展）：

设 $\phi: \mathcal{X} \rightarrow \mathbb{R}^d$ 为RoBERTa的特征提取函数。对于扩展后的输入：

原始特征空间： $\mathcal{F}_{\text{orig}} = \phi(x) : x \in \mathcal{X}$

扩展特征空间： $\mathcal{F}_{\text{exp}} = \phi([x; \tilde{c}]) : x \in \mathcal{X}, \tilde{c} = \text{LLM}(x)$

则 $\dim(\mathcal{F}_{\text{exp}}) > \dim(\mathcal{F}_{\text{orig}})$ ，且类间距离增大：

$$\mathbb{E}y \neq y' [d(\mathcal{F}_{\text{exp}}^y, \mathcal{F}_{\text{exp}}^{y'})] > \mathbb{E}y \neq y' [d(\mathcal{F}_{\text{orig}}^y, \mathcal{F}_{\text{orig}}^{y'})]$$

5. 总结

LLM在预训练时已经学习到了丰富的世界知识和语言模式，这种知识可以通过生成任务转移到下游的判别任务中。LLM将其内部的隐式知识显式化为文本，供判别模型学习。同时，与传统的随机增强不同，LLM生成的内容保持了语义相关性：

$$p(\tilde{c}|x, y) \approx p(c|x, y)$$

通过增加训练样本的多样性，但又保持类别相关性：

$$\text{Var}[\mathcal{D}'] > \text{Var}[\mathcal{D}], \quad \text{但} \quad \text{Bias}[\mathcal{D}'] \approx \text{Bias}[\mathcal{D}]$$

综上所述，该方法之所以有效，主要原因包括：

- 解决了短文本的固有限制：** 标题通常只有10-20个字，信息量极其有限。
- 利用了LLM的先验知识：** 例如"巴萨"自动关联到"欧冠"、"足球"等概念。
- 增强了类别特征的显著性：** 生成的内容会包含类别特异性词汇（如体育类的"进球"、"战术"；科技类的"研发"、"市场"）。
- 提供了更多的上下文线索：** 让RoBERTa能够学习到更丰富的模式。

这种方法本质上是将LLM作为一个"知识增强器"，将其在大规模预训练中学到的知识注入到特定任务的训练数据中，形成了一种新型的半监督学习范式。

6. 结论

本文针对中文新闻标题分类任务面临的核心挑战，提出了一套完整的解决方案，在理论创新和实践应用两个层面都取得了重要进展。

主要贡献包括：

1. 系统性地分析了中文新闻标题分类的三大挑战，并提出了针对性的解决方案；
2. 成功将LSFA方法应用于中文新闻分类场景，通过特征空间的知识迁移有效解决了长尾分布问题，实验证明该方法不仅提升了尾部类别的性能，还间接改善了头部类别的分类效果；
3. 创新性地提出了基于LLM的内容扩充数据增强策略，并从信息论角度提供了理论支撑，证明了通过增加互信息可以提升分类性能；
4. 设计了包含预热启动、余弦退火和伪标签学习的训练策略，充分挖掘了模型潜力。

总之，本文通过融合预训练模型、数据平衡技术和创新的数据增强策略，为中文新闻标题分类提供了一个有效的解决方案，不仅在学术上具有理论价值，在工业应用中也展现了实用前景。

参考文献

- [1] K. Deng, P.K. Bol, K.J. Li, & J.S. Liu, On the unsupervised analysis of domain-specific Chinese texts, Proc. Natl. Acad. Sci. U.S.A. 113 (22) 6154-6159, <https://doi.org/10.1073/pnas.1516510113> (2016).
- [2] Xiaoya Li, Yuxian Meng, Xiaofei Sun, Qinghong Han, Arianna Yuan, and Jiwei Li. 2019. Is Word Segmentation Necessary for Deep Learning of Chinese Representations?. In Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, pages 3242–3252, Florence, Italy. Association for Computational Linguistics.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova, BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, <https://arxiv.org/abs/1810.04805>
- [4] Curma, Helda & Sinaj, Valentina. (2023). Handling Data Imbalance in Text Classification.
- [5] Tomas Mikolov, Kai Chen, Greg Corrado, Jeffrey Dean(2013). Efficient Estimation of Word Representations in Vector Space.arXiv:1301.3781[cs.CL]
- [6] Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Ziqing Yang(2021). Pre-Training with Whole Word Masking for Chinese BERT. arXiv:1906.08101 [cs.CL]
- [7] Chandan Durgia (2021).Exploring BERT variants (Part 1): ALBERT, RoBERTa, ELECTRA
- [8] Yiming Cui, Wanxiang Che, Ting Liu, Bing Qin, Ziqing Yang(2021). Pre-Training with Whole Word Masking for Chinese BERT. arXiv:1906.08101 [cs.CL]
- [9] Liang Xu, Hai Hu, Xuanwei Zhang, Lu Li, Chenjie Cao, Yudong Li, Yechen Xu, Kai Sun, Dian Yu, Cong Yu, Yin Tian, Qianqian Dong, Weitang Liu, Bo Shi, Yiming Cui, Junyi Li, Jun Zeng, Rongzhao

Wang, Weijian Xie, Yanting Li, Yina Patterson, Zuoyu Tian, Yiwen Zhang, He Zhou, Shaowei Hua Liu, Zhe Zhao, Qipeng Zhao, Cong Yue, Xinrui Zhang, Zhengliang Yang, Kyle Richardson, Zhenzhong Lan. CLUE: A Chinese Language Understanding Evaluation Benchmark. arXiv:2004.05986v3 [cs.CL]

[10] Chen, W., Yang, K., Yu, Z. et al. A survey on imbalanced learning: latest research, applications and future directions. *Artif Intell Rev* 57, 137 (2024). <https://doi.org/10.1007/s10462-024-10759-6>

[11] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer(2011).SMOTE: Synthetic Minority Over-sampling Technique. arXiv:1106.1813v1 [cs.AI]

[12] Yuan, Mengqi & Xu, Jinke & Li, Zhongnian. (2019). Long Tail Multi-label Learning. 28-31. 10.1109/AIKE.2019.00013.

[13] Jason Wei, Kai Zou(2019). EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks. arXiv:1901.11196v2 [cs.CL]

[14]Xu, Pengyu, et al. "Label-specific feature augmentation for long-tailed multi-label text classification." *Proceedings of the AAAI conference on artificial intelligence*. Vol. 37. No. 9. 2023.