

阅读作业1: JM Book Ch 6

1. 摘要部分

1.1 人工撰写

王殿云 2022211733号 2022219107版

向量语义学是自然语言处理领域中表征词义的一种基本方法,其灵感来源于分布假说,即出现在相似语境中的词往往具有相似的意义。本章从这一语言学假说入手,探讨如何通过直接从文本分布中学习词义表征(称为词嵌入)来实例化这一假说。

本章首先讨论了词汇语义学这一研究词义的语言学分支。一个恰当的词义模型应该捕捉多个方面:具有相似意义的词、反义词、具有积极或消极内涵的词,以及从不同角度描述同一事件的词。该模型还应表征词的不同词义。除了简单的相似性,词还可以表现出相关性、属于语义场或参与语义框架。

向量语义学将一个词表示为多维语义空间中的一个点,该空间源自词的分布。本章描述了两种主要方法:基于词-文档矩阵或词-词矩阵的稀疏向量(使用tf-idf或PPMI加权)和稠密向量(如word2vec)。

在稀疏向量的构建中,主要介绍了两种方法:词-文档矩阵和词-词矩阵。词-文档矩阵将每个词表示为一个向量,其中每个维度对应一个文档,而词-词矩阵则将每个维度表示为一个上下文词。为衡量这些向量之间的相似性,本章介绍了余弦相似度方法,它计算两个向量之间的夹角余弦值。同时,由于原始频率向量存在局限性,本章介绍了加权方案。对于词-文档矩阵,使用tf-idf加权,它结合了词频和逆文档频率,给予在特定文档中频繁但在整体上罕见的词(如"Romeo")更高的权重。对于词-词矩阵,使用正点互信息(PPMI),衡量两个词共现频率比随机预期高出多少,有助于识别与目标词强烈关联的词。

稠密向量上,本章介绍了word2vec,特别是带负采样的skip-gram(SGNS),该方法能创建短而稠密的向量。与基于计数的方法不同,word2vec采用自监督方法,通过预测一个词是否出现在目标词附近来训练嵌入。其数学原理是使用词向量点积经sigmoid函数转换来计算概率,通过随机梯度下降调整嵌入。本章还提到fasttext通过使用带字符n-gram的子词模型来解决未知词问题,GloVe通过共现概率比捕捉全局语料库统计信息。

可视化高维嵌入可以通过列出与目标词最相似的词、使用层次聚类或t-SNE等降维技术将嵌入投影到二维空间来实现。这些可视化显示具有相似意义的词如何聚集在一起,正面词、负面词和中性功能词分别形成不同的区域。历史语义学通过从不同时代构建嵌入空间,可追踪词义随时间的变化。同时,教材中也指出嵌入也会重现并放大训练数据中的偏差,导致分配伤害和表征伤害。

总之,向量语义学基于文本分布模式提供了强大的词义表征。无论是稀疏模型还是稠密嵌入,它们都能捕捉语义关系,尽管存在偏差、评估等挑战,但支持了众多自然语言处理应用。

1.2 AI总结

Prompt:

下边文件中是Vector Semantics and Embeddings这一章节的内容。请阅读该章节，撰写一篇中文摘要总结。请使文字风格更丰富、更具细致性、教育性、谦逊、专业和友好，并且使用成段的说明和论述，尽量避免使用低级的连词。

Claude 3.7 Sonnet(Extended thinking):

Vector语义与嵌入技术：自然语言处理的基石

《Vector Semantics and Embeddings》章节全面阐述了向量语义学在自然语言处理中的基础理论与应用实践。该章节深入探讨了如何将单词的意义表示为多维空间中的向量（即嵌入），并通过这些向量之间的关系来捕获单词之间的语义相似性和关联性。

章节开篇引用了庄子的"得鱼而忘荃，得意而忘言"来比喻单词仅是获取意义的工具，以及一个关于趋同进化的生动例子，引出了分布式假设（distributional hypothesis）这一核心概念：在相似语境中出现的单词往往具有相似的含义。这一假设最早由20世纪50年代的语言学家提出，认为单词的意义可以从其在文本中的分布情况推断得出。

向量语义学将单词表示为高维空间中的点，这些表示形式（嵌入）直接从单词在文本中的分布中学习得到。章节详细介绍了两类主要的向量模型：

- 1. 稀疏向量模型：**包括词-文档矩阵和词-词矩阵，其中每个维度对应词汇表中的一个单词或文档集合中的一个文档。这类模型通常采用tf-idf或PPMI（点互信息）等权重计算方法来确定向量中各维度的值。
- 2. 密集向量模型：**如word2vec，这类模型生成低维度（通常为50-1000维）的密集向量，比稀疏向量在各种NLP任务中表现更佳。章节详细解释了skip-gram模型的工作原理，它通过训练一个二分类器来预测词与其上下文的共现关系，并使用学到的权重作为词嵌入。

向量之间的相似度通常使用余弦相似度计算，该方法基于向量的点积，能有效衡量向量方向的接近程度，从而反映单词语义的相似程度。

本章还探讨了词嵌入的多种语义特性，包括它们捕获同义关系、上下位关系以及进行类比推理的能力。例如，著名的"king - man + woman $\approx$ queen"展示了向量空间能够捕获复杂的语义关系。此外，章节还讨论了词嵌入中存在的偏见问题，以及如何使用历史文本中训练的嵌入来研究语义随时间的变化。

在评估方面，章节介绍了内在评估（如相似度测试、类比任务）和外在评估（在实际NLP任务中的表现）两种方法，以及一些著名的评估数据集如WordSim-353和SimLex-999。

通过这一章节，读者能够深入理解向量语义学的理论基础、计算方法和应用场景，认识到它作为现代NLP技术基础的重要性。这些表示学习方法不仅能自动从文本中学习有用的表示，还为后续更强大的语境化嵌入模型（如BERT）奠定了基础。

ChatGPT 4o:



在本章《向量语义与嵌入》中，我们探索了如何通过向量表示词语的意义，尤其是在自然语言处理中，词语嵌入是如何通过它们在文本中的分布来实现的。向量语义模型的核心思想基于“分布假设”（distributional hypothesis），该假设认为词语的意义可以通过它们在语言中的上下文关系来定义。1950年代，语言学家们如Joos、Harris和Firth等首次提出了这一假设，认为具有相似上下文的词语通常具有相似的意义。

词语的向量表示，也被称为嵌入（embeddings），是一种多维空间中的点，用于捕捉词语之间的语义相似性。向量模型包括稀疏模型和密集模型。稀疏模型如tf-idf和PPMI（点对点互信息）是基于词语共现频率构建的，而密集模型（如Word2Vec）通过更紧凑的向量表示词语，通常维度较低（例如50到1000），且更适合捕捉词义的细微差别。

本章详细介绍了如何使用Word2Vec等工具生成这些密集嵌入。Word2Vec通过跳字模型（skip-gram）训练一个分类器，学习词语嵌入，使得在给定的上下文中，相关词语的嵌入会更接近。这种方法不仅提升了计算效率，而且也在各种NLP任务中展现出优异的表现，尤其是在情感分析、语义匹配等应用中。

通过使用嵌入，模型能够更好地理解词语之间的相似性，进而进行任务如问答、文本摘要等。该模型的一个关键优点是能够自动从大量文本数据中学习到有用的词语表示，避免了传统的手工特征工程。

此外，向量语义模型还能够捕捉到词语间的关系性，诸如类比关系。例如，模型可以通过向量的加减运算来解决类似“国王是男人，女人是怎样？”的类比问题，证明了嵌入在处理语言关系中的强大能力。

总结来说，向量语义和词语嵌入为自然语言处理提供了强有力的工具，使得机器可以更加精准地理解语言的含义及其背后的语义关系。通过学习这些向量，NLP系统能够高效地进行文本分析和理解任务，并在许多实际应用中取得了显著的成功。

DeepSeek（深度思考）：



向量语义与词嵌入技术深度解析

一、语义表征的哲学基础与技术演进

本章以庄子“得鱼忘筌，得意忘言”的哲学思想为引，揭示了语义理解的本质在于超越符号表层。这一思想与现代自然语言处理的向量语义模型形成跨时空呼应。20世纪50年代Joos、Harris等学者提出的“分布假说”奠定了理论基础：词语的语义由其上下文分布决定。Osgood于1957年通过三维情感空间（效价、唤醒度、支配性）量化词义，开创了向量语义的先河。

二、词汇语义学的多维解析

2.1 词义关系的层次结构

- **同义性与近似性**：真正的绝对同义词几乎不存在，原则性差异理论指出语言形式的差异必然伴随语义差异。例如"car/automobile"虽可互换，但存在语域差异。
- **相似性与关联性**：相似性基于特征重叠（如"猫/狗"的生物属性），关联性则源于共现事件（如"咖啡/杯子"的饮用场景）。语义场理论（如医疗、餐饮领域）揭示了词语在特定主题下的结构化关联。
- **语义框架与角色**：动词"buy/sell/pay"共享商业交易框架，通过施事、受事等语义角色实现多视角表征，支持语义推理与复述生成。

2.2 情感语义的量化建模

Osgood的三维情感模型通过向量空间定位词语的隐含情感：

- 效价维度区分积极（courageous=8.05）与消极（heartbreak=2.45）
- 唤醒度捕捉情感强度（excited=5.5 vs calm=3.95）
- 支配性体现控制程度（controlling=7.38 vs awed=3.58）

三、向量语义模型的技术实现

3.1 共现矩阵的构建策略

- **术语-文档矩阵**：行表示词项，列表示文档，单元格记录词频。适用于文档分类与信息检索。
- **术语-术语矩阵**：采用滑动窗口（±4词）统计共现频率，更精细捕捉词语搭配模式。如图6.6显示"cherry/strawberry"与"pie/sugar"的高共现性。

3.2 权重优化算法比较

3.3 词嵌入模型的突破

Word2vec的Skip-Gram模型通过二元分类任务学习分布式表征：

- 正样本：目标词与真实上下文词对（如"apricot-jam"）
- 负采样：随机选取k个噪声词（如"apricot-aardvark"）

· 优化目标函数：
$$L = -\log \sum c_{\text{pos}} \cdot w + \sum \log \sum (-c_{\text{neg}} \cdot w)$$

采用SGD更新参数，最终获得300维稠密向量。实验表明，窗口大小±2时捕获语法相似性，±5时侧重主题关联性。

四、应用与评估体系

4.1 核心应用场景

- **文档相似度计算**：通过向量质心 ($d = \frac{1}{k} \sum w_i$) 与余弦相似度实现跨文档比对
- **语义类比推理**：向量平移模型解决 "king - man + woman $\approx$ queen" 式关系推理
- **历时语义演化**：通过不同时期语料训练嵌入，追踪词义变迁（如 "gay" 从 "快乐" 到 同性恋含义）

4.2 评估方法与挑战

- **内在评估**：WordSim-353（词对相似度）、TOEFL（同义词选择）、SCWS（上下文敏感相似度）
- **外在评估**：在下游任务（情感分析、机器翻译）验证嵌入质量
- **社会偏见问题**：嵌入可能放大语料中的性别/种族偏见（如 "程序员 $\rightarrow$ 男性 + 主妇" 类比），需通过降维去偏技术改进

五、技术局限与发展方向

当前模型仍面临三大挑战：

1. 静态嵌入无法处理一词多义（如 "mouse" 的啮齿类/设备义项）
2. 低频词/新词的表征不足（FastText通过子词n-gram缓解）
3. 社会偏见的系统性消除（需结合知识图谱与伦理约束）

未来趋势指向动态上下文嵌入（如BERT）与多模态融合，以及更细粒度的历时语义建模。这些发展将推动NLP系统在保持语言复杂性的同时，实现更精准、公平的语义理解。

（注：本总结基于文档提供的技术细节，部分示例与数据引用原文图示与表格内容，力求准确还原技术脉络。）

1.3 差异对比

我写的摘要采用简洁明了的段落结构，按照原文章节顺序介绍向量语义学的基本概念、稀疏向量方法、稠密向量方法和应用评估，结构清晰，语言风格朴实直接，比较利于直接获取信息。

大模型摘要（尤其是DeepSeek和Claude）就采用了更系统化的结构，分点展开。尤其是DeepSeek，采用了多级标题结构，将内容细分为"语义表征的哲学基础"、"词汇语义学的多维解析"等主题块，语言风格也比较学术。同时，我发现大模型还有时会超出原文范围添加额外信息（或是对原文理解不到位），例如DeepSeek提出的"程序员→男性+主妇"这个例子和原文表述就有点出入，存在一定的幻觉。

2. 问题部分

在阅读本章节内容时，我注意到6.8.3一节中的以下内容：

原文：It turns out that dense embeddings like word2vec actually have an elegant mathematical relationship with sparse embeddings like PPMI, in which word2vec can be seen as implicitly optimizing a function of a PPMI matrix (Levy and Goldberg, 2014c).

翻译：

原来密集嵌入（如word2vec）与稀疏嵌入（如PPMI）之间存在一种优雅的数字关系，其中word2vec可以被视为隐式优化PPMI矩阵的函数（Levy和Goldberg，2014c）。

该部分的证明引起了我的兴趣。因此，我找到了其中引用的论文（Levy, O. and Y. Goldberg. 2014c. Neural word embedding as implicit matrix factorization. NeurIPS.），与Claude 3.7 Sonnet(Extended thinking) 对话，解答了相关疑惑。

2.1 对话流

Claude 3.7 Sonnet(Extended thinking)



熵的表达式为

$$I = \sum_{i=1}^n \sum_{j=1}^n p(x_i, y_j) \log p(x_i, y_j) = \sum_{i=1}^n p(x_i) [H - \sum_{j=1}^n p(y_j|x_i) \log p(y_j|x_i)]$$

3. 条件熵熵值

条件熵度量条件熵值

$$\begin{aligned} H_{Y|X} &= -\sum_{i=1}^n p(x_i) \sum_{j=1}^n p(y_j|x_i) \log p(y_j|x_i) \\ &= -\sum_{j=1}^n p(y_j) \log p(y_j|x_i) = -\sum_{i=1}^n \sum_{j=1}^n \frac{p(x_i, y_j)}{p(x_i)} \log p(y_j|x_i) \end{aligned}$$

4. 联合熵熵值

联合熵度量联合熵，度量系统X和系统Y的联合熵熵值

$$H(X, Y) = -\sum_{i=1}^n \sum_{j=1}^n p(x_i, y_j) \log p(x_i, y_j) = -\sum_{i=1}^n p(x_i) \left[-\sum_{j=1}^n p(y_j|x_i) \log p(y_j|x_i) \right]$$

联合熵与熵熵值相等，度量了系统X和Y的联合熵熵值

5. 互熵熵值

互熵度量系统X和系统Y，度量系统X和Y的互熵熵值

$$\frac{\partial I}{\partial x_i} = p(x_i, y_j) \log p(x_i, y_j) + 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} - p(x_i)$$

互熵熵值等于，度量了系统X和Y的互熵熵值

$$p(x_i, y_j) \log p(x_i, y_j) = 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} - p(x_i)$$

熵熵值等于1 - p(x_i)，度量熵值

$$p(x_i, y_j) \log p(x_i, y_j) = 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} - p(x_i)$$

$$p(x_i, y_j) \log p(x_i, y_j) = 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} - p(x_i)$$

$$p(x_i, y_j) \log p(x_i, y_j) = 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} - p(x_i)$$

$$p(x_i, y_j) \log p(x_i, y_j) = p(x_i) \left(p(x_i, y_j) + 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i} \right)$$

$$p(x_i) = \frac{p(x_i, y_j)}{p(x_i, y_j) + 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}}$$

6. 互熵熵值

互熵熵值度量系统X和系统Y，度量熵值

$$\frac{1}{1 + x} = \frac{p(x_i, y_j)}{p(x_i, y_j) + 1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}}$$

互熵熵值度量系统X和系统Y，度量熵值

$$x = \frac{p(x_i, y_j)}{1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}}$$

$$x = \log \left(\frac{p(x_i, y_j) \cdot \frac{\partial I}{\partial x_i}}{1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}} \right)$$

$$x = \log \left(\frac{p(x_i, y_j) \cdot \frac{\partial I}{\partial x_i}}{1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}} \right) = \log 2$$

7. PMF互熵熵值

互熵熵值，度量了系统X和系统Y的互熵熵值

$$PMF(x_i, y_j) = \log \left(\frac{P(x_i, y_j)}{P(x_i)P(y_j)} \right) = \log \left(\frac{p(x_i, y_j) \cdot \frac{\partial I}{\partial x_i}}{(1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}) \cdot (1 - p(y_j) \cdot \frac{\partial I}{\partial y_j})} \right) = \log \left(\frac{p(x_i, y_j) \cdot \frac{\partial I}{\partial x_i}}{1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}} \right)$$

互熵，度量了系统X和系统Y的互熵熵值

$$x = \log \left(\frac{p(x_i, y_j) \cdot \frac{\partial I}{\partial x_i}}{1 - p(x_i) \cdot \frac{\partial I}{\partial x_i}} \right) = \log 2$$



2.2 答案总结

通过上述对话，我理解了SGNS的本质正是对自然语言处理中经典的点互信息(PMI)矩阵的位移版本进行矩阵分解。

SGNS的训练过程通过最大化观察到的词-上下文对的向量点积，同时最小化随机采样的"负"词-上下文对的向量点积来进行。这个目标函数可以表示为：

$$\ell(w, c) = \#(w, c) \log \sigma(\vec{w} \cdot \vec{c}) + k \cdot \#(w) \cdot \frac{\#(c)}{|D|} \log \sigma(-\vec{w} \cdot \vec{c})$$

通过求导并令导数为零，可以求得最优点积值：

$$\vec{w} \cdot \vec{c} = \log \left(\frac{\#(w, c) \cdot |D|}{\#(w) \cdot \#(c)} \right) - \log k = \text{PMI}(w, c) - \log k$$

这表明SGNS隐式地分解了矩阵：

$$M_{ij}^{\text{SGNS}} = \vec{w}_i \cdot \vec{c}_j = \text{PMI}(w_i, c_j) - \log k$$

其中k是负采样数量，对应于PMI矩阵的一个常数位移。

这项研究优雅地揭示了神经词嵌入与传统分布式语义方法之间的深层联系，加深了我对word2vec等方法工作原理的理解。

2.3 答案评价

与Claude对话前，我也自己阅读了上文中提到的论文。论文本身的推导过程较为清晰明了，Claude较好地遵循了原文的论述与推导，并且提供了标准的Latex格式公式，并且为我快速摘取了我需要理解的关键步骤，还增加了自然语言说明。这份回答很好地帮助我解答了问题！