

自然语言处理课程实践 开题报告

来易卦，来一卦——基于文言文检索增强生成的易学咨询系统

1. 动机

【陶白星座】是一个结合大语言模型进行塔罗牌结果解析的产品，用户可以在小程序中免费抽取塔罗牌，通过小额消费（每次解读3元），来让大语言模型对牌面进行解析。查看财报，我们发现，这样一个简单的小程序，营收利率却远超Cursor这样复杂且实用的工具类产品。这让我们很快意识到在生成式人工智能服务领域中，【占卜算卦】类产品的用户具有极高的消费意愿。【算卦】类产品在国内具有更广泛的应用群体和更下沉的市场，但市面上的【算卦】类产品无论在产品完整度还是解读效果上，都远未达到饱和。

基于这个动机，我们在上周搭建了一个基于中国传统易学理论，结合LLM进行命理、卦象、运势分析的小程序，致力于将古老的易学智慧以现代化的方式呈现给用户，名为【易卦AI】。其功能特色包括：

- 黄历查询：每日宜忌、吉凶神煞、时辰吉凶等信息
- 起卦占卜：铜钱起卦、八卦解读、专业解析
- 个人运势：基于八字的个人运势分析
- 占卜问事：与虚拟道长对话，解析命理疑问

产品部分页面展示如图：





小程序**测试版**现已上线，目前所有功能都免费、免广告开放，可以通过以下二维码申请体验，也欢迎大家将小程序推荐给身边的人，我们的管理人员会给大家通过体验资格~



但是，目前大语言模型对传统易学、八字理论不甚了解，幻觉现象明显，而易学相关典籍卷帙浩繁，难以直接作为上文。因此，我们希望能够通过RAG技术来提供问题相关资料，缓解模型幻觉。同时，我们希望这个小程序能成为易学爱好者的启蒙工具，让易学爱好者了解如何将易学典籍中的知识应用于实际的卦象分析中去。

在这个背景下，我们希望构建一套**基于文言文检索增强生成的易学咨询系统**，使得模型可以检索并理解文言文，同时给出有命理依据的专业解析。

2. 题目

来易卦，来一卦——基于文言文检索增强生成的易学咨询系统

3. 任务描述

本项目旨在构建一个面向中国传统古籍文献的检索增强生成(RAG)任务的系统，以解决当前大语言模型在处理传统古籍内容时出现的幻觉问题。主要任务包括：

- 构建易学古籍知识库：**收集整理《周易》《三命通会》等28部重要易学经典文献，建立结构化的古籍数据库，并按照年代-领域-书目-文本的四级索引体系进行组织。
- 开发面向文言文的检索机制：**针对文言文特点设计专门的检索策略，包括文本预处理、向量化表示、混合检索策略和重排序模型等，以提高古文检索的准确性和相关性。
- 微调古文embedding和rerank模型：**基于古今对照语料，使用对比学习方法优化模型，提高对古文的表示能力和检索质量。
- 整合易学咨询问答系统：**整合检索结果与大语言模型，实现基于古籍依据的准确解析，为用户提供可靠的易学咨询服务。
- 设计性能评估体系：**基于C3Bench等benchmark，设计适合易学文本的评估指标，全面测试系统性能。

4. 预期目标

1. 技术目标：

- ☐ C3Bench评分：相较于通用RAG系统，提高古文检索的准确率至少10%
- ☐ RAG框架设计：文言文RAG系统架构设计，构建支持MCP协议的文言文RAG框架

2. 功能目标：

- ☐ 提供带有原文出处的专业解析，支持易学知识的溯源查证
- ☐ 优化小程序交互界面，让用户能看到原文引用，提升用户体验和可信度

3. 应用目标：

- ☐ 开发一个完整的易学咨询小程序原型系统
- ☐ 形成一套可扩展的古文RAG框架，支持未来扩展到其他古代文献领域
- ☐ 建立一个包含30本以上易学、玄学古籍条目的检索数据库

5. 相关工作

5.1 文言文检索与处理技术

文言文检索与现代文本检索存在本质区别，这直接塑造了整个研究领域的基础特性。文言文极度简洁，以单字词为主；词类功能高度灵活，同一字可在不同语境中充当不同词性；广泛使用省略，许多主语、宾语隐含于上下文；缺乏语法标记，没有时态、数量、性别等显性变化；使用复杂的敬语系

统；词汇与现代汉语存在显著差异；高度依赖典故和互文性。这些语言特点使得文言文检索需要完全不同的处理方法，无法简单套用现代中文NLP技术。

研究表明，即使是最先进的中文大语言模型，如未经专门训练，在处理文言文任务时也表现欠佳。例如，在WYWEB基准测试中，通用中文模型在文言文任务上的得分远低于专业模型，这凸显了专门化研究的必要性。

5.1.1 文言文句例与现代文句例对比

5.1.1.1 例1：词类功能灵活性

文言文：

「臣死且不避，卮酒安足辞？」

现代文：

「我连死亡都不会逃避，何况是一杯酒呢？怎么能推辞呢？」

分析：在文言文中，"辞"字既可作动词（推辞），也可作名词（言辞）。"安"字在此处不是表示安全，而是用作反问副词，意为"怎么"、"如何"。"足"不是脚的意思，而是表示"足够"、"值得"的动词。一个短句中多个字都体现了文言文词类功能的高度灵活性。

5.1.1.2 例2：省略现象

文言文：

「闻之，观其言而知其人。」

现代文：

「我听说过这样的道理，通过观察一个人说的话，就能了解这个人是什么样的人。」

分析：文言文中省略了主语"我"，也省略了"之"字后面的宾语（这样的道理）。文言文仅用8个字表达的内容，在现代文中需要30多个字才能完整表达，体现了文言文的极度简洁和广泛使用省略的特点。

5.1.1.3 例3：典故和互文性

文言文：

「十年寒窗，今朝金榜题名。」

现代文：

「经过多年刻苦学习，今天终于在科举考试中取得了成功。」

分析：文言文中的"寒窗"是典故，指代刻苦学习；"金榜题名"也是固定典故，指代科举考试成功。这些典故在文言文中常被简单引用，不需详细解释，但在现代文中需要更明确地表达。文言文的这种高度互文性和对典故的依赖，使得不懂相关背景知识的人难以理解其真正含义。

5.1.1.4 例4：缺乏语法标记

文言文：

「昔人已乘黄鹤去，此地空余黄鹤楼。」

现代文：

「从前的那个人已经骑着黄鹤离开了，这个地方只剩下了黄鹤楼。」

分析：文言文中没有时态标记，"已乘"表示完成时只通过"已"字简单表示；"空余"表示现在状态，但没有明确的时态标记。现代文中则通过"了"字等语法助词明确标示时态。

5.2 古文专用模型研究

目前我们调研到的，具有古文理解能力的大语言模型：

- **TongGu**：复旦大学与华南理工大学合作开发的古籍大语言模型，经过400GB精选古籍预训练和知识图谱融入，在C3Bench测试中综合得分达76.8分，特别擅长古籍上下文理解。
- **WenyanGPT**：专门针对文言文任务的大型语言模型，通过25万古今平行语料微调，在Classical-MBench评测中达到翻译准确率89.7%。

适合古文处理的Embedding模型：

- **GuwenBERT**：在古文数据集上微调的BERT模型，适用于古文文本表示和检索。
- **SinoBERT**：台湾中央研究院2023年底发布的专门针对古汉语的双向编码器，经过1亿古文语料预训练，在知识问答任务上比GuwenBERT提高了8.7个百分点。
- **RUCAIBox/Erya**：在古文翻译任务上微调的编解码框架模型。
- **BAAI/bge-large-zh-v1.5**：通用RAG专用Embedding模型，可通过适当微调应用于古文检索。

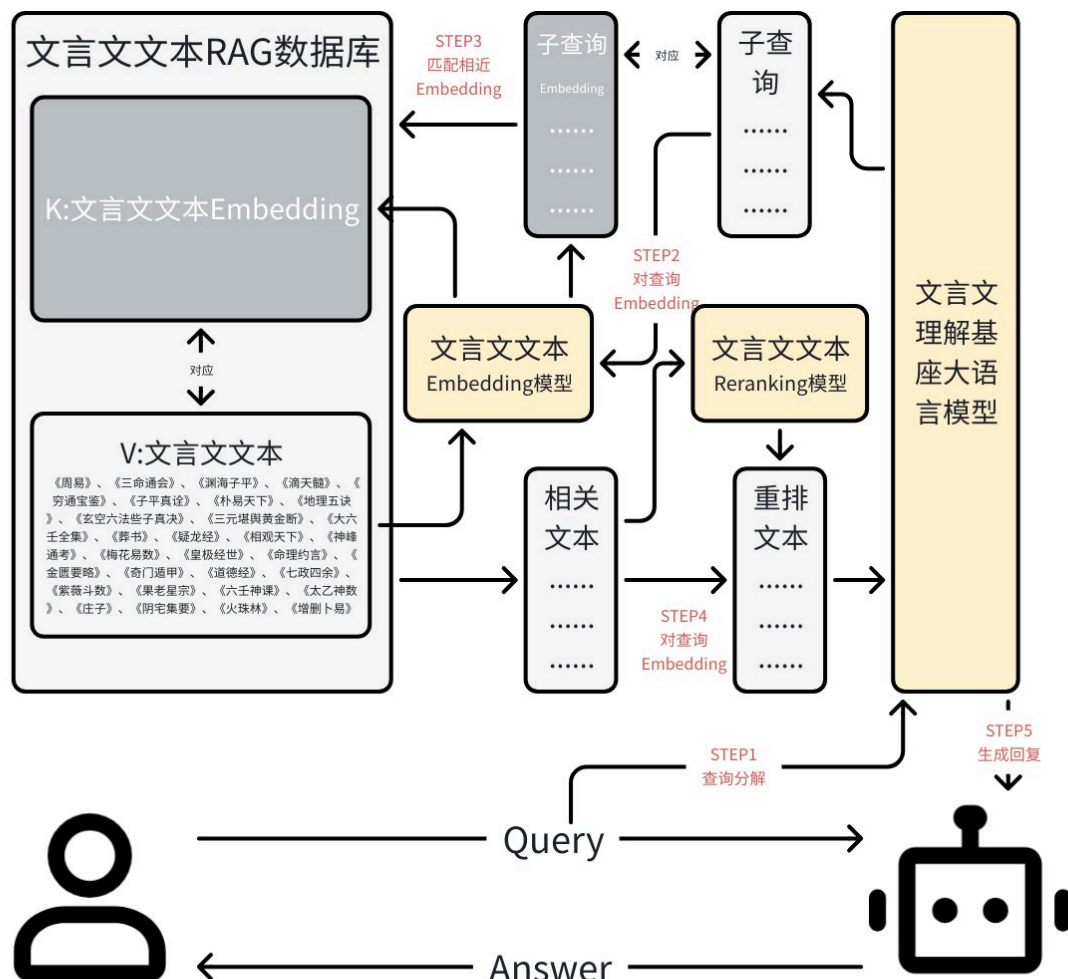
5.3 评估基准

C3Bench（Comprehensive Classical Chinese Benchmark）是2023年由复旦大学、北京大学和中科院计算所联合推出的首个全面评估古汉语理解能力的基准测试集。该测试包含五大任务类别：语义理解、文本分类、信息抽取、文本生成和跨时代语言处理。

测试语料涵盖先秦至民国的18个朝代，包括经、史、子、集四部典籍，难度分为初级、中级和高级三个等级。与其他中文评测基准相比，C3Bench的独特之处在于其历时性评估框架，可测量模型在不同历史时期文本的理解能力差异。

目前在C3Bench上表现最好的模型是TongGu（综合得分72.47分），其次是Qwen2-7B-Instruct（56.22分）和GLM4-9B-Chat（52.99分）。所有模型在先秦文献和诗词文本上表现较弱，这表明古文处理仍有很大的提升空间。

6. 技术方案



6.1 数据来源与处理

1. 易学古籍数据：

《周易》、《三命通会》、《渊海子平》、《滴天髓》、《穷通宝鉴》、《子平真詮》、《朴易天下》、《地理五诀》、《玄空六法些子真决》、《三元堪輿黄金断》、《大六壬全集》、《葬书》、《疑龙经》、《相观天下》、《神峰通考》、《梅花易数》、《皇极经世》、《命理约言》、《金匱要略》、《奇门遁甲》、《道德经》、《七政四余》、《紫薇斗数》、《果老星宗》、《六壬神课》、《太乙神数》、《庄子》、《阴宅集要》、《火珠林》、《增删卜易》

2. 数据处理流程：

- 文本数字化与标准化：统一文本格式，处理异体字和繁简转换
- 分段与标注：按章节、段落进行结构化分割，添加元数据标注（年代、作者、主题等）
- 平行语料构建：收集/生成部分古文-现代文平行语料，用于模型微调
- 四级索引构建：按年代-领域-书目-文本构建层级索引结构

6.2 评估方法

我们将采用C3Bench作为主要评估基准，重点关注古代哲学文本理解任务，主要关注与**该套框架在C3Bench任务中的检索准确率**。

6.3 文言文RAG系统架构设计

通过与历史学中国式方向的同学沟通，我们决定重新设计一套**适用于古文检索的四级索引架构**设计。同时，该RAG系统将以MCP的方式集成至问答系统中，模型可以自主调用工具生成索引，来检索相关文献。

6.3.1 支持MCP协议的RAG系统

MCP（Modular Capability Protocol，模块化能力协议）是一种使大语言模型能够主动识别调用需求并自动调用外部工具的协议框架。其核心特点包括：

- **自主调用**：模型能自动识别何时需要检索外部知识，无需用户明确指令
- **工具抽象**：将复杂功能封装为标准化接口，模型通过函数调用方式访问
- **结构化通信**：严格定义输入输出格式，确保模型与工具间可靠交互
- **上下文感知**：模型可根据对话历史和当前查询动态选择合适的工具参数

在文言文RAG系统中，MCP协议使模型能够在识别到需要古籍知识支持时，自动构造符合古文检索特点的查询请求，并将检索结果无缝整合到回答中。

在MCP架构下，文言文RAG系统的调用流程如下：

1. 模型分析阶段：

- 模型识别用户查询涉及易学古籍知识
- 确定是否需要外部文献支持
- 提取查询中的关键时空信息（朝代、学派等）

2. 工具调用阶段：

模型对问题生成如下的查询：

代码块

```
1  {
2      "name": "wenyanwen_retrieval",
3      "parameters": {
4          "query": "乾坤易理的定义是什么？",
5          "dynasty": "宋",
6          "domain": "义理",
7          "result_count": 3
8      }
9  }
```

3. 结果处理阶段：

- 模型解析检索返回的结构化数据
- 提取与用户查询最相关的文本片段
- 根据检索结果重新调整回答策略

4. 回答生成阶段：

- 融合模型知识与检索文本
- 适当引用原文，注明出处
- 根据用户需求提供解释或现代译文

6.3.2 四级索引架构设计

我们将采用年代-领域-书目-文本的四级索引结构，这种分层索引将采用"宽松到严格"的查询流程：

1. **年代索引**：将易学文献按历史朝代（先秦、汉、唐、宋、明、清等）分类，便于限定历史范围；
2. **领域索引**：按易学内部分支（如卜卦、命理、风水、奇门等）进行分类；
3. **书目索引**：具体到28部经典著作；
4. **文本索引**：段落级文本的向量化表示；

以上前三步由模型控制MCP协议给出索引，第四步是传统的基于Embedding的RAG文档检索方法。技术实现上，我们将采用PostgreSQL+pgvector作为向量数据库基础，结合Meta-data过滤与向量检索的混合查询机制。

6.3.3 Embedding 模型优化策略

我们将主要采用以下策略来优化Embedding模型的古文处理能力：

- 基础策略：


$$\max_{\theta} \mathcal{J}(\theta) = \cos(E_1, E_2) = \frac{E_1 \cdot E_2}{||E_1|| \cdot ||E_2||}$$

其中：

- E_1 表示古文的嵌入向量（古文Embedding结果）
- E_2 表示现代中文翻译的嵌入向量（现代文翻译Embedding结果）
- θ 表示模型参数
- $\cdot$ 表示点积操作
- $||E_1||$ 和 $||E_2||$ 是各自嵌入向量的L2范数
- $\cos(E_1, E_2)$ 是两个嵌入之间的余弦相似度

这个公式旨在最大化古文文本嵌入和其现代中文翻译嵌入之间的余弦相似度，有效地在嵌入空间中对齐两种文本的向量表示。

- 训练数据：使用TongGu开源的10000+对高质量古今平行语料
- 基础模型选择：SinoBERT、GuwenBERT或BGE-large-zh作为起点



6.4 系统整合与部署

系统将基于langchain框架、flask服务器架构与React前端架构整合以上组件，形成完整的易学咨询RAG系统：

1. 前端：微信小程序界面
2. 中间层：实现支持MCP协议的RAG检索引擎
3. 后端：易学古籍知识库和大语言模型API（gpt-4o、claude3.7、chatglm4等）

7. 开发环境

AutoDL租赁 4090*4 Ubuntu20.04 Pytorch

8. 组员分工及检查点

姓名	任务分工	检查点1	检查点2	检查点3	检查点4
王殿云	Embedding模型微调方法设计、完成小程序开	数据预处理完成	Embedding微调框架编写完成	MCP-RAG框架搭建	系统整合与测试

	发、RAG框架搭建				
王艺栋	设计Rerank模型微调方法并进行实验、协助RAG框架搭建	古今平行语料准备	Rerank模型实验	系统评估方案设计	系统整合与测试
王博涵	协助小程序开发、进行Embedding模型微调实验	古今平行语料准备	进行Embedding微调实验	Embedding实验结果分析	系统整合与测试

9. 时间安排

- 5.16：开题报告
- 5.16-5.23：数据收集与预处理，索引设计
- 5.23-5.30：模型微调实验
- 5.30：中期检查
- 5.30-6.10：MCP-RAG框架实现，系统整合
- 6.10-6.17：系统测试与优化，评估与分析
- 6.17-6.20：文档完善，结题准备
- 6.20：结题报告