

北京邮电大学人工智能学院

本科毕业设计（论文）开题报告

学院	人工智能学院		专业	人工智能	
学生姓名	王殿云	学号	2022211733	班级	2022219107
指导教师姓名	何召锋	所在单位	北京邮电大学	职称	教授
设计（论文）题目	（中文）大语言模型安全对齐的可解释性方法研究与实现				
	（英文）Research and Implementation of Interpretable Methods for Large Language Model Safety Alignment				

毕业设计（论文）开题报告内容：

一、选题的背景和意义

大语言模型（Large Language Models, LLMs）近年来在自然语言处理领域取得了突破性进展，以 GPT-4、Claude、Llama 等为代表的模型展现出强大的语言理解与生成能力，在文本摘要、代码生成、问答系统等任务中表现卓越。然而，这些模型在实际部署过程中面临着严峻的安全挑战：模型可能生成有害、偏见或虚假的内容，甚至在遭受对抗性攻击时产生危险输出。因此，如何使大语言模型的行为与人类价值观保持一致，即实现"安全对齐"（Safety Alignment），已成为人工智能领域亟待解决的核心问题。

当前主流的安全对齐方法主要包括基于人类反馈的强化学习（Reinforcement Learning from Human Feedback, RLHF）和直接偏好优化（Direct Preference Optimization, DPO）。RLHF 通过训练奖励模型并采用强化学习算法优化策略模型，使其生成符合人类偏好的响应；DPO 则将奖励模型隐式参数化，通过简单的分类损失直接优化策略模型，显著降低了训练复杂度。尽管这些方法在实践中取得了良好效果，但它们普遍存在一个根本性缺陷：对齐过程缺乏透明度。研究者难以理解对齐训练究竟改变了模型内部的哪些计算机制，也无法解释模型为何能够识别并拒绝有害请求。这种"黑盒"特性不仅阻碍了对齐方法的系统性改进，也给模型的安全审计和可信部署带来了挑战。

参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）方法的出现为大规模模型的适应性调整提供了新思路。其中，低秩适应（Low-Rank Adaptation, LoRA）因其简洁高效的特性而被广泛采用。LoRA 假设任务相关的权重更新存在于低秩子空间中，通过将权重更新参数化为低秩矩阵分解 $\Delta W=BA$ ，仅需训练少量参数即可实现有效的模型适应。近期研究表明，安全相关的模型行为可能由权重空间中的低秩结构所主导，这为通过子空间分析理解和控制安全对齐提供了理论基础。然而，

现有低秩适应方法面临两个基本局限：一是学习到的子空间不透明，优化过程隐式发现任务相关方向，无法提供语义层面的解释；二是 LoRA 与全参数微调之间持续存在性能差距，这通常被归因于可训练参数数量有限，但一个被忽视的因素是在多语义纠缠的表示空间中识别适当子空间的困难。

多语义性（Polysemanticity）是神经网络表示的一个基本特性，指单个神经元响应多个语义不相关的概念。根据叠加假说（Superposition Hypothesis），大语言模型编码的语义特征数量远超其维度数，导致特征以非正交方式叠加表示。这种语义纠缠使得直接在模型隐藏空间中分离与特定任务相关的子空间变得困难。机械可解释性（Mechanistic Interpretability）领域的最新进展为解决这一问题提供了新工具。稀疏自编码器（Sparse Autoencoders, SAEs）能够将多语义的神经网络激活分解为高维稀疏特征空间，其中单个维度对应单语义概念。Anthropic 团队的研究表明，SAE 可以从 Claude 3 Sonnet 等生产级模型中提取数百万个可解释特征，这些特征涵盖从具体概念（如"金门大桥"）到抽象概念（如"代码漏洞"）的广泛语义范围，并且可以通过特征激活值操控来引导模型行为。

基于上述背景，本课题提出将稀疏自编码器与低秩适应方法相结合，构建可解释的安全对齐框架。核心思想是：利用预训练的 SAE 将模型的多语义表示分解为单语义特征空间，在该空间中识别与安全对齐行为相关的特征方向，然后利用这些特征对应的解码器方向构建显式的、可解释的低秩子空间，用于指导 LoRA 适配器的初始化和训练。这一方法具有双重优势：一方面，通过在 SAE 特征空间中进行分析，可以有效克服多语义性带来的子空间识别困难；另一方面，所构建的对齐子空间继承了 SAE 特征的语义可解释性，使研究者能够理解适配器学习调制了哪些语义概念。

本研究的意义体现在以下几个层面。从理论角度看，本工作建立了机械可解释性与参数高效微调之间的桥梁，为理解低秩适应的工作机制提供了新视角，并从 Cover 定理的角度为 SAE 特征空间中子空间识别的可行性提供了理论支撑。从方法角度看，本工作提出了一种新颖的 SAE 引导的低秩子空间构建方法，将可解释性直接嵌入微调过程，而非仅作为事后分析工具。从应用角度看，本方法有望在保持参数高效性的同时实现优异的安全对齐性能，并为模型安全审计提供可解释的依据。这对于推动可信人工智能的发展具有重要的理论价值和实践意义。

二、研究的基本内容

内容一：调研大语言模型安全对齐与可解释性技术的研究现状，系统学习稀疏自编码器与参数高效微调的理论基础

大语言模型的安全对齐旨在确保模型能够识别并拒绝有害请求，同时在良性输入上保持有用性。本课题首先需要系统调研该领域的研究进展，包括 RLHF、DPO 等对齐方法的原理与局限，以及近

期关于对齐机制的理论分析工作。在可解释性方面，需要深入理解机械可解释性的基本范式，特别是线性表示假说和叠加假说的理论内涵，掌握稀疏自编码器如何通过稀疏字典学习将模型的多语义激活分解为单语义特征。同时需要研读 Anthropic 的"Scaling Monosemanticity"系列工作，了解 SAE 在生产级模型上的应用效果和特征解释方法。在参数高效微调方面，需要掌握 LoRA 及其变体（如 AdaLoRA、DoRA）的数学原理，理解低秩假设的理论基础，并重点关注近期关于 LoRA 非对称性的研究发现，即 B 矩阵在适应过程中起主导作用这一现象，这为本课题的方法设计提供了重要依据。

本内容对毕业要求指标点的支撑： 本阶段工作要求针对大语言模型安全对齐这一复杂工程问题，识别其在实际部署中面临的安全性、可控性与可解释性等多重约束条件，明确研究目标与技术需求，支撑指标 2.1。需要运用数学和工程科学原理分析稀疏表示理论与低秩分解的基本原理，建立理论分析框架，支撑指标 2.2。需要充分利用学术文献检索工具，系统调研 AI 对齐、机械可解释性等领域的前沿研究成果，支撑指标 5.1。

支撑毕业要求指标点：✓2.1 ✓2.2 □2.3 □4.1 ✓5.1 □5.2 □6.2 □7.1 □10.1 □11.2 □12.1

内容二：设计基于稀疏自编码器的激活收集与对齐相关特征识别方案

本课题的核心技术贡献之一是提出一种基于 SAE 的安全相关特征识别方法。具体而言，需要构造对齐与非对齐响应的对比数据集，在相同提示下收集模型生成安全拒绝与有害响应时的内部激活。利用预训练的 SAE（如 Gemma Scope 或 Llama Scope）将这些激活编码为稀疏特征表示，然后通过统计分析识别在两种条件下激活模式显著不同的特征。特征识别的关键在于设计合适的差异度量指标，本课题拟采用激活均值差异结合相对变化百分比的复合指标，以捕获对齐状态变化时响应最敏感的特征子集。此外，还需要进行层选择分析，确定哪些 Transformer 层编码了最具判别性的安全相关信息，这将指导后续子空间构建的目标层选择。通过 PCA 可视化等方法验证所识别特征的有效性，观察对齐与非对齐样本在特征空间中的分布模式。

本内容对毕业要求指标点的支撑： 本阶段工作需要针对已建立的理论框架，论证使用 SAE 提取对齐相关特征的合理性与可行性，支撑指标 2.3。需要采用科学方法设计实验方案，包括数据集构造、激活收集策略、统计分析方法的选择，支撑指标 4.1。需要合理选择和使用深度学习框架、SAE 工具库等技术资源，支撑指标 5.1。

支撑毕业要求指标点：□2.1 □2.2 ✓2.3 ✓4.1 ✓5.1 □5.2 □6.2 □7.1 □10.1 □11.2 □12.1

内容三：实现基于对齐子空间引导的低秩适应训练方法

基于识别出的安全相关特征，本课题需要构建显式的可解释对齐子空间并将其用于指导 LoRA 训练。首先，提取所识别特征对应的 SAE 解码器方向向量，这些向量代表了原始表示空间中语义一

致的方向。由于所选特征数量可能较多且存在冗余，采用主成分分析（PCA）进行降维，保留解释大部分方差的主要方向。随后通过 QR 分解获得一组正交基向量，形成对齐相关子空间的标准正交基表示。基于 LoRA 非对称性的研究发现，本课题提出使用该子空间基向量初始化 LoRA 的 B 矩阵，为优化提供有语义基础的起点。此外，设计可选的子空间约束损失函数，通过惩罚落在对齐子空间正交补空间中的激活分量，鼓励模型表示保持在安全相关方向附近。完成算法实现后，需要在标准深度学习框架中进行系统集成与测试，确保方法的正确性和效率。

本内容对毕业要求指标点的支撑： 本阶段工作需要运用现代深度学习开发工具完成系统实现，包括子空间构建、LoRA 初始化策略设计、损失函数实现等，支撑指标 5.2。在方案设计与实现过程中需要考虑计算资源消耗，通过参数高效方法降低训练成本，遵循可持续发展理念，支撑指标 7.1。需要在多学科交叉背景下合理规划项目进度与资源分配，支撑指标 11.2。

支撑毕业要求指标点：□2.1 □2.2 □2.3 □4.1 □5.1 ✓5.2 □6.2 ✓7.1 □10.1 ✓11.2 □12.1

内容四：在标准安全基准测试集上进行实验验证与性能评估

本课题需要设计全面的实验方案验证所提方法的有效性。实验将在多个模型规模和家族上进行，包括 Gemma 2 2B、Gemma 2 9B 和 Llama 3.1 8B 等开源模型。训练数据采用 HH-RLHF 数据集中的红队攻击子集，筛选模型成功维持安全行为的高质量对齐样本。评估指标包括：安全性指标（有害性评分、安全率、高风险率），使用 GPT-4 作为评判器；泛化性指标，在 HEx-PHI 等分布外安全基准上测试；鲁棒性指标，使用 GCG 等对抗攻击方法评估模型抵抗越狱攻击的能力；能力保持指标，在 ARC、HellaSwag、WinoGrande、BoolQ 等通用基准上评估。通过与全参数微调、标准 LoRA、DoRA、提示防御等基线方法的系统对比，分析本方法在不同场景下的性能优势与局限。此外，进行深入的可解释性分析，利用 Neuronpedia 等工具获取所识别特征的自然语言解释，验证特征选择的语义合理性；通过特征干预实验验证所识别特征的因果相关性。最后，分析子空间在训练过程中的保持程度，理解初始化引导与约束损失的作用机制。

本内容对毕业要求指标点的支撑： 本阶段工作需要全面评估所提方法对社会、安全、法律等方面的潜在影响，分析可解释安全对齐技术对提升 AI 系统可信度的作用，支撑指标 6.2。需要以规范的学术论文形式呈现研究成果，清晰阐述研究背景、方法设计、实验结果与分析结论，支撑指标 10.1。在整个研究过程中需要持续跟踪可解释 AI 与大语言模型安全领域的最新进展，培养终身学习能力，支撑指标 12.1。

支撑毕业要求指标点：□2.1 □2.2 □2.3 □4.1 □5.1 □5.2 ✓6.2 □7.1 ✓10.1 □11.2 ✓12.1

三、拟解决的主要问题

本课题围绕大语言模型安全对齐的可解释性这一核心目标，拟解决以下三个关键科学问题：（1）多语义表示空间中安全相关子空间的识别问题

科学问题一：多语义纠缠表示中安全特征的精准识别与可解释因果归因问题

大语言模型的隐藏表示空间存在严重的语义纠缠（semantic entanglement）现象，单个神经元同时编码多个语义不相关的概念，导致安全相关特征与其他语义特征相互叠加、难以分离。现有安全对齐方法以端到端方式隐式修改模型参数，研究者无法理解对齐训练究竟改变了模型内部的哪些计算机制，也无法确认模型的安全行为是否由真正的安全语义理解所驱动。因此，如何突破多语义纠缠表示中安全特征的精准识别与语义解耦，建立从特征激活到对齐行为的可解释因果关联，是实现可解释安全对齐的首要基础问题。本课题拟利用稀疏自编码器（SAE）将模型纠缠的语义空间解耦为独立的单语义特征，通过对比对齐与非对齐样本的特征激活差异精准识别安全相关特征，并借助因果干预实验验证所识别特征与安全行为之间的因果关联，从而为后续的子空间构建与对齐训练提供可解释的语义基础。

科学问题二：可解释正交对齐子空间的构建与对抗鲁棒性保障问题

现有安全对齐方法习得的安全行为停留在表层模式匹配层面，缺乏对安全相关特征的精确定位与可靠干预手段，易被越狱攻击（jailbreak attack）等对抗性手段绕过。即使部分研究发现了安全行为的低秩结构特征，其从权重空间推导的子空间仍缺乏激活空间层面的语义可解释性，无法提供深层语义安全约束。因此，如何从解耦的安全特征方向构建可解释的正交对齐子空间，并确保其在对抗攻击下维持深层语义安全约束能力，是实现鲁棒安全对齐的关键问题。本课题拟从 SAE 解码器中提取安全特征对应的语义方向，通过 PCA 降维与 QR 分解构建具有明确语义基础的正交安全子空间，使安全机制从不可解释的隐式参数修改转变为显式的、可审计的子空间约束，并通过 GCG 等对抗攻击基准验证该子空间在对抗条件下的鲁棒性。

科学问题三：子空间引导的参数高效安全对齐与通用能力保持问题

参数高效微调方法（如 LoRA）在安全对齐任务上与全参数微调之间存在持续的性能差距，其根本原因在于标准 LoRA 的随机初始化在多语义纠缠的表示空间中可能收敛到次优解，无法捕获真正的安全相关子空间。与此同时，安全对齐训练还面临通用能力退化的风险，即模型在获得安全行为的同时可能丧失语言理解与生成等基础能力。因此，如何利用可解释对齐子空间引导低秩适应的参数更新，弥合参数高效微调与全参数微调的安全性能差距，同时避免通用能力退化，是实现高效可解释安全对齐的核心问题。本课题拟以安全子空间的正交基向量初始化 LoRA 的 B 矩阵，将隐式的

子空间搜索替换为显式的、有语义基础的子空间构建，并设计可选的子空间约束损失与能力保持数据混合策略，在安全性能、参数效率与通用能力之间实现最优平衡。

四、研究方法及措施

本课题采用理论分析与实验验证相结合的研究方法，具体包括：

（1）文献调研与理论分析

通过系统的文献调研建立对研究领域的全面认识，重点研读 Anthropic、OpenAI 等机构的技术报告和顶级会议论文，掌握稀疏自编码器、低秩适应、安全对齐等关键技术的最新进展。在此基础上，从数学角度分析 SAE 特征空间中子空间识别的可行性，建立 Cover 定理与特征可分性之间的理论联系，为方法设计提供理论支撑。同时分析 LoRA 非对称性现象的成因，理解 B 矩阵在定义输出子空间中的关键作用，为子空间引导策略提供依据。

（2）模块化系统设计与实现

采用模块化设计思想构建实验系统，主要包括：激活收集模块，负责在模型推理过程中提取指定层的隐藏状态；特征分析模块，实现 SAE 编码、差异统计、特征筛选等功能；子空间构建模块，完成 PCA 降维、QR 分解、投影矩阵计算；训练模块，实现子空间引导的 LoRA 初始化和可选的约束损失；评估模块，集成多种安全和能力评估基准。各模块采用标准接口设计，便于独立测试和灵活组合。实现基于 PyTorch 框架，充分利用现有开源工具库（如 HuggingFace Transformers、PEFT）加速开发。

（3）系统性实验与对比分析

设计全面的实验方案验证方法有效性。首先进行消融实验，分析各组件（子空间初始化、约束损失）的独立贡献；然后进行超参数敏感性分析，包括层选择、特征数量、SAE 宽度、LoRA 秩等；最后与多种基线方法进行公平对比，涵盖不同模型规模和家族。实验结果将从统计显著性角度进行分析，确保结论的可靠性。

（4）可解释性验证与案例分析

通过多种方法验证所提方法的可解释性。利用 Neuronpedia 等工具获取 SAE 特征的自然语言解释，评估特征选择与安全概念的语义一致性；设计特征干预实验，通过放大或抑制特定特征的激活值观察模型输出变化，验证因果相关性；进行子空间漂移分析，量化训练前后 B 矩阵张成子空间的变化程度。选取典型案例进行深入分析，展示方法的实际应用效果。

五、研究工作的步骤与进度

进度安排：

第 1 阶段（2025.11.20—2025.12.8）： 明确课题目标与研究范围，广泛查阅国内外相关文献，深入了解大语言模型安全对齐与可解释性技术的研究背景与发展现状，完成开题报告撰写。

第 2 阶段（2025.12.9—2025.12.31）： 系统学习稀疏自编码器的理论原理与实现方法，研读 Anthropic "Towards Monosemanticity"和"Scaling Monosemanticity"系列工作，掌握 SAE 在大语言模型可解释性研究中的应用范式。同步学习 LoRA 等参数高效微调技术，理解低秩假设的数学基础。

第 3 阶段（2026.1.1—2026.1.20）： 搭建实验环境，配置所需的计算资源和软件依赖。设计并实现激活收集模块，构造对齐与非对齐提示对，选择合适的安全基准数据集（如 HH-RLHF 红队子集），完成模型激活数据的采集工作。

第 4 阶段（2026.2.24—2026.3.16）： 实现对齐相关特征识别算法，包括 SAE 编码、统计差异分析、特征排序与筛选等功能。进行层选择分析实验，确定最优目标层配置。完成对齐子空间构建，实现 PCA 降维和 QR 分解，获得正交基表示。

第 5 阶段（2026.3.17—2026.4.6）： 实现子空间引导的 LoRA 初始化与训练方法，设计并实现可选的子空间约束损失函数。在标准安全基准上进行初步实验验证，与基线方法进行对比分析。根据实验结果进行方法调优。

第 6 阶段（2026.4.7—2026.4.20）： 完成全面的性能评估与消融实验，进行可解释性分析和案例研究。整理实验结果，撰写论文初稿。准备毕业设计答辩材料，完成论文修改与定稿。

目前的完成状况：

目前已完成课题方向的确定和初步文献调研，对大语言模型安全对齐、稀疏自编码器、低秩适应等核心技术有了基本了解。已阅读 Anthropic 的"Scaling Monosemanticity"工作、LoRA 原始论文、Safe LoRA 等相关文献，对研究现状形成了初步认识。实验环境正在配置中，已申请所需的 GPU 计算资源。开题报告撰写完成，为后续研究工作奠定了基础。

六、主要参考文献

- [1] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations (ICLR). 2022.
- [2] Cunningham H, Ewart A, Riggs L, et al. Sparse Autoencoders Find Highly Interpretable Features in Language Models[C]//International Conference on Learning Representations (ICLR). 2024.

[3] Templeton A, Conerly T, Marcus J, et al. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet[J]. Anthropic Transformer Circuits Thread, 2024.

[4] Bricken T, Templeton A, Batson J, et al. Towards Monosemanticity: Decomposing Language Models with Dictionary Learning[J]. Anthropic Transformer Circuits Thread, 2023.

[5] Hsu C Y, Tsai Y L, Lin C H, et al. Safe LoRA: The Silver Lining of Reducing Safety Risks When Finetuning Large Language Models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2024.

[6] Rafailov R, Sharma A, Mitchell E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.

[7] Ouyang L, Wu J, Jiang X, et al. Training Language Models to Follow Instructions with Human Feedback[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022: 27730-27744.

[8] Elhage N, Hume T, Olsson C, et al. Toy Models of Superposition[J]. Anthropic Transformer Circuits Thread, 2022.

[9] Zhu J, Greenewald K, Nadjahi K, et al. Asymmetry in Low-Rank Adapters of Foundation Models[C]//International Conference on Machine Learning (ICML). 2024: 62369-62385.

[10] Ganguli D, Lovitt L, Kernion J, et al. Red Teaming Language Models to Reduce Harms: Methods, Scaling Behaviors, and Lessons Learned[J]. arXiv preprint arXiv:2209.07858, 2022.

允许进入毕业设计（论文）下一阶段：是 ☒ 否 ☐		指导教师	何 召 锋
日期	2025 年 12 月 26 日	签字	