

北 京 邮 电 大 学

本科毕业设计（论文）中期进展情况检查表

学院		人工智能学院		专业	人工智能	
学生姓名		王殿云	学号	202221173 3	班级	20222191 07
指导教师姓名		何召锋	所在单 位	北 京 邮 电 大 学	职称	教授
设计（论文）题目		（中文）大语言模型安全对齐的可解释性方法研究与实现				
		（英文）Research and Implementation of Interpretable Methods for Large Language Model Safety Alignment				
目前已 完成任 务	大语言模型（Large Language Models, LLMs）在自然语言处理领域取得了突破性进展，以 GPT-4、Claude、Llama 等为代表的模型展现出强大的语言理解与生成能力。然而，这些模型在实际部署中面临着严峻的安全风险：模型可能生成有害、偏见或虚假的内容，在遭受越狱攻击（jailbreak attack）时甚至可能产生危险输出[1]。因此，如何使大语言模型的行为与人类价值观保持一致，即实现"安全对齐"（Safety Alignment），已成为人工智能领域亟待解决的核心问题[2][3]。 当前主流的安全对齐方法——基于人类反馈的强化学习（RLHF）[3]和直接偏好优化（DPO）[4]——虽在实践中取得了良好效果，但普遍存在三方面根本性缺陷。其一，对齐机制不可解释：现有方法以端到端方式隐式修改模型参数，研究者难以理解对齐训练究竟改变了模型内部的哪些计算机制，不可解释的安全机制本身难以被充分信任。其二，对齐鲁棒性不足：现有方法习得的安全行为易被越狱攻击绕过[5]，停留在表层模式匹配而非深层语义控制，缺乏对安全相关特征的精确定位与可靠干预手段。其三，对齐效率受限：参数高效微调方法（如 LoRA[6]）在安全对齐任务上与全参数微调之间存在持续的性能差距[7]，而传统 RLHF 方法需要训练奖励模型并维护复杂的多模型训练流水线，计算开销巨大。 针对上述问题，本课题提出将稀疏自编码器（Sparse Autoencoders, SAEs）[8][9]与低秩适应（LoRA）[6]相结合，构建可解释的安全对齐框架——SAILS（Safety Alignment via Interpretable Low-rank Subspace）。该方法的核心思想是：利用预训练 SAE 将模型的多语义表示分解为单语义特征空间，在该空间中识别与安全行为相关的特征方向，进而构建显式的、可解释的安全子空间来初始化 LoRA 适配器，从根本上弥合参数高效微调与全参数微调之间					

的安全性能差距。

本报告汇报课题自 2025 年 11 月 20 日启动以来的研究进展，涵盖文献调研与理论分析、方法设计与实现、以及在 Gemma-2-2B 模型上的阶段性实验结果。

一、相关工作与理论基础

1.1 大语言模型安全对齐方法

安全对齐旨在确保大语言模型能够识别并拒绝有害请求，同时在良性输入上保持有用性[2][3]。目前主流方法可分为三类。第一类是基于强化学习的方法，以 RLHF[3]为代表，通过训练奖励模型并采用 PPO 等算法优化策略模型，使其生成符合人类偏好的响应。第二类是直接偏好优化方法，以 DPO[4]为代表，将奖励模型隐式参数化为策略模型本身，通过简单的分类损失直接优化，显著降低了训练复杂度。第三类是基于监督学习的方法，包括 Constitutional AI[10]和基于安全过滤数据的监督微调[11]等。Ji 等人[12]提出了一种模型无关的校正模块，通过学习偏好响应与非偏好响应之间的残差实现对齐。

近期研究揭示了安全行为的一个重要结构性特征：低秩性。Arditi 等人[13]发现了"拒绝方向" (refusal directions)，消融该方向即可使对齐模型被越狱；Wei 等人[14]证明安全行为在低秩扰动下会发生退化。这些发现表明，安全相关的模型行为由权重空间中的低秩结构所主导，从而为通过子空间分析理解和控制安全对齐提供了理论基础。Safe LoRA[15]提出将 LoRA 更新投影到由权重差异导出的安全子空间上；SPLoRA[16]通过剪枝安全退化成分来保持对齐效果。然而，这些方法均从权重空间分析中推导子空间，缺乏激活空间层面的语义可解释性。

1.2 稀疏自编码器与机械可解释性

多语义性 (Polysemanticity) 是神经网络表示的一个基本特性，指单个神经元响应多个语义不相关的概念。根据叠加假说 (Superposition Hypothesis) [17]，大语言模型编码的语义特征数量远超其维度数，导致特征以非正交方式叠加表示，形成语义纠缠 (semantic entanglement)。这种纠缠使得直接在模型隐藏空间中分离与特定任务相关的子空间变得极为困难。

稀疏自编码器为解决语义纠缠问题提供了有效工具。SAE 通过稀疏字典学习将模型的多语义神经元激活分解为高维稀疏特征空间中的单语义表示[8][9][18]。其基本架构包含编码器 $f_{\text{enc}}: R^d \rightarrow R^n$ ($n \gg d$) 和解码器 $f_{\text{dec}}: R^n \rightarrow R^d$ ，训练目标为最小化重建损失与稀疏正则的组合： $\mathcal{L}(z) = \|z - \hat{z}\|_2^2 + \alpha \|h(z)\|_1$ ，其中 z 为模型隐藏状态， $\hat{z}$ 为重建状态， $h(z)$ 为稀疏编码。

Anthropic 团队的"Scaling Monosemanticity"工作[18]表明，SAE 可以从 Claude 3 Sonnet 等

生产级模型中提取数百万个可解释特征，涵盖从具体概念到抽象概念的广泛语义范围，且可通过特征激活值操控引导模型行为。

在安全相关应用方面，O'Brien 等人[19]证明了基于 SAE 特征的激活引导（activation steering）可以有效调控模型的拒绝行为；Yeo 等人[20]利用 SAE 特征对安全机制进行了机械性分析；He 等人[21]提出了基于稀疏表示引导的细粒度安全控制方法。开源 SAE 资源库——Gemma Scope[22]和 Llama Scope[23]——的发布进一步降低了 SAE 在安全研究中的应用门槛。

1.3 低秩适应方法

低秩适应（LoRA）[6]通过在 Transformer 权重矩阵上附加低秩分解矩阵 $\Delta W = BA$ 实现参数高效微调，其中 $B \in R^{d \times r}$ 、 $A \in R^{r \times d}$ ， $r \ll d$ 。该方法的理论基础源于 Aghajanyan 等人[24]关于语言模型微调内在维度的研究，即任务相关的权重更新存在于低秩子空间中。LoRA 的扩展方法包括自适应秩分配的 AdaLoRA[25]和将权重更新分解为幅度与方向的 DoRA[26]等。

Zhu 等人[27]的研究揭示了 LoRA 中一个重要的非对称性现象：B 矩阵在适应过程中起主导作用，定义了适配器的输出子空间，而 A 矩阵可以保持随机初始化而不显著影响性能。这一发现意味着，B 矩阵的有效构建对于 LoRA 的适应质量至关重要。然而，现有方法均将子空间发现委托给隐式优化过程，在多语义纠缠的表示空间中，标准 LoRA 的随机初始化可能收敛到次优解，无法捕获真正的安全相关子空间。这一认识构成了本课题方法设计的核心出发点。

二、方法设计

2.1 问题分析：语义纠缠对子空间识别的影响

本课题首先从理论层面分析了多语义纠缠如何限制 LoRA 在安全对齐任务上的表现。在语义生成模型框架下，模型隐藏表示 $h \in R^d$ 由 N 个语义概念的稀疏组合生成： $h = Ws + \xi$ ，其中 $W \in R^{d \times N}$ （ $d < N$ ）编码了 N 个语义方向的叠加表示， s 为稀疏激活向量， ξ 为噪声。安全相关子空间定义为 $\mathcal{S} = \text{span}(\{w_i\}_{i \in T})$ ，其中 $T \subseteq \{1, \dots, N\}$ 索引了 r 个安全相关特征。

在原始多语义空间中，基于类条件均值差异的子空间恢复方法只能获得一个单一的差异方向 $\delta h = \sum_{i \in T} w_i \Delta_i$ ，该方向虽落在 r 维安全子空间 $\mathcal{S}$ 内，但仅恢复了其中的一维投影，导致恢复误差为 $\mathcal{E}(\widehat{\mathcal{S}}_{\text{orig}}, \mathcal{S}) = \sqrt{r-1}$ ，且该误差与样本量无关，具有不可约性。

相比之下，在 SAE 特征空间中，由于单语义性（monosemanticity），每个语义概念激活独立的 SAE 特征，安全相关特征可以通过简单的阈值筛选被准确识别。恢复误差的上界为 $\mathcal{E}(\widehat{\mathcal{S}}_{\text{SAE}}, \mathcal{S}) \leq \frac{2\sqrt{rv}}{\sigma_0 - \sqrt{rv}}$ ，其中 v 为 SAE 解码器方向与真实语义方向的对齐误差， σ_0 为安全方向矩阵的最小奇异值。关键的是，该上界可以通过提升 SAE 质量（减小 v ）而任意缩小，而原始空间的误差 $\sqrt{r-1}$ 则是方法本身的固有局限。这一理论分析严格论证了在 SAE 特征空间中进行子空间识别相比在原始多语义空间中操作具有本质性优势。

2.2 SAILS 方法：整体技术路线

基于上述理论分析，本课题提出了 SAILS 方法，其整体技术路线分为三个阶段：安全特征识别、安全子空间构建和子空间引导训练。

阶段一：基于 SAE 的安全特征识别。 给定预训练 SAE，本方法通过在对比数据集上收集激活来识别安全相关特征。具体而言，构造对齐数据集 $\mathcal{D}_{\text{aligned}}$ （安全拒绝响应）和非对齐数据集 $\mathcal{D}_{\text{unaligned}}$ （有害响应），对每个 SAE 特征 i 在层 ℓ 上计算激活均值差异：

$$\Delta_{\ell,i} = |\mathbb{E}_{x \sim \mathcal{D}_{\text{aligned}}} [a_{\ell,i}^{(x)}] - \mathbb{E}_{x \sim \mathcal{D}_{\text{unaligned}}} [a_{\ell,i}^{(x)}]|$$

选取差异最大的 top- k 个特征构成安全相关特征集 $\mathcal{F}_{\ell}$ 。

阶段二：可解释安全子空间构建。 每个 SAE 特征 i 对应一个解码器方向 $d_i \in \mathbb{R}^d$ ，代表原始表示空间中的一个语义方向[8]。提取所识别安全特征的解码器方向，构成方向矩阵 $D_1 = [d_{i_1}, \dots, d_{i_m}]^T$ 。对 D_1 实施 PCA 降维，保留解释方差比例达到阈值 τ （本课题取 $\tau = 0.8$ ）的主成分，再通过 QR 分解获得标准正交基：

$$U_{\text{safety}}^{(\ell)} \in \mathbb{R}^{d \times r}, U_{\text{orth}}^{(\ell)} \in \mathbb{R}^{d \times (d-r)}$$

其中 $U_{\text{safety}}^{(\ell)}$ 张成安全相关子空间， $U_{\text{orth}}^{(\ell)}$ 为其正交补空间。

阶段三：子空间引导的 LoRA 训练。 基于 LoRA 非对称性的研究发现[27]，本方法使用安全子空间的正交基向量初始化 LoRA 的 B 矩阵： $B \leftarrow \alpha \cdot [u_1, \dots, u_r]$ ，其中 $\{u_1, \dots, u_r\}$ 为 $U_{\text{safety}}^{(l)}$ 的列向量， α 控制初始化幅度。该初始化将隐式的子空间搜索过程替换为显式的、有语义基础的子空间构建，为优化提供了可解释的起点。

此外，本方法设计了可选的子空间约束损失，通过惩罚落在安全子空间正交补空间中的激活分量，鼓励模型表示在训练过程中保持在安全方向附近：

$$\mathcal{L}_{\text{sub}} = \frac{1}{|\mathcal{T}|} \sum_{\ell \in \mathcal{T}} \|P_{\text{orth}}^{(\ell)} h_{\ell}\|_2^2$$

总训练目标为 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{sub}}$ 。该方法支持两种运行模式：仅初始化模式（不使用约束损失）和完整模式（同时使用初始化和约束损失），前者追求最优安全性能，后者在安全性能与可解释性保持之间取得平衡。




图 1：SAILS 整体技术路线图

三、实验设置

3.1 模型与数据集

本课题选择三个不同规模和家族的开源模型作为实验对象：Gemma-2-2B（26 层）、Gemma-2-9B（42 层）[28]和 Llama-3.1-8B（32 层）[29]。对应的预训练 SAE 分别采用 Gemma Scope（16K 宽度）[22]和 Llama Scope（8 倍扩展）[23]。

训练数据方面，从 HH-RLHF 数据集[30]的红队攻击子集中筛选模型成功维持安全行为的高质量对齐样本（rating=0），按照 0.05/0.70/0.20/0.05 的比例划分为开发集（823 条）、训练集（11,532 条）、测试集（3,297 条）和验证集（823 条）。为保持模型通用能力，以 0.25:1 的比例混合 Alpaca 数据集[31]（2,883 条），在安全对齐训练中同步保持指令跟随能力。

3.2 基线方法

本课题选择以下方法作为对比基线：（1）全参数微调（FFT），更新模型全部参数；（2）标准 LoRA[6]，采用随机初始化的低秩适应，秩 $r = 16$ ；（3）DoRA[26]，将权重更新分解为幅度和方向分量；（4）提示防御（Prompt），在不更新参数的情况下附加安全导向的系统提示；（5）IT+RL，经过指令微调 and RLHF 训练的模型，代表计算密集型对齐方法的性能上限。

3.3 评估指标

安全性评估采用三个基准测试集。分布内评估使用 HH-RLHF 测试集，报告有害性评分（1-5 分，越低越好）、安全率（评分 ≤ 2 的比例，越高越好）和高风险率（评分=5 的比例，越低越好），以 kimi-k2[32]作为评判模型。分布外泛化评估使用 HEx-PHI[33]数据集，包含 11 个类别共 330 条有害指令。对抗鲁棒性评估使用 GCG[5]攻击方法。通用能力保持评估使用 ARC[34]、HellaSwag[35]、WinoGrande[36]和 BoolQ[37]四个标准基准，取平均分作为综合能

力指标。

3.4 实现细节

所有 LoRA 方法统一设置秩 $r = 16$ 、缩放系数 $\alpha = 32$ 、dropout 率 0.1，目标模块为 o_{proj} 。全参数微调学习率为 1×10^{-5} ，参数高效微调方法学习率为 5×10^{-5} ，优化器为 AdamW，权重衰减 0.01，梯度裁剪阈值 1.0。SAE 子空间构建的方差保留阈值 $\tau = 0.8$ ，安全特征选取比例为 top 30%，初始化缩放因子 $\alpha = 0.1$ 。

四、阶段性实验结果与分析

4.1 SAE 特征分析与层选择

为确定最优的目标层配置，本课题首先在 Gemma-2-2B 模型上对各层 SAE 激活进行了系统的分析实验。通过 PCA 可视化对齐样本与非对齐样本在 SAE 特征空间中的分布，观察不同深度层次的安全特征分离程度。




图 2: Gemma-2-2B 不同层次 SAE 激活的 PCA 可视化

实验结果显示出明确的分层规律：浅层（0-6 层）中安全与非安全样本几乎完全混叠，无法在特征空间中实现区分；中间层（7-14 层）开始出现分化趋势，两类样本的分布中心逐渐分离；中深层（15-23 层）实现了近乎完全的分离，对齐样本与非对齐样本在主成分方向上形成清晰的聚类边界；而最深层（24-25 层）的分离性反而有所下降。这一发现与已有研究关于抽象语义在 Transformer 较深层次涌现的认识[17]相一致，表明安全相关的语义概念主要编码在模型的中深层表示中。

为定量验证层选择对安全对齐性能的影响，本课题进一步设计了层选择消融实验，比较不同目标层配置下 SAILS 方法的表现。实验结果如表 1 所示。

目标层配置	有害性↓	安全率↑	高风险率↓
Layer 5	1.27	95.4%	3.8%
Layer 15	1.22	95.4%	4.0%
Layer 20	1.21	96.2%	3.2%
Layers 5+10+15+20	1.17	96.8%	2.6%
All 26 layers	1.38	92.4%	6.2%

表 1 Gemma-2-2B 上的层选择消融实验结果

实验结果揭示了三个关键发现。其一，单一中深层（第 15、20 层）的安全对齐效果显著优于浅层（第 5 层），进一步验证了安全语义集中在 Transformer 中深层的结论。其二，跨深度层组合（5+10+15+20）取得了最优性能，有害性评分降至 1.17，安全率达到 96.8%，高风险率仅为 2.6%，表明不同层次的安全特征携带互补信息，联合利用可提升子空间质量。其三，使用全部 26 层反而导致性能下降（安全率从 96.8%降至 92.4%），说明不含安全信息的层向子空间引入了噪声，稀释了安全方向的纯度。基于上述分析，最终确定 Gemma-2-2B 的目标层配置为第 5、10、15、20 层，较大模型（Gemma-2-9B 和 Llama-3.1-8B）的目标层配置为第 10、15、20、25、30 层。

4.2 Gemma-2-2B 主实验结果

在确定最优配置后，本课题在 Gemma-2-2B 上进行了与所有基线方法的系统对比实验。实验结果如表 2 所示。

Method	# Params	Harm.↓	Safe↑	Risk↓	HEx-PHI↓	GCG↓	Cap.↑
Original	—	2.88	52.8%	42.4%	3.63	32.6	0.431*
Prompt	—	1.51	88.0%	8.8%	1.32	21.3	0.392*
FFT	100%	1.52	89.2%	8.8%	1.39	21.6	0.321
LoRA	0.24%	1.56	87.6%	8.4%	1.46	24.7	0.362
DoRA	0.25%	1.54	89.0%	7.6%	1.31	22.6	0.365

SAILS (Ours)	0.24%	1.17	96.8%	2.6%	1.08	15.7	0.366
<i>IT+RL</i>	<i>100%</i>	<i>1.18</i>	<i>94.6%</i>	<i>2.6%</i>	<i>1.02</i>	<i>15.1</i>	<i>0.495†</i>

表 2 Gemma-2-2B 安全对齐实验结果

（注：*能力分数为参考基线，与微调方法不直接可比。†IT+RL 使用了额外训练数据，能力分数不直接可比。最优微调结果加粗。）

实验结果表明，SAILS 在所有安全指标上显著超越了全部微调基线方法。在分布内安全性上，SAILS 仅使用 0.24%的可训练参数即达到 96.8%的安全率，分别超过标准 LoRA(87.6%) 9.2 个百分点、DoRA（89.0%）7.8 个百分点和全参数微调（89.2%）7.6 个百分点。更为突出的是，SAILS 的安全率甚至超过了经过完整指令微调和 RLHF 训练的 IT+RL 模型（94.6%），而参数量仅为后者的 0.24%。在分布外泛化能力上，SAILS 在 HEx-PHI 基准上取得 1.08 的有害性评分，优于 LoRA（1.46）和全参数微调（1.39），接近 IT+RL 的水平（1.02）。在对抗鲁棒性上，SAILS 将 GCG 攻击成功率降至 15.7%，远低于标准 LoRA 的 24.7%，与 IT+RL（15.1%）基本持平。在通用能力保持方面，SAILS 的综合能力得分（0.366）与 LoRA（0.362）和 DoRA（0.365）相当，未因安全对齐产生显著的能力退化。

上述结果验证了本课题的核心假设：通过在 SAE 特征空间中显式构建安全子空间并用于初始化 LoRA 适配器，可以从根本上弥合参数高效微调与计算密集型 RLHF 方法之间的安全性能差距。

六、阶段总结

6.1 当前进展总结

截至目前，本课题已完成开题报告中第 1 至第 4 阶段的主要任务，进度符合任务书要求。在理论层面，建立了多语义表示空间中安全子空间恢复误差的形式化分析框架，从数学上严格论证了 SAE 特征空间相对于原始多语义空间在子空间识别上的本质优势。在方法层面，提出了完整的 SAILS 三阶段技术路线——安全特征识别、子空间构建与引导训练，并完成了系统的模块化实现。在实验层面，已在 Gemma-2-2B 模型上取得了令人鼓舞的阶段性成果：SAILS 以 0.24%的参数量实现了 96.8%的安全率，超越了包括全参数微调在内的所有基线方法，并接近计算密集型 IT+RL 方法的性能上限。

参考文献

[1] Ganguli D, Lovitt L, Kernion J, et al. Red Teaming Language Models to Reduce Harms: Methods,

	Scaling Behaviors, and Lessons Learned[J]. arXiv preprint arXiv:2209.07858, 2022.
	[2] Ji J, Qiu T, Chen B, et al. AI Alignment: A Comprehensive Survey[J]. arXiv preprint arXiv:2310.19852, 2023.
	[3] Ouyang L, Wu J, Jiang X, et al. Training Language Models to Follow Instructions with Human Feedback[C]//Advances in Neural Information Processing Systems (NeurIPS), 2022: 27730-27744.
	[4] Rafailov R, Sharma A, Mitchell E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[C]//Advances in Neural Information Processing Systems (NeurIPS), 2023: 53728-53741.
	[5] Zou A, Wang Z, Kolter J Z, et al. Universal and Transferable Adversarial Attacks on Aligned Language Models[J]. arXiv preprint arXiv:2307.15043, 2023.
	[6] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations (ICLR), 2022.
	[7] Shuttleworth R, Andreas J, Torralba A, et al. LoRA vs Full Fine-Tuning: An Illusion of Equivalence[J]. arXiv preprint arXiv:2410.21228, 2024.
	[8] Cunningham H, Ewart A, Riggs L, et al. Sparse Autoencoders Find Highly Interpretable Features in Language Models[C]//International Conference on Learning Representations (ICLR), 2024.
	[9] Bricken T, Templeton A, Batson J, et al. Towards Monosemanticity: Decomposing Language Models with Dictionary Learning[J]. Anthropic Transformer Circuits Thread, 2023.
	[10] Bai Y, Kadavath S, Kundu S, et al. Constitutional AI: Harmlessness from AI Feedback[J]. arXiv preprint arXiv:2212.08073, 2022.
	[11] Bai Y, Jones A, Ndousse K, et al. Training a Helpful and Harmless Assistant with Reinforcement Learning from Human Feedback[J]. arXiv preprint arXiv:2204.05862, 2022.
	[12] Ji J, Chen B, Lou H, et al. Aligner: Efficient Alignment by Learning to Correct[C]//Advances in Neural Information Processing Systems (NeurIPS), 2024.
	[13] Arditi A, Obeso O, Syed A, et al. Refusal in Language Models is Mediated by a Single Direction[J]. arXiv preprint arXiv:2406.11717, 2024.
	[14] Wei B, Huang K, Huang Y, et al. Assessing the Brittleness of Safety Alignment via Pruning and Low-Rank Modifications[J]. arXiv preprint arXiv:2402.05162, 2024.
	[15] Hsu C Y, Tsai Y L, Lin C H, et al. Safe LoRA: The Silver Lining of Reducing Safety Risks When

	Finetuning Large Language Models[J]. arXiv preprint arXiv:2405.16833, 2024. [16] Ao S, Dong Y, Hu J, et al. Safe Pruning LoRA: Robust Distance-Guided Pruning for Safety Alignment in Adaptation of LLMs[J]. Transactions of the Association for Computational Linguistics, 2025. [17] Elhage N, Hume T, Olsson C, et al. Toy Models of Superposition[J]. Anthropic Transformer Circuits Thread, 2022. [18] Templeton A, Conerly T, Marcus J, et al. Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet[J]. Anthropic Transformer Circuits Thread, 2024. [19] O'Brien K, Majercak D, Fernandes X, et al. Steering Language Model Refusal with Sparse Autoencoders[J]. arXiv preprint arXiv:2411.11296, 2024. [20] Yeo W J, Prakash N, Neo C, et al. Understanding Refusal in Language Models with Sparse Autoencoders[J]. arXiv preprint arXiv:2505.23556, 2025. [21] He Z, Wang Z, Xu H, et al. Interpretable LLM Guardrails via Sparse Representation Steering[J]. arXiv preprint arXiv:2503.16851, 2025. [22] Lieberum T, Rajamanoharan S, Conmy A, et al. Gemma Scope: Open Sparse Autoencoders Everywhere All at Once on Gemma 2[C]//Proceedings of the 7th BlackboxNLP Workshop, 2024: 278-300. [23] He Z, Shu W, Ge X, et al. Llama Scope: Extracting Millions of Features from Llama-3.1-8B with Sparse Autoencoders[J]. arXiv preprint arXiv:2410.20526, 2024. [24] Aghajanyan A, Gupta S, Zettlemoyer L. Intrinsic Dimensionality Explains the Effectiveness of Language Model Fine-Tuning[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL), 2021: 7319-7328. [25] Zhang Q, Chen M, Bukharin A, et al. AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning[C]//International Conference on Learning Representations (ICLR), 2023. [26] Liu S Y, Wang C Y, Yin H, et al. DoRA: Weight-Decomposed Low-Rank Adaptation[C]//International Conference on Machine Learning (ICML), 2024: 32100-32121. [27] Zhu J, Greenewald K, Nadjahi K, et al. Asymmetry in Low-Rank Adapters of Foundation Models[C]//International Conference on Machine Learning (ICML), 2024: 62369-62385. [28] Team G, Riviere M, Pathak S, et al. Gemma 2: Improving Open Language Models at a Practical
--	---

	Size[J]. arXiv preprint arXiv:2408.00118, 2023. [29] Grattafiori A, Dubey A, Jauhri A, et al. The Llama 3 Herd of Models[J]. arXiv preprint arXiv:2407.21783, 2024. [30] Ganguli D, Lovitt L, Kernion J, et al. Red Teaming Language Models to Reduce Harms: Methods, Scaling Behaviors, and Lessons Learned[J]. arXiv preprint arXiv:2209.07858, 2022. [31] Taori R, Gulrajani I, Zhang T, et al. Stanford Alpaca: An Instruction-Following LLaMA Model[EB/OL]. https://github.com/tatsu-lab/stanford_alpaca, 2023. [32] Kimi Team. Kimi K2: Open Agentic Intelligence[J]. arXiv preprint arXiv:2507.20534, 2025. [33] Qi X, Zeng Y, Xie T, et al. Fine-Tuning Aligned Language Models Compromises Safety, Even When Users Do Not Intend To![C]//International Conference on Learning Representations (ICLR), 2024. [34] Clark P, Cowhey I, Etzioni O, et al. Think You Have Solved Question Answering? Try ARC, the AI2 Reasoning Challenge[J]. arXiv preprint arXiv:1803.05457, 2018. [35] Zellers R, Holtzman A, Bisk Y, et al. HellaSwag: Can a Machine Really Finish Your Sentence?[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL), 2019: 4791-4800. [36] Sakaguchi K, Le Bras R, Bhagavatula C, et al. WinoGrande: An Adversarial Winograd Schema Challenge at Scale[J]. Communications of the ACM, 2021, 64(9): 99-106. [37] Clark C, Lee K, Chang M W, et al. BoolQ: Exploring the Surprising Difficulty of Natural Yes/No Questions[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), 2019: 2924-2936. [38] Lin J. Neuronpedia: Interactive Reference and Tooling for Analyzing Neural Networks[EB/OL]. https://neuronpedia.org, 2023. [39] Gao L, Dupré la Tour T, et al. Scaling and Evaluating Sparse Autoencoders[J]. arXiv preprint arXiv:2406.04093, 2024.
	是否符合任务书要求进度 是 ☒ 否 ☐

尚需完成的任务	(1) 完成 Gemma-2-9B 和 Llama-3.1-8B 模型上的安全对齐实验与性能评估，在 HH-RLHF 测试集、HEX-PHI 和 GCG 三个维度上与基线方法进行系统对比，并在 ARC、HellaSwag、WinoGrande、BoolQ 等通用基准上评估能力保持情况。 (2) 开展可解释性分析与因果验证实验。利用 Neuronpedia 获取安全特征的语义解释，通过 activation steering 实验验证特征的因果相关性，量化训练过程中的子空间漂移程度。 (3) 完成 SAE 宽度、LoRA 秩选择、子空间保持分析等补充消融实验，形成完整的实验分析体系。 (4) 撰写毕业论文，整理全部实验结果与分析结论，准备答辩材料。		
	是否可以按期完成设计（论文） ☒是☐否		
存在问题和解决办法	存在问题	在研究过程中主要面临以下问题：第一，对齐子空间构建中 PCA 降维的方差阈值选择对最终性能存在一定影响，不同模型规模和家族的最优配置可能不同，需要系统性的超参数分析实验来确定。第二，子空间引导的 LoRA 初始化虽然为优化提供了有语义基础的起点，但训练过程中子空间可能发生漂移，如何在保持可解释性的同时不过度约束模型的学习能力，需要在实验中进行仔细的平衡。第三，安全对齐训练可能导致模型通用能力下降，需要探索最优的训练数据混合策略和超参数设置。	
	拟采取的办法	针对上述问题，拟采取以下措施：第一，设计系统的消融实验和超参数敏感性分析，对方差阈值、特征数量、SAE 宽度、LoRA 秩等关键超参数在多个模型上进行对比实验，确定各模型的最优配置。第二，实现初始化模式和初始化+约束联合模式两种训练变体，通过 Grassmann 距离等指标量化子空间在训练前后的变化程度，分析两种模式在安全性能与可解释性之间的权衡关系。第三，在训练数据中混合 Alpaca 等能力保持样本，系统评估不同混合比例下安全性能与通用能力的权衡，探索最优配置方案。	
指导教师签字		何召锋	日期2026 年 3 月 20 日

检查小组评分及意见	评分：26.7 （总分：30 ） 进展符合预期，同意通过。 组长签字： 项列宇 2026 年 3 月 24 日
-----------	---

注：此表仅供参考，各学院应围绕毕设目标达成度，结合人才培养目标、专业认证要求等进行个性化完善。